

# GPT-1 科研全仿真 · S9 成稿

---

## 目录

一个架构吃下十二个任务

# 一个架构吃下十二个任务

——GPT-1 的第一人称复盘：一个直觉、三次失败，和我一年后才发现记错的三件事

仿真声明：本文是基于公开材料的第一人称合理重构，不代表论文作者本人或其机构的真实经历、观点或言论。凡"我记得""我当时猜"的段落属重构；凡带数字的事实均可在论文原文核对，依据见每幕末的章末注。

## 第一幕·问题：句子级的东西，为什么迁不动

本章论点：卡住我们的不是模型不够大，是两件最基础的事——"用什么目标学"和"用什么方式把学到的东西挪到任务上"——当时都还没有答案。

那年我在做无监督表征。上一年我做了一件事，现在回头看它是我后来所有判断的源头：一个 byte 级的 mLSTM，纯粹用"猜下一个字节"来训，训完以后里面长出了一个专门管情感的神经元——你把它拧一下，生成的文本情感就跟着翻面（可查证：Radford, Jozefowicz, Sutskever, 2017）。同期我还在写 block-sparse 的 GPU kernel（可查证：论文引文 [16]），动机很直白：这类大模型，得先训得起。

那件事在我脑子里留下一个执念：语言模型内部已经悄悄学会了"任务"，只是没人把它系统地挖出来。后来我常把这个念头压缩成一句自问：如果语言模型在预训练里已经学会了怎么读句子，为什么每个下游任务还要从零学一遍怎么用它？这句话听着像口号，但它其实是一个能拿来否决方案的判断标准——它第一个否决的就是我自己那个最省事的想法（第二幕详说）。

而当时的 NLP 现状正好反着——词嵌入早就是标配，可"比词更高的东西"，也就是句子级、篇章级的知识，谁也迁不动。

先立三个词，后面要反复用：

迁移：在一大堆没标注的文本上学到的东西，怎么挪到某个具体任务上去用。目标函数（练习题）：你逼模型练的那道题——练什么题，模型就长成什么样。预训练 / 微调：先用海量没标注的文本把一个大模型练出来（预训练），再拿少量标注数据把它调到具体任务上（微调）。

为什么迁不动？我把当时的困境写成两句话，这两句话后来几乎一字不改地进了论文的第一节（可查证：论文 §1）：

第一，不清楚该用哪种"练习题"来学（术语叫优化目标）。当时前沿分三派：用"猜下一个词"来学（语言建模）、用"把英语翻成法语"来学（机器翻译）、用"判断两句话是不是讲同一件事"来学（篇章连贯）——而且是各赢各的任务，没有公认赢家（可查证：§1 原文 `each method outperforming the others on different tasks`）。

第二，不清楚学到的东西该怎么挪到任务上。当时流行三条路：一是在模型身上给不同任务加不同的专用部件，再把模型内部给每个词、每句话算出的那串数字（行话叫"表示"）当成外挂特征，另接一套小模型来读它；二是上一套复杂的学习技巧，比如先只调最后一层、再一层层往前放开，或者给不同层设不同的学习速度；三是往任务的目标里再塞一道练习题（可查证：§1 列出的 [43,44] / [21] / [50]）。

这里得先对外行解释一件最基础的事，因为后面所有的判断都建立在这上面。

什么是语言模型。一句直觉类比：它就是一直在做完形填空——把一段话的最后几个词盖住，猜下一个词是什么。机制上，它把一整段文本拆成一个个 token，然后要求模型对每一个位置都输出"下一个 token 的概率分布"，用真实文本去校正。写成式子就是：给定前面  $k$  个 token，最大化下一个 token 的对数概率， $L_1(U) = \sum \log P(u_i | u_{1-k}, \dots, u_{i-1}; \Theta)$ （可查证：§3.1 式 (1)）。

它哪里不像"理解"。完形填空做得再好，也不等于它懂了意思——它只是把海量文本里的搭配关系压缩进了参数。这一点我后面会吃亏：我一度以为"它在预训练里学会了任务"，而更准确的表述是"它学到了很多下游任务用得上的组件"（后者才是论文 §5 的说法）。

当时我人就在这个夹缝里：一边坚信大模型里藏着任务，一边拿不出任何办法把任务挖出来。

## 第二幕·直觉：如果架构一动不动，只动输入呢

本章论点：我后来全部的赌注，是把“任务差异”从架构层搬到输入层；在把这个赌注写下来之前，我先写死过一个更省事、但注定要死的想法。

我的第一个想法非常省事，甚至有点偷懒：顺着情感神经元往下做，把无监督预训练好的大 **LSTM** 的隐状态抽出来，当成特征，喂给每个任务的专用模型。这条路不需要我研究怎么迁移——特征给你了，剩下的是你的事。

它就是当时最主流的两条路线：CoVe（用机器翻译学上下文词向量）和 ELMo（用双向 LSTM 学上下文词向量）都是这么干的。

它死在一个结构性问题上，而不是死在我训得不好。特征路线里，迁过去的只有“表示”，而任务模型本身还是随机初始化、任务专用的。论文里我把这句话写成了全文最锋利的一句批评：ELMo 那一派的做法“为每个下游任务引入了一大堆新参数”（可查证：§2 原文 `a substantial amount of new parameters for each separate target task`）。也就是说，无监督学到的东西只负责输入层，真正的推理还是靠标注数据现场学——标注少的任务照样崩。这跟我“模型内部已经会了”的信念直接打架。

第二处问题在 LSTM 自己身上：它对长程依赖是“一条状态向量独立承载”，几百词之前的信息基本磨没了；做句子级任务勉强可用，做篇章级推理力不从心；而且训练很慢（依据：情感神经元那版的训练设置属论文外材料，见章末注）。

第三处问题最难堪：这条路已经有人走过了。Dai & Le 在 2015 年就做过“LSTM 语言模型预训练 + 微调”，Howard & Ruder 在那年 1 月刚把它做到位（ULMFIT）——但两组都只用在文本分类上（可查证：§2）。NLI、QA 这种“输入是两三段文本”的结构化任务，这条路线没人走通。

转机是两件事撞在一起。

一是架构。Vaswani 他们 2017 年的 Transformer，加上那年年初有人用 Transformer decoder 做长文生成（可查证：论文引文 [62]、[34]；§3.1 明确写 `a multi-layer Transformer decoder` [34]），证明了这套东西当纯语言模型用是成立的。它的关键不在“更深”，而在记忆方式：每个位置可以直接看回所有历史位置。

一句直觉类比：**LSTM** 像是用一根绳子把整句话串下来，读到后面时前面早被磨掉了；注意力像是给每个词都贴便利贴，允许它直接连到前面任何一个词上。机制上就是让每个位置的表示由前面所有位置加权求和得到，权重由“当前词和那个词有多相关”算出来—— $\text{softmax}(QK^T/\sqrt{d})V$ ，而且为了维持“预测下一个词”，得用一个遮罩把未来位置挡掉（可查证：§3.1 式 (2) 与 Fig 1 左）。

它哪里不像我后来给的评价那么高。注意力并不保证“看懂”，它只是给模型提供了一条更短的梯度路径去建立长程依赖；而且这份“结构化记忆”要花平方级的算力去买。我在论文里写它是 `a more structured memory for handling long-term dependencies`（可查证：§1），这是我能核到的表述；但把它读成“长程推理因此被解决”就过誉了。

顺带把这份记忆的价钱说清楚：注意力让每个位置都能看回它之前的所有位置，代价是计算量随句子长度平方增长——句子长一倍，算力大约要翻四倍。所以“换更长的上下文”从来不是免费升级，它是一笔必须用算力实打实支付的账。当年我敢下这个注，是因为我要的恰恰是长程：语料是整段整段的小说，长程带来的收益压过了它多花的算力——这笔账我算对了，但它同时也意味着，任何想再往下走的人，都得先解决“算力怎么跟上”这个问题。（这部分属通用技术常识，不是论文内容，故未加论文出处——见章末注。）

二是怎么迁移。Rocktäschel 2015 年那种做蕴含的思路：把前提和假设用分隔符拼成一条序列，让模型自己去处理（可查证：[52]，§1 与 §3.3 均引）。如果这招成立，“结构化任务没法微调”的死结就解了——不改架构，改输入就行。

拼图在脑子里合上了：Transformer decoder 当 LM 预训练 → 所有任务统一拍平成一条序列 → 只在最后加一个线性层微调，架构零改动，预训练每一层参数都参与下游。

这里必须把两条路线的区别讲清楚，因为它是这一整套方法的理论核心。

预训练当成“初始化”，和预训练当成“特征”，是两件事。一句直觉类比：特征迁移像请一位翻译——他把你说的话口译一遍（提供表示），但之后每个专业问题还得请各自的专家（随机初始化的任务模型）来答；初始化迁移是把这位翻译请来当项目经理，让他自己上手所有专业问题。机制上的差别是参数量：前者每个任务新增一大堆没经过预训练的模块，后者只多一个输出层  $W_y$  和几个分隔符的 embedding（可查证：§3.2 末句 `the only extra parameters we require during fine-tuning are  $W_y$ , and embeddings for delimiter tokens`）。

它哪里不像“免费”。零架构改动不等于没有代价——它把任务的结构信息全压到了输入格式上。一旦拍平方式错了，模型连“哪边是前提、哪边是假设”都看不见。这个隐患，第三幕会以最棘手的方式回来找我。

### 第三幕·试错：这一阶段真正的工作量在删东西

本章论点：从 **v0** 走到论文里的形式，我做的不是加法，是三次删改；而每一次删改的理由，事后有一半是我自己猜的。

先还一笔债：用哪份语料。候选两个：BooksCorpus 和 1B Word Benchmark。查完发现 1B Word 是句子级打乱的——长程结构被物理摧毁（可查证：§4.1 原文 `shuffled at a sentence level - destroying long-range structure`）。我的全部赌注押在长程依赖上，用它等于亲手毁掉自己押注的结构。于是选 BooksCorpus：七千多本未出版的英文小说，天然长段落连续文本（可查证：§4.1）。训完的困惑度是 18.4（可查证：§4.1 `token level perplexity of 18.4`）——这是我这辈子第一次有一个数能证明“我的语言模型本身训得还行”，而不是靠下游任务间接背书。

数据这一轨还有两笔账没算。

第一笔是清洗规则。原始小说文本里混着乱码、错乱的符号、不统一的标点和空白，这些不处理，词表会被噪音吃掉一大块。我们的做法是用 `ftfy` 修文本、用 `spaCy` 切词（可查证：§4.1）——但真正的功夫在规则的松紧上，而规则这东西有反身性：收得紧一点，噪音是干净了，可一些本来有意义的写法（作者刻意用的怪标点、方言拼写）也被一起滤掉了；而语言模型恰恰要靠这些“不规则”来学会真实语言的样子。我在这里犯过一次典型错误：先把规则收到最紧，结果训出来的模型在正常句子上反而不稳，之后才把规则放松回去。这是个只有动手才会遇到的坑——清洗的目标从来不是“干净”，而是“干净到词表够用、又脏到分布还在”。然后才是词表：4 万次 BPE 合并（可查证：§4.1）。

第二笔账是规模。语料就这么大——七千多本小说，量级上与当时同行的另一个选择相当（可查证：§4.1 对两个语料“大小相当”的比较）。它不是我们算出来的最优规模，而是那个年代能合法拿到、又确实具备长程连续性的最大一块。“数据规模怎么定的”这个问题，当时的诚实答案是“只有这么多”。

**v0**：裸拼接。最直接的形式化——Transformer decoder 在语料上训 LM，微调时把任务的两段文本直接拼成一条序列，取最后一个位置的隐状态过线性层出标签，目标函数只有监督损失。

它不够用，两个理由。一，没有正则，微调等于让几千个标注样本去拉动 1.17 亿参数（参数量可由 §4.1 的结构参数算出），小样本上过拟合的风险极高。二，“直接拼接”没有任何结构标记：模型不知道前提在哪结束、假设从哪开始，也不知道该从哪里取表示——而预训练时它从没见过这种“两段拼盘”的输入。这是典型的分布外输入，是拿没见过的格式去考验一个刚训好的模型。

**v1**：加辅助目标 + 加分隔符。补丁来自“辅助目标”那一派：微调目标改成  $L3 = L2 + \lambda \cdot L1$ （可查证：§3.2 式 (5)，权重  $\lambda$  在 §4.1 取 0.5），也就是让模型在下游任务上继续做一点语言建模；同时给输入加上 `<s>`、`<e>`、`<$` 这些分隔符，把结构边界告诉模型（可查证：§3.3 首段）。

这里我要诚实一次，因为一年后我重看自己的表才发现当时想错了：我给辅助目标写的动机是“提升泛化、加速收敛”（这是论文 §3.2 的原话 `improving generalization ... and accelerating convergence`），但在我心里的账本是“它能治小数据过拟合”。后半句是错的——第四幕会用我自己的消融表把账算给我看。

**v1** 暴露的新问题很具体。相似度任务：两个句子没有天然先后，“甲\$乙”和“乙\$甲”是同一个样本，但拼接强行指定了顺序，模型会学到一种假的顺序偏置。QA 更麻烦：一个文档配 K 个候选答案，拼成一条序列根本没法表达“K 选 1”这个结构。

**v2**：按任务结构设计输入。最后一块拼图：不是“一种拼法走天下”，而是针对每类任务的形状给不同的拼法——但所有花样都只动输入，不动模型的骨架（“骨架”就是那些层、那些参数的组织方式，也就是行话里的“架构”）。

先给一个外行版：像把两道题抄到同一张答题卡上，中间盖一个分隔章，让阅卷人自己看出题目的结构。下面三类任务，就是把这张卡做成三种版式（可查证：§3.3 三个任务族全文）：

- 判断类（前提能不能推出假设）：一张卡，写成 前提 \$ 假设，模型从头读到尾，末尾接一个最简单的打分器（术语叫线性层：把一串数字加权求和，输出一个分数）出结论。
- 比较类（两句话是不是一个意思）：两句之间本来没有先后，所以同一个样本抄两遍——正着抄一遍、倒着抄一遍，各自读一遍模型，再把两次读出来的那串数字按位相加。用这种“正反一样”的对称，把“谁在前谁在后”这个本不存在的假信息抵消掉。
- 选择题类（一个文档配 K 个候选答案）：把文档、问题、候选答案拼成一张卡；K 个候选就是 K 张卡，每张各读一遍得一个分数，最后把 K 个分数归一化成“选谁的概率”（这一步的术语叫 softmax——把一组任意分数摊成一组合计为 1 的概率）。

写成式子，其实只有三行（可查证：§3.3）：判断类 `[premise; $; hypothesis]`；比较类 `[A; $; B]` 与 `[B; $; A]` 两条各读一遍再相加；选择题类 `[z; q; $; ak]` 各自读一遍后过 softmax。

它哪里不像“白给”。那几个分隔符本身是随机初始化的，预训练时模型从没见过它们——我以为我在给它结构，其实是给它一批必须现场学会的新符号。这一点后来在我排查实验崩溃时，成了第一个被冤枉的对象。

超参数的坦白账。抄惯例的部分：12 层、768 维、12 个头、FFN 3072，加上 Adam、线性 warmup 接余弦衰减、GELU、dropout 0.1、修正版 L2——全是当时的标准件（可查证：§4.1）。调出来的部分：微调学习率  $6.25e-5$ 、批 32、**3 个 epoch**——“3 个 epoch 对大多数情况够用”这句话背后，是小数据集上第 4、第 5 个 epoch 开始掉头的观察（可查证：§4.1 原文 `finetunes quickly and 3 epochs of training was sufficient`；“是调出来的”属重构成）。纯猜的部分： $\lambda=0.5$ 。论文只给了值，没给理由（可查证：§4.1）——因为它真的没有理由，它就是网格搜索里可接受的那一个。

然后是那次崩溃。微调阶段，在 STS-B、RTE、MRPC、CoLA 这些数据集上，loss 曲线像过山车：同一套超参，换个随机种子，能从接近 SOTA 掉到基线以下。

排查路径走了两条弯路。第一条，我怀疑那几个分隔符 embedding——它们随机初始化，预训练里没见过，我猜是它们在污染序列表示。我试过冻结它们、试过把初始化调小，没用。第二条才摸到真凶：微调对小数据太粗暴。1.17 亿参数在几千个样本上强拉，两三个 epoch 就过拟合，而且不同任务的崩溃点还不一样。

最后稳住它的是三件套：线性 warmup 加衰减、3 个 epoch 早停、以及 v1 留下的辅助目标。当时我真心以为是辅助目标在兜底。这一点，第四幕会用我自己的数据纠正。

## 第四幕·定型与反例：RTE 这 2490 条样本

本章论点：我最后保住的不是分数，是一个说法；而一个说法要想站得住，得经得起把表摊开逐行算。

实验的排布是这样的：要证明“一个任务无关的模型能超越每个任务的专用模型”，任务面就必须覆盖单句、句对、多段三种结构——于是定了四类任务、12 个数据集（可查证：§4.2 与 Table 1）。选 GLUE 还有个现实考量：它那年 4 月刚发布，是社区公认的擂台；论文里有专门的表把 GLUE 系任务单列（可查证：Table 4 注 `All task evaluations in this table were done using the GLUE benchmark`，§1 也点名引用了这个 benchmark）。

每个任务都选当时的最好成绩（圈内简称 SOTA）当对手：NLI 上是 CAFE 和 Stochastic Answer Network，QA 上是 Dynamic Fusion Net 和 BiAttention MRU，GLUE 系任务直接用它的官方基线（可查证：Table 2/3/4）。我最怕的是 **ELMo** 系——它是那年 2 月的社区宠儿，如果“BiLSTM + ELMo”在多数任务上逼近我，“零架构改动”的卖点就不再成立。好在擂台自己把对手递过来了：GLUE 官方基线就是那套 ELMo 系模型。

结果：12 个任务里有 9 个刷新了当时的最好成绩（可查证：§1、§4.2 末段）。最漂亮的两个是长程推理：Story Cloze 涨 8.9%，RACE 涨 5.7%；文本蕴含上 MultiNLI 涨 1.5%（可查证：Abstract）。GLUE 的总均分是 72.8，前最好是 68.9（可查证：§4.2）。

然后是那三处失利。这在论文里都能核到，而且一年后我才把它们数清楚：RTE 只有 56.0，输给一个多任务 BiLSTM 的 61.7（可查证：§4.2；Table 2 里那一行的名字是 `Multi-task BiLSTM + Attn [64]`，注意它不含 ELMo）；MRPC 82.3，输给 TF-KLD 的 86.0；SST-2 91.3，输给 Sparse byte mLSTM 的 93.2——最后一个，论文里我只写了“与 SOTA 有竞争力”（可查证：§4.2 与 Table 4）。

RTE 是分量最重的那一处，因为它是当时肉眼可见的：2490 个样本，多任务 BiLSTM 拿到 61.7，明显高于 56.0。我在论文里放了一句免责声明，原话是“考虑到我们在更大的 NLI 数据集上的强表现，我们的模型很可能也能从多任务训练中受益，但我们目前没有探索这一点”（可查证：§4.2 原文）。这句话的功能是双重的：承认输，同时把“输”翻译成“我还没用那一招”。RTE 我没有塞进附录，我把它放在正文里配上这句话——把小规模失利摆在台面上，本身就是对“你挑数据集”这一质疑的回应。

真正救回信心的是两组机理实验。一组是层迁移扫描：把预训练的层一层层接到下游，性能随之提升，满迁移在 MultiNLI 上最多贡献 9%（可查证：§5 与 Fig 2 左）——说明每一层预训练参数都在干活。另一组是零样本探针：不做任何微调，直接用启发式规则问模型——把句子的平均 token 对数概率拿来给语法接受度打分并设阈值、给情感句尾追加一个 very 并把输出分布限制在 positive/negative 两个词里、让模型给 RACE 的每个选项算平均 token 对数概率、把代词替换成两个候选再比后续序列的概率（可查证：§5 四个启发式的完整描述）——这些探针的性能随预训练稳定上升，而 LSTM 对照组的方差明显更大（可查证：§5 原文 `LSTM exhibits higher variance in its zero-shot performance`）。

这两组图不产生任何 SOTA 数字，但它们让我相信一件事：小数据集上的失败是“怎么微调”的问题，不是“预训练范式”的问题。范式成立，工程拖了后腿，项目就不用死。

接下来，是我自己的表格纠正我自己。

先说“消融”这个词是什么意思：把自己往模型身上加的零件一个个拆下来，看分数掉多少——这是判断“这个零件到底有没有用”的唯一硬证据。我们做了三种拆法，都在 GLUE 的 8 个任务上（GLUE 是一个公开擂台，把若干标准任务打包在一起排名；可查证：Table 5、Table 4 注）：

- 拆掉预训练：均分从 74.7 掉到 59.9（掉 14.8%）。
- 把 Transformer（第二幕那套“给每个词都贴便利贴”的注意力网络）换成更老的结构 LSTM（就是“用一根绳子把句子从头串到尾”的那种）：掉到 69.1，掉了 5.6 分，而且它只在 MRPC 一个任务上赢过我。
- 拆掉辅助目标（那道“一边做任务、一边继续猜下一个词”的附加练习题）：均分 75.0——比我留着它还高 0.3。

这些分数是各任务自己的评分，口径并不统一（有的是准确率，有的是相关系数），所以只能看同一个任务自己的涨跌，不能横向比大小。摊开逐任务看，拆掉辅助目标之后：CoLA 45.4→47.9、SST-2 91.3→92.0、MRPC 82.3→84.9、STS-B 82.0→83.2，全都涨了；反过来 MNLI 81.8→81.1、QNLI 88.1→86.9、QQP 70.3→69.8、RTE 56.0→54.4，全都跌了。

论文里我把它概括成两句：辅助目标对 NLI 系任务和 QQP 有帮助；“更大的数据集受益于这个辅助目标，更小的数据集则不受益”（可查证：§5 原文）。这两句话在 RTE 上互相冲突——RTE 是全场最小的数据集（2490 条），却因为辅助目标涨了 1.6 分。这是个我当年没看出来的漏洞，也是一年后复算表格时才抓到的：我那两句概括，被我自己表里最小的那一格推翻了。

为什么会这样？一句直觉类比：只看平均分，你会以为两个方案的差别只有 0.3 分；把每个任务的分数摊开，你会发现是两组任务在往相反的方向拉，互相抵消掉了。机制上，均值是净效应，不等于每个子集都受益——这是所有聚合指标的共同局限。它哪里不像“辅助目标没用的证据”：它同样不是“辅助目标有害”的证据，它说明的是我当时那个一刀切的  $\lambda=0.5$  是粗糙的，以及我把“它帮我兜住了小数据”这个功劳记错了人。真正稳住小数据的是 warmup 加衰减和 3 个 epoch 早停。

而这套叙事里最诚实的部分，是论文自己写的：对于本来就是分片的任务，处理成整片序列是没必要的，因为分片本身已经包含结构信息（可查证：§3.3 原文，论文在讲输入变换时明确承认了这一点）。预训练已经把语言里很多东西学进去了，辅助目标只是补一点（可查证：§2 第三小节末句）。这句话是我给自己打的预防针——可惜一年后我才真的读到它。

## 第五幕·反思：审稿、勘误，和一年后才敢承认的事

本章论点：这篇论文里最值钱的部分，是它没写出来的那 80%；而其中有一部分，连我自己都记错了。

论文是作为预印本挂出去的，首页就印着“Preprint. Work in progress.”（可查证：论文首页脚注）——它没走会议评审，直接公开。这不代表没人审读。挂出去之前，我们在组内做过一次假想审稿：假定审稿人手里只有论文、没有任何口头补充，然后请最严格的那位同事来审。让这段经历值钱的地方在于，那三条意见全都指向真实弱点，没有一条是误读。

那三条意见我反复读了两周。

第一条：RTE 那 56.0 和“9/12”的卖点不匹配，你说“很可能从多任务训练受益但没探索”，那正好说明在极小数据上你没有优势，这是选择性报告。我的应对是让步一半：措辞整改，并把 RTE 的多任务变体作为下一步实验承诺；但“选择性报告”这个定性我不认——12 个任务是成文前就定下的，GLUE 系任务来自官方清单，不是成文后筛的。

第二条最疼：你自己那张消融表里，去掉辅助目标的均分 75.0 比留着的 74.7 还高，四个任务全面更高，那“它有帮助”从何说起。这条我据理力争了一半、也接受了一半：0.3 的差距是噪声量级，不辩；但“基本是噪声甚至有害”是过度解读，因为收益集中在更大的数据集上，损害集中在更小的数据集上，这个非单调结构本身是有信息量的发现。我承诺在正文里补一句“ $\lambda$  对各任务并非最优”，并把  $\lambda$  的粗扫过程写进附录。那位扮演审稿人的同事还要求逐任务做显著性检验，我拒绝了——8 个任务乘以多种子的重跑，成本和论文的剩余周期不匹配。这句是实话，不是托词。（顺带说一句：承诺归承诺，最终挂出去的版本里， $\lambda$  只有一个 0.5，过程仍然没写进去——可查证：§4.1。）

第三条最难答：没有代码、没有权重，而当时同期的 ELMo 和 ULMFiT 都已经开源；BooksCorpus 本身有体裁偏见（小说为主）；而且你没有和 ELMo 在同一份数据、同等算力下做过对照。我的应对是把“可复现”从权重级降到配方

级——把数据清洗、分词、词表构建的参数补全；至于同数据对照，我原则上接受，因为那个实验恰好能检验我“长程连续文本是关键”的主张，它对我有利。

一年后，我重读自己的论文和数据，抓出了三处我自己的记忆错误。

第一处，我在一次内部复述里说“论文全文没提 GLUE”——这是错的。论文第一节就点名引用了这个 benchmark，第四节又写了“我们利用了它”，Table 4 的注里还专门说明那张表的所有评测都在 GLUE 上做。我记错的来源很典型：在想法诞生的时候（那年 3 月）GLUE 还不存在，我把“当时不存在”错推成了“全文没提”。

第二处，就是第四幕里已经认过的那笔账：辅助目标在小数据集上是做贡献，而我记成了“它在小数据上帮了我大忙”。

第三处，我把失利名单记成了“RTE、STS-B、MRPC 和 CoLA”。事实是 STS-B 和 CoLA 恰恰是胜绩——STS-B 涨了 1 个点，CoLA 从 35.0 跳到 45.4，是那篇论文里最大的一次跳升。我真正的三处失利是 RTE、MRPC、SST-2。用自己论文里的胜绩去给自己论文的败绩作证，这种错误只有一种可能：隔了一年，我记住的是叙事，不是数据。

这些坑能不能在一开始就避开？大部分不能。那年没有任何公开经验告诉我们“1.17 亿参数在 2490 条样本上做微调的方差有多大”——同期的 ULMFiT 最大模型比我小一个数量级。这是典型的“只能在执行中暴露的风险”。能提前做的只有一件事：从设计之初就把小数据集标记为高风险区，优先安排消融预算，而不是等问题出现了再回头补救。

所以我这一年后真正带走的结论只有三条，而且都不在论文的结论段里。

一，数据形态决定方法上限。1B Word 被句子级打乱，长程结构就物理消失了——你押注长程依赖，就绝不能用它。选语料时先问一句“它的形态和你假设的结构匹配吗”，比事后调参有用得多。这条判据可以迁移到任何模态。

二，高风险区可以事前标记。12 个任务里哪几个会输，事前唯一的信号就是“样本量与参数量的量级比”。这不是玄学，是可以在实验开始前写进风险清单的东西。

三，不要相信论文的趋势句，要重算它的表。所有被概括出来的规律——“大数据受益、小数据不受益”——都是净效应，都可能被某一个小小的子集反着走。我自己写下的那句话，就被我自己表里最小的那一格推翻了。这一条我付了一年的学费。

---

## 章末注（重构点留痕，每条一行：哪个判断、依据是什么）

第一幕 1. “情感神经元是我所有判断的源头”——据作者公开研究轨迹衔接推断【合理重构：Radford, Jozefowicz, Sutskever 2017 与本文同源；该文献不在论文参考文献表内】。2. “两难困境的两条表述”——论文 §1 原文，非重构【可查证】。3. 时间点设为 2018 年 3 月——据引文 [21][34][44] 的发表时间定【合理重构】；注意 GLUE 于 2018 年 4 月发布，成文时已被论文引用。3a. 那句自问（“如果模型已经学会了怎么读句子，为什么每个任务还要从零学一遍怎么用它”）——为叙事化表达，用来承载 S2/S3 档案中的站队逻辑【合理重构】。

第二幕 4. naive 想法取“LSTM 特征路线”——这是当时该背景下最省事的默认选项【合理重构】。5. “情感神经元那版模型训练很慢”——依据该文献的训练设置，属论文外材料【合理重构·论文外】。6. “拼图合上”的触发场景——据 §1 对 [52] 与 §3.1 对 [34]/[62] 的引用反推【合理重构】。7. “预训练当初始化 vs 当特征”的对比——参数量结论可查证（§3.2 末句）；类比的恰当性由我负责【可查证 + 类比】。7a. “注意力的平方级代价”与“长程收益压过算力成本”——前者属通用技术常识（论文未写、故无出处），后者属我对下注理由的重构【合理重构·常识】。

第三幕 8. v0 的形态（裸拼接、无辅助目标、无分隔符）——由终版引入这三样反推其曾经缺席【合理重构】。9. v1 的动机——论文原句是 *improving generalization ... and accelerating convergence*【可查证】；“我心里记成了治小数据过拟合”属自我陈述，且已被 Table 5 反证。10. 相似度任务的“假顺序偏置”、QA 的“K 选 1”困难——由 §3.3 对这两处做的特殊处理反推【合理重构】。11. “3 个 epoch 与  $1r\ 6.25e-5$  是调出来的”——§4.1 只给了值和收敛式描述【合理重构】。12. 微调崩溃事件（现象、排查路径、根因）——依据 Table 5 中辅助目标收益的非单调结构（大数据受益、小数据受损）推断现场踩过坑【合理重构】。13. “当时以为是辅助目标在兜底”——修正后的表述；原判断已被 Table 5 反证【合理重构，已修正】。13a. 清洗规则的“收紧—放松”返工、以及“清洗的目标不是干净，而是干净到词表够用又脏到分布还在”——现场细节与判断属重构；论文只给出 `ftfy + spaCy + 40k BPE` 的配方【合理重构】。13b. “数据规模只有这么多”——据 §4.1 对两个候选语料“大小相当”的表述，结合当年可合法获取的资源推断【合理重构】。

第四幕 14. baseline 选择与“最怕 ELMo 系”的心理——据 Table 4 基线构成（GLUE 官方 ELMo 系）反推【合理重构】。15. “RTE 不塞附录而放正文”的排版决策——§4.2 呈现方式的客观事实 + 排版动机推断【可查证 + 合理重构】。16. 三处失利的身份确认（RTE/MRPC/SST-2）——由“9 out of 12”与 §4.2、Table 4 反推：§4.2 自陈相似度

只在三个中两个上取胜、SST-2 只称 competitive【可查证·反推】。17. "论文的概括句在 RTE 上互相冲突"——Table 5 的 RTE 54.4→56.0 与 §5 两句原话直接冲突【可查证·独立发现】。

第五幕 18. 审稿意见三条与 rebuttal 的让步/力争配比——审稿意见由隔离会话独立生成，rebuttal 策略按当年预印本文化的真实博弈模拟【合理重构】。19. 三处自我记忆错误（GLUE、辅助目标、失利名单）——前两处为 S8 核查抓出的 P0 级事实错误，第三处为论据错位；均已回改并保留修订注【可查证·核查结论】。20. "这些坑能不能在 S1 避开"的答案——判断属反思【合理重构】。

附录 · 勘误与对照（原 S8 核查报告压缩版）

本节是成稿的可核验性骨架：把第三方核查的三张表压成三行结论，完整报告见 S8.md。

| 表            | 结果                                                                                                                                                                                                |
|--------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 【对上了】        | 27 组对照全部通过：所有性能数字、引文原句、图表编号经逐条复核无误。数字层零编造。                                                                                                                                                        |
| 【编圆了但论文没这回事】 | 10 条：P0 两条（S1"全文未提 GLUE"——论文 §1/§4.2/Table 4 注/脚注 1 均出现；S4 辅助目标"在小数据上正则有效"——Table 5 逐任务差值相反）；P1 三条（辅助目标因果链方向错误、失利名单错误、"2013 年风格 BiLSTM"修辞失真）；P2 五条（标签错配与表述不严）。错误率约为带标签断言的 17%，其中与论文事实直接矛盾的占 3.3%。 |
| 【论文有而叙事漏了】   | 10 条覆盖度缺口，其中 GLUE 总均分 72.8 vs 68.9、BooksCorpus 困惑度 18.4、层迁移 9% 这三个正面硬数字在首轮叙事中零覆盖，已在 S6 补记并写进本文第四幕。                                                                                                |

两处最重要的独立发现：①上文第四幕那条"论文的两句概括被自己表里最小的那一格推翻"；②隔离审稿人与作者 rebuttal 各自只引用了辅助目标消融表里对己有利的一半（审稿人只列受损的四个任务，作者只列受益的三个），双方都绕开了 RTE。

《档案 · S9》

【阶段】S9 成稿（面向外行的第一人称长文 + 迷你复检）

【已知事实】（成稿中可核查的硬数据，全部锚在论文行号）

1. 9/12 刷新 SOTA；Story Cloze +8.9、RACE +5.7、MultiNLI +1.5、GLUE 均分 72.8 vs 68.9 — Abstract、§1、§4.2

2. 三处失利：RTE 56.0 vs 61.7（Multi-task BiLSTM + Attn [64]，不含 ELMo）、MRPC 82.3 vs 86.0、SST-2 91.3 vs 93.2 — §4.2、Table 2/4

3. Table 5 逐任务差值：w/o aux 在 CoLA/SST-2/MRPC/STS-B 上更高、在 MNLI/QNLI/QQP/RTE 上更低；w/o pretrain 59.9；LSTM 69.1（-5.6，只在 MRPC 赢）

4. §5：层迁移满迁移在 MultiNLI 最多 +9%；zero-shot 四启发式；LSTM 零样本方差更大

5. §4.1：BooksCorpus 7000+ 本、长连续文本；1B Word 句子级打乱；困惑度 18.4；超参与  $\lambda=0.5$ （无理由）

6. §3.2：L3 = L2 +  $\lambda L1$ ；动机原句 improving generalization / accelerating convergence；微调唯一新增参数  $w_y$  + 分隔符 embedding

7. §3.3：三类输入变换（蕴含  $\$$ ；相似度双向逐元素相加；QA  $[z;q;\$;a_k] + \text{softmax}$ ）；论文自陈分片任务不必整片处理

8. 论文为 preprint；全文无 "GPT" 字样

【合理重构】（成稿中的重构点已在各幕章末注逐条留痕，共 20 条）

主要类别：naive 想法的形态与死因（4/20）、v0-v1-v2 的中间版本与死因（3 条）、微调崩溃的现场细节（1 条）、审稿与 rebuttal 的博弈配比（1 条）、反思性判断（2 条）

【改写决策】

1. 视角统一：S7 审稿段改写为"收到意见那两周"的作者视角；S8 三张表不进正文，压成附录《勘误与对照》

2. 标签转写：行内【可查证】/【合理重构】撤掉，改用"我记得/我当时猜/我后来才发现"承载；20 条重构点全部在章末注留痕（可核验性未丢）

3. 结构重排：五幕（问题 → 直觉 → 试错 → 定型与反例 → 反思），每幕开头一句本章论点

4. 理论三层讲法：6 处核心概念按"类比 → 机制 → 公式/伪代码 → 它哪里不像"给（语言模型、单向注意力、初始化 vs 特征迁移、输入拍平、辅助目标、聚合指标）

5. 字数核算（实测，汉字口径，脚本：scripts/s9\_selfcheck.py）：成稿正文 7,443 汉字；基线取 S1-S8 各阶段叙事正文（不含《档案》块）合计 12,067 汉字 → 61.7%，落在模板第 5 条要求的 60-70% 区间，同时落在

README 的"6000-9000 字"产品规格内。正文 + 章末注(927) + 附录(341)合计 8,711 汉字。

口径警示(本轮踩到): ①基线必须含 S8—S8 本身就是一份长审计报告, 只把 S1-S7 当基线会得到 99.1%, 结论完全相反; ②必须按汉字数算——同一稿件按字符数(含标点西文)算只有 37.7%。两个口径差 24 个百分点, 模板应写明按汉字数、且基线为 S1-S8。

6. 负结果占比: 第一至四幕的失败线(naive 之死、v0/v1 之死、1B Word 被毙、清洗规则返工、微调崩溃、RTE/MRPC/SST-2 三处失利、辅助目标误判)按幕内篇幅人工估算  $\approx 44\%$ , 达标  $\geq 40\%$ 。

#### 【负结果】

1. 改写过程本身的新增风险: 五幕叙事把"我当时真心以为辅助目标在兜底"写成了一次自我纠正的伏笔——这是对原始材料(S4 原稿的错误归因)的叙事化利用, 属二次加工; 迷你复检已逐处确认, 全文没有任何一处把它写成"当时就知道是错的", 该错误始终以后知视角("一年后重算表才发现")呈现。

2. 外行闸(模板第 6 条)跑了三轮, 首轮全军覆没: 抽检 3 段  $\rightarrow$  第一轮(扮演外行的隔离子代理, 无任何机器学习背景)判定: 段一(第一幕两难困境)"没讲清"、段二(第三幕输入变换)"没讲清"、段三(第四幕消融表)"半讲清", 三段复述全部失准, 卡点都是术语裸用(迁移/优化目标/拍平/逐任务表示相加/消融/GLUE/LSTM)。

$\rightarrow$  三段全部重写: 段一补三个词的头次释义(迁移、目标函数、预训练与微调)并把三条迁移路径落到白话; 段二改成"答题卡"类比先行 + 三类版式 + 机制句 + 三行式子, 并给 softmax、线性层加白话注; 段三补"消融"定义、GLUE 是什么、分数口径不可横向比。

$\rightarrow$  第二轮复检: 同一三段打分 6 / 5 / 8 (满分 10), 残留术语洞四处("改模型结构"、"架构"、"线性层"、第四幕未回指 Transformer)  $\rightarrow$  以三处就地补注覆盖。这三处补注未做第三轮复检, 是本稿的残余风险, 已在【未决问题】挂账。

3. 扩写引入的三处新断言: 清洗规则的收紧-放松返工、数据规模"只有这么多"、注意力的平方级代价——前两处属【合理重构】、第三处属通用技术常识(论文未载), 均已在章末注补留痕(7a / 13a / 13b)。

#### 【未决问题】

1. 字数口径已在上一项记明: 正文 7,443 汉字 / 基线(S1-S8 叙事正文, 不含《档案》块)12,067 汉字 = 61.7%; 正文字符数 11,934 仅作对照。建议把这条口径写进模板第 5 条, 否则复跑极易误判不合格。

2. 外行闸第二轮后补的三处术语注未再复检(见【负结果】2), 下次复用本文时优先抽查那三处。

3. 本文仍未做的: 真实最小复现。

【一致性自检】与《档案·S8》无冲突: S8 的 10 条幻觉与 10 条覆盖度缺口在成稿中全部体现(P0 未复活、失灵名单已改正、覆盖度缺口已补写); 对 S8 独立发现(RTE 反例)已写入正文第四幕。

【后见之明自检】成稿视角是"项目结束一年后", 允许知道全部结果与核查结论; 但正文中未使用论文之后的历史(GPT-2/3、ELMo 后续命运、社区对预训练范式的长期评价)作为论据——合规。