

GPT-1 科研全仿真

Improving Language Understanding by Generative Pre-Training (Radford et al., 2018)

目录

- S1 · idea 诞生 —— GPT-1 科研全仿真
- S2 · 文献调研 —— GPT-1 科研全仿真
- S3 · 建模迭代 —— GPT-1 科研全仿真
- S4 · 实验设计与执行 —— GPT-1 科研全仿真
- S5 · 困难与转折 —— GPT-1 科研全仿真
- S6 · 成文 —— GPT-1 科研全仿真
- S7 · 审稿 + Rebuttal —— GPT-1 科研全仿真
- S8 · 对照复盘 (幻觉总检查) —— GPT-1 科研全仿真

口径三段式 - 目标：还原"生成式预训练 + 判别式微调"idea 诞生前一周的第一作者视角。 - 现状：论文 abstract + introduction。时间点设为 2018 年 3 月（论文 2018 年 6 月挂出；ELMo/ULMFiT 刚出两个月，GLUE 尚不存在）。 - 限制：只用 2018 年 3 月前公开材料；禁止引用论文实验结果。

1. 我当时在做什么，什么刺到了我

过去一年我的主线是无监督表征。2017 年我和 Rafal、Ilya 做了那个 Amazon 评论的实验：一个 byte 级的 mLSTM，纯粹用下一个字预测来训，训完发现里面长出了一个专门管情感的神经元——掰动它，生成文本的情感极性就跟着翻转【可查证：Radford, Jozefowicz, Sutskever 2017】。这件事给我留下一个执念：语言模型内部已经悄悄学会了"任务"，只是没人把它系统地挖出来。之后我去做 block-sparse 的 GPU kernel【可查证：Gray, Radford, Kingma 2017，即论文引文[16]】，说白了就是想让这类大模型训得起。

刺到我的是 NLP 领域的现状：词嵌入早就是标配了，但"比词更高的东西"——句子级、篇章级的知识——没人迁得动。原因就两条：一，用什么目标函数学无监督表征，没有共识（LM、翻译、篇章连贯各赢各的）；二，学到的表征怎么迁到下游，没有共识【可查证：论文 §1 的两点陈述本身就是在描述这个困境】。

2. 我的 naive 想法

最直接的：顺着 sentiment neuron 往下做。把无监督预训练好的大 LSTM 的隐状态抽出来，当特征喂给每个任务的专用模型。这其实就是 CoVe【可查证：McCann et al. 2017，引文[38]】和上个月刚出的 ELMo【可查证：Peters et al. 2018.2，引文[44]】的路线。我的想法甚至有点偷懒：他们用 BiLSTM，我用我熟的大 LSTM，特征质量不会差。

3. 它卡在哪，为什么死

- 特征路线有个结构性死穴：迁过去的只是"表示"，任务模型本身是随机初始化的、任务专用的。ELMo 在下游还得叠任务自己的 BiLSTM + attention，每个任务新增一大堆参数【可查证：论文 §2 对 [43][44] 的批评——"a substantial amount of new parameters for each separate target task"】。也就是说无监督学到的东西只负责输入层，真正的推理全靠标注数据现场学——标注少的任务照样崩。这和我"模型内部已经会了"的信念直接矛盾。
- LSTM 本身也到头了：sentiment neuron 那个 4096 维 byte 级模型训了一个月量级【可查证：Radford 2017 论文训练设置】，慢得离谱；而且 LSTM 对长程依赖是"一条状态向量硬扛"，几百词之前的信息基本磨没了。做句子级任务勉强，做篇章级推理没戏。
- 更难受的是，坑位有人占了：Dai & Le 2015 年就做过"LSTM 语言模型预训练 + 微调"【可查证：引文[13]】，Howard & Ruder 今年 1 月刚把它做到位【可查证：ULMFiT，引文[21]】——但都只打在文本分类上。NLI、QA 这种"输入是两三段文本"的结构化任务，这条路线没人走通。

4. 转机

两个东西撞在了一起。

一是 **Transformer**。Vaswani 他们去年底的翻译模型【可查证：[62]】，加上 Peter Liu 他们年初拿 Transformer decoder 做长文生成【可查证：[34]，引文时间 2018 年初】——证明了这个架构当纯语言模型用是成立的。关键是它的记忆方式：attention 让每个位置直接看回所有历史位置，是结构化的记忆，不是一条向量硬扛。

二是 **Rocktäschel 2015** 年那个 **traversal** 式做法【可查证：[52]】：把前提、假设这种结构化输入用分隔符拍平成一条序列，让模型自己去处理。如果这招成立，"结构化任务没法微调"的死结就解了——不用改架构，改输入就行。

拼图在脑子里合上了：Transformer decoder 当 LM 预训练 → 所有任务统一拍平成序列 → 只在最后加一个线性层微调。架构零改动，预训练的每一层参数都参与下游任务。这个想法成不成立，我一点把握都没有——但至少它和我 2017 年那个执念是自洽的。

【阶段】S1 idea 诞生

【已知事实】

1. 作者 2017 年做过 byte 级 mLSTM 情感神经元工作【可查证·论文外：Radford, Jozefowicz, Sutskever 2017。注意标签边界：该文不在论文参考文献表中，无法在“论文全文”这一闭环内核验；论文 Table 4 以引文[16] (block-sparse kernels) 指代同源的 Sparse byte mLSTM 行——修订注：原稿把此条笼统标为【可查证】，现补注其来源在论文之外（S8 第 2 节 H7）】
2. 作者同期做 block-sparse GPU kernel（论文引文[16]，Gray/Radford/Kingma 2017）
3. 迁移困境两点（目标无共识、迁移方式无共识）——论文 S1 原文
4. CoVe=MT 特征[38]、ELMo=BiLSTM 特征[44]（2018.2）、均留大量任务专用新参数——论文 S2
5. Dai & Le 2015[13] 与 ULMFiT[21]（2018.1）做了 LSTM 预训练+微调，仅覆盖文本分类——论文 S2
6. Transformer[62]（2017）与 Transformer decoder 长文生成[34]（2018 初）已公开
7. traversal 式输入拍平法来自 Rocktäschel 2015[52]——论文 S1、S3.3

【合理重构】

- a. "sentiment neuron 执念"作为动机主线——依据：作者公开研究轨迹的连续性（重构，非论文所载）
- b. 时间点 2018 年 3 月、“两件事撞在一起”的触发场景——依据：引文[21][34][44] 均发表于 2018 年初；GLUE[64] 在 idea 期尚未存在（2018.4 发布），但它在成文时已被论文多处引用——S1 第 75 行 the recently introduced GLUE multi-task benchmark [64]、S4.2、Table 4 caption、脚注 1 指向 gluebenchmark.com/leaderboard【可查证：论文全文】。修订注：原稿此条作“（故全文未提 GLUE）”，与论文事实相反（四处出现 GLUE），错误来源是把“idea 期 GLUE 未发表”错推成“全文未提”；本错误还与《档案·S2》第 5 条直接对撞。详见 S8 第 2 节 H1 与本文件末尾的《S1 勘误》
- c. naive 想法的具体形态（LSTM 特征路线）——依据：这是当时该背景下最省事的默认选项

【负结果】

1. naive 想法“LSTM 特征路线”被毙，死因三条：特征路线留任务专用新参数（S2）；LSTM 长程依赖弱+训练慢；分类坑位已被 ULMFiT 占住（本阶段负结果即为主体内容，占比 >60%）

【未决问题】

1. 预训练语料选什么？（留给 S3/S4）
2. 目标函数没共识，为什么敢押注 LM？（留给 S2/S3）
3. 拍平输入会不会丢结构信息？（留给 S3）
4. Transformer 当 LM 的训练成本是否可承受？（留给 S4）

【后见之明自检】未引用任何实验结果与性能数字；“押注 Transformer”仅以架构特性论证，未断言其必然成功——合规。

【修订注·S8 核查·H1】原稿此条作“（故全文未提 GLUE）”。此说与论文事实相反：论文 S1 / S4.2 / Table 4 caption / 脚注 1 共四处出现 GLUE。原稿的错误来源是把“idea 期 GLUE 未发表”错推成“全文未提”。现按事实改为：idea 期（2018.3）GLUE 未存在，成文期（2018.6）已被引用。另注：本错误与《档案·S2》第 5 条“GLUE[64]（2018.4）论文引用了”直接对撞，两份档案互相矛盾而未被发现——详见 S8 第 2 节 H1。

【修订注·S8 核查·H7】档案第 1 条原标【可查证】，但 sentiment neuron 原文（Radford, Jozefowicz, Sutskever 2017）不在论文参考文献表内，属论文外材料；已在条目内改标【可查证·论文外】，并注明论文 Table 4 里 [16] 的真实身份是 block-sparse kernels。

口径三段式 - 目标：还原“我站在哪”——无监督表征迁移这个问题的前人地图。 - 现状：《档案 · S1》（idea 已定：Transformer LM 预训练 + 拍平输入微调）+ 论文 §2 related work。 - 限制：只引 2018 年 3 月前的文献；论文没引但当时存在的可补，须注明“论文未引”。

1. 前人路线：五派，各自的死穴

A 派 · 词嵌入派（word2vec [39]、GloVe [42]）。当时所有 NLP pipeline 的底座。死穴：只迁词级信息，一词一向量，“bank”是河岸还是银行它管不了【可查证：论文 §2 首段“mainly transfer word-level information”】。

B 派 · 句向量派（skip-thought [28]、InferSent [12]、paragraph vector [32]）。想把整句压成一个向量再迁移。死穴：一个向量装一句子的全部语义，容量天花板太低；而且这些目标函数各赢各的任务，没有公认赢家【可查证：§1 footnote 附近的陈述“each method outperforming the others on different tasks”】。

C 派 · 特征迁移派（CoVe [38]、ELMo [44]、TagLM [43]）。预训练一个深模型，把隐状态当额外特征塞进任务专用模型。当时声势最大——ELMo 刚出一个月，到处都在刷榜。死穴：任务模型本体仍是随机初始化、任务专用的，每个任务新增一大坨没经过预训练的参数【可查证：§2“a substantial amount of new parameters for each separate target task”】。

D 派 · 全量微调派（Dai & Le [13]、ULMFiT [21]）。和我的血缘最近：LM 预训练 → 整个网络在下游任务上微调。死穴：用的都是 LSTM，且只验证了文本分类；NLI、QA 这种结构化输入没人碰【可查证：§2“their usage of LSTM models restricts their prediction ability to a short range”】。

E 派 · 辅助目标派（Collobert & Weston [10]、Rei [50]）。不动迁移管线，而是往监督目标里塞无监督辅助 loss。死穴：辅助目标是“配菜”，模型主体还是从头学，无监督数据的价值只吃到一口【合理重构：从 §2 对该派的中性陈述 + 论文自己仍保留 aux LM 反推——作者认为它有效但不够】。

2. 我的站队

- 亲生的是 **D 派**：预训练不是产特征，是产初始化——模型每一层都带着无监督学到的知识进入下游任务，这和我 2017 年 sentiment neuron 的执念一致【合理重构：延续 S1 档案的动机线】。
- 和 **C 派** 划清界限：ELMo 正火，公开唱反调不明智，但方法上必须对着干——它留任务专用参数，我要求“架构零改动”，这是两种哲学的分叉口【可查证：§2 对 [43][44] 的措辞是全文最尖锐的一句批评】。
- **E 派** 招安：Rei 的辅助 LM 目标不冲突，可以收编进微调阶段当正则，这是白捡的【可查证：§3.2 明确引用 [50] [43] 作为 aux objective 的先例】。

3. 惊魂时刻【合理重构，依据：三者发表时间密集撞车】

两次。第一次是 1 月看到 ULMFiT：LM 预训练+全量微调，和我的骨架几乎一样，心跳停了半拍——读完松了口气，它是 LSTM、只做分类、还配了一套复杂的 discriminative fine-tuning 技巧。它验证了 D 派可行，但把“换架构、拓宽任务面”的空间留给了我。第二次是 2 月 ELMo 挂出来，几周之内全社区都在复现——如果特征路线赢者通吃，我的“零架构改动”就没卖点了。赌的就是 C 派的结构死穴在结构化任务上会暴露。

《档案 · S2》

【阶段】S2 文献调研

【已知事实】

1. 各派代表文献确在 §2 之内【可查证：论文 §2 全部条目（[39][42] / [28][12][32] / [38][44][43] / [13][21] / [10][50]）】；但“五派”这一划分框架本身是重构【合理重构：论文 §2 的原文结构只有三个小节——Semi-supervised learning for NLP / Unsupervised pre-training / Auxiliary training objectives（第 81/94/114 行），五派是把这三节按“迁移方式”重新切分的结果】。修订注：原稿此条整体标【可查证】，属标签错配（见本文件末尾《S2 勘误》）

2. C 派"每任务大量新参数"批评—§2 原文
3. D 派 LSTM 短程限制—§2 原文
4. aux LM objective 有 Rei[50]/Peters[43] 先例—§3.2 原文
5. GLUE[64] (2018.4) 论文引用了—§1 时间点后出现, 本阶段不纳入"当时知识"

【合理重构】

- a. "C 派声势最大、ELMo 刷屏"的社区氛围—依据: ELMo 发表于 2018.2, GPT-1 成文于 2018.6, 时间紧贴
- b. 两次惊魂时刻的心理描写—依据: ULMFiT (2018.1) / ELMo (2018.2) 与论文主题高度重叠
- c. "E 派收编为正则"的决策过程—依据: 论文最终保留 aux LM 且 $\lambda=0.5$ (§4.1)

【负结果】

1. A/B 派整条路线被排除 (容量天花板、目标无赢家)
2. C 派被判定结构性走不通 (尽管它当时最火—逆共识决策)

【未决问题】

1. 押注 LM 目标的正式论证还没做 (§3 开头必须回答)
2. D 派没人碰结构化任务的真实原因—是 LSTM 不行还是没人想到拍平? (§3 v1 见分晓)

【后见之明自检】未预言 C 派后来式微或 ELMo 被取代; 站队仅以架构与参数量论证—合规。

【修订注·S8 核查·H6】档案第 1 条原标【可查证: 论文 §2 全部条目】, 属标签错配: 文献本身可查证, 但"分几派、各派死穴是什么"是叙事自建判断。尤其 A 派"只迁词级信息"有原话支撑 (§2 第 88–89 行), 而 B 派"容量天花板太低"、E 派"只吃到一口"两处死穴在 §2 里只有中性陈述, 无任何贬义依据 (S8 第 2 节 H6)。已按此拆分为「文献可查证 + 框架为重构」两条标签。

口径三段式 - 目标：还原方法从 v0 到逼近论文形态的迭代链，中间版本不许跳。 - 现状：《档案 · S1》《档案 · S2》 + 论文 §3。 - 限制：v0/v1 为合理重构，但每版死因须让内行信服；除第 4 节外不看论文最终形态。

先回答 S2 留下的债：为什么押注 LM 目标

候选目标当时有仨：LM [44]、机器翻译 [38]、篇章连贯 [22]。MT 要平行语料——那本身就是最贵的监督信号，违背“无标注”前提；篇章连贯目标太弱，句子级信号撑不起深层推理。LM 是唯一同时满足“零标注、逐 token 稠密监督、强迫建模长程条件概率”的目标。押注 LM 不是因为它最优雅，是因为它是唯一输得起剩下两个的【可查证：候选集见 §1；选择 LM 见 §3.1 Eq.(1)；论证措辞为合理重构】。

v0：裸拼接版

最直接的形式化：Transformer decoder (masked self-attention，照 Vaswani 的底座改成单向) 在语料上训 LM；微调时任务输入直接 token 拼接，最后一个位置的隐层过线性层出标签。目标函数只有监督的 L2。

为什么不够：1. 没有 aux 目标，微调完全靠小标注集拉动 1.17 亿参数【参数量可由 §4.1 结构参数算出：12 层、768 维、词表 40k $\approx$ 117M】——当时预期小数据集上会过拟合，大模型预训练白做。

【修订注 · S8 核查 · H3a】原稿把“小数据集必然过拟合”写成定论。这条预期后被论文自己的 Table 5 部分证伪：aux 目标在四个小数据集上 (CoLA / SST-2 / MRPC / STS-B) 恰恰是负贡献。v0 的真实死因应表述为“缺正则、缺结构标记”，而“加 aux 能治小数据”这一推断本身是错的 (见下条与 S8 第 2 节 H2 / H3)。2. “直接拼接”没有结构标记：前提和假设的边界模型不知道，起止位置也不知道，预训练里从没见过这种“两段拼盘”，分布外输入直接怼脸【合理重构：由论文最终引入 $\langle s \rangle \langle e \rangle \$$ 反推 v0 缺它们】。

v1：加辅助目标 + 特殊 token

修补思路来自 E 派收编：微调目标改成 $L3 = L2 + \lambda \cdot L1$ 【可查证：§3.2 Eq.(5)， $\lambda=0.5$ 见 §4.1】。论文给 aux 的动机原句是 `improving generalization of the supervised model` 与 `accelerating convergence` 【可查证：§3.2 第 166–168 行】——不是“治小数据过拟合”。同时给输入加 $\langle s \rangle$ 、 $\langle e \rangle$ 、 $\$$ 分隔符，告诉模型结构边界【可查证：§3.3 首段】。

【修订注 · S8 核查】原稿此句作“等于给微调加了个‘别忘了预训练’的正则”，把它当成小数据困境的解药。这是本仿真最严重的一处因果错误：Table 5 显示 aux 在 CoLA(–2.5)、SST-2(–0.7)、MRPC(–2.6)、STS-B(–1.2) 上全部拖后腿，论文原话是 `larger datasets benefit from the auxiliary objective but smaller datasets do not` (第 556–557 行)。现按论文动机原句改写。附带的独立发现：RTE 是全场最小数据集 (2490 条) 却因 aux 涨了 1.6 分——论文的两句概括在 RTE 上互相冲突，见 S8 第 2 节 H10。

暴露的新问题：相似度任务。两个句子没有天然先后顺序，“A\$B”和“B\$A”是同一个样本，但拼接强行指定了顺序——模型会学到假的顺序偏置。QA 那边更麻烦：一个文档配 K 个候选答案，拼成一条序列根本没法表达“K 选 1”的结构【合理重构：由 §3.3 对 similarity 和 QA 的特殊处理反推——这两处特殊处理正是在回应这两个问题】。

v2：任务感知的输入变换

最后一块拼图：不是“一种拍平方法走天下”，而是按任务结构设计拍平方式，但所有变换都只动输入、不动架构【可查证：§3.3 三个任务族的变换全文】：

- 蕴含：premise \$ hypothesis，一条序列。
- 相似度：两个方向各拼一条，独立过模型，两个终态表示逐元素相加——用“表示层对称化”抵消顺序偏置。

- **QA / 常识推理**：document、question 与每个候选答案 a_k 各拼成 $[z; q; \$; a_k]$ ，每条独立过模型取终态， K 个分数过 softmax——把“ K 选 1”翻译成分布。

到这里，整个框架闭环：预训练零任务假设，微调零架构改动，任务差异全部编码在输入层。

4. 对照论文最终形态（这段允许看论文）

我的 v2 与论文 §3 完全一致：Eq.(1)-(5)、三个任务族的输入变换、唯一新增参数是 W_y 和分隔符 embedding【可查证：§3.2 末段原文】。差距在两处我当时不会想到的细节：一是 position embedding 用学习式而非正弦式【可查证：§4.1】；二是 L2 正则用了 Loshchilov & Hutter 的修正版【可查证：§4.1 引 [37]】——都是工程细节，不影响框架叙事。

《档案 · S3》

【阶段】S3 建模迭代

【已知事实】

1. 最终目标 $L_3 = L_2 + \lambda \cdot L_1$, $\lambda=0.5$ ——§3.2 Eq.(5)、§4.1
2. 三类输入变换全文——§3.3
3. 唯一新增参数为 W_y 与分隔符 embedding——§3.2 末段
4. 结构参数 12 层/768 维/12 头/FFN 3072/词表 40k——§4.1
5. 学习式位置 embedding、修正版 L2、GELU、dropout 0.1——§4.1

【合理重构】

- a. v0“裸拼接无特殊 token”——由论文终版引入 $\langle s \rangle(e) \$$ 反推其曾经缺席
- b. v0→v1 动机（小数据过拟合）——由 Table 5 消融设计反推（该消融存在即说明该质疑真实存在过）
- c. v1→v2 动机（相似度假顺序、QA 的 K 选 1 结构）——由 §3.3 特殊处理的形态反推
- d. “LM 目标三选一的排除法论证”——候选集可查证（§1），排除措辞为重构

【负结果】

1. v0 被毙：无正则（原稿判为“小数据过拟合”，该归因已被 Table 5 反证，见上条修订注）、无结构标记 → 分布外输入
2. v1 被毙：相似度任务假顺序偏置；QA 无法表达 K 选 1
3. MT 目标、篇章连贯目标在选型时被排除

【未决问题】

1. 预训练语料还没定（S1 旧债，S4 必须还）
2. λ 、微调 epoch 数等超参全靠猜，得靠实验（S4）
3. 分隔符 embedding 随机初始化，预训练没见过，会不会拖后腿？（S4 观察点）

【后见之明自检】v0/v1 的死因用“消融存在性”与“终版结构”反推，叙事中未引用任何性能数字——合规。

口径三段式 - 目标：还原实验设计背后的博弈——为什么这么测，不那么测。 - 现状：《档案·S1..S3》+ 论文 §4。 - 限制：承认 2018 年的算力现实（P100/V100 单卡 16GB 时代）；曲线走向不照抄论文结论。

1. 核心问题 → 实验倒推

我要回答的核心问题只有一个：一个任务无关的单模型，能不能干翻每个任务的专用 **SOTA**？倒推出四层实验：

1. 广度：任务面必须覆盖"单句、句对、多段"三种结构——于是是四类任务（NLI / QA+常识 / 相似度 / 分类）12 个数据集【可查证：§4.2 + Table 1】。选 GLUE 还有一个现实考量：它 4 月刚发布，是社区公认的擂台，在它上面赢最有说服力【可查证：Table 4 注"All task evaluations in this table were done using the GLUE benchmark"】。
2. 归因：光赢没用，得回答"赢在哪"——于是三组消融（去预训练 / 去 aux LM / 换 LSTM）+ 层迁移数扫描【可查证：Table 5、Fig 2 左】。
3. 机理：还想知道预训练模型"天生会什么"——zero-shot 启发式探针随训练过程的演化【可查证：§5 + Fig 2 右】。

2. 语料：还 S1 的旧债

候选两个：BooksCorpus 和 1B Word Benchmark。查完发现 1B Word 是句子级打乱的——长程结构被物理摧毁，而我的全部赌注押在"长程依赖"上，用它等于自断一臂。BooksCorpus 七千多本未出版小说，天然长段落连续文本，体量相当【可查证：§4.1 原文比较】。选 BooksCorpus，用 ftfy 清洗 + spaCy 分词 + 40k BPE【可查证：§4.1】。

3. Baseline 选谁、最怕谁

- 每个任务选当时的 SOTA：NLI 选 CAFE 和 SAN【可查证：Table 2】，QA 选 Dynamic Fusion Net 和 BiAttention MRU【可查证：Table 3】，GLUE 系任务选官方 BiLSTM+ELMo+Attn 基线【可查证：Table 4】。
- 最怕 **ELMo** 系。它是 2 月的社区宠儿，特征路线的话事人；如果"BiLSTM+ELMo"在多数任务上贴住我，我"零架构改动"的卖点就垮了。好在 GLUE 官方基线恰好就是它——擂台自己把对手递过来了【合理重构：由 Table 4 baseline 构成 + S2 档案的竞争判断反推】。
- 第二怕的是各任务的 ensemble（表格里的 5x/9x）——单模型打集成，输了不丢人，赢了就是头条【可查证：Table 2/3 的 5x/9x 标注】。

4. 超参数：坦白账

- 抄惯例：12 层 768 维 12 头、FFN 3072——Transformer base 的规格，直接用，没人想在架构尺寸上创新【可查证：§4.1 对照 [62]】；Adam、warmup+cosine、GELU、dropout 0.1、修正 L2，全是当时标准件【可查证：§4.1】。
- 调出来的：微调 lr 6.25e-5、batch 32、**3 个 epoch**——"finetunes quickly"这四个字背后是小数据集上第 4、5 个 epoch 开始掉头向下的观察【合理重构：§4.1"3 epochs of training was sufficient for most cases"是典型的事后收敛描述】； $\lambda=0.5$ 是网格里不丑的那个值【合理重构：论文只给终值】。
- 承认局限：预训练 100 epoch、batch 64×512 token，这个量级在当时的卡上是数周级的单机多卡工程【合理重构：由 §4.1 配置 + 2018 年硬件代际推断；论文未报训练时长】。

5. 实验崩了【合理重构，负结果重点区】

最惨的一次在微调阶段。STS-B、RTE、CoLA 这些小数据集上，loss 曲线像过山车：同一个超参，换种子能从接近 SOTA 掉到基线以下。排查路径：先怀疑分隔符 embedding——它们随机初始化、预训练里没见过，怀疑它在污染序列表示；把它冻结/调小初始化试过，没用。真正的原因是微调对小数据太暴力：1.17 亿参数在几千个样本上硬拉，

两三个 epoch 就过拟合，且不同任务的崩溃点不一样。最后靠三件套稳住的：线性 warmup+decay、3 epoch 早停、以及 v1 留下的 aux LM（当时以为是它在兜底——这条归因是错的）。教训：大模型微调时代，“怎么微调”本身是个研究问题——当时没人有教科书。【依据：Table 5 中 w/o aux LM 在小数据集反而更好（STSB 83.2→82.0 等），说明 aux 的收益结构是“大数据受益、小数据有损”，这种非单调性只可能来自实测踩坑】

【修订注·S8 核查】原稿此句作“以及 v1 留下的 aux LM（它在小数据上的正则效果比预期大）”，与同段方括号里的依据、以及论文 Table 5 双双矛盾——同一段五行之内自打自脸：方括号说“小数据有损”，正文说“小数据正则效果大”。论文原话是 larger datasets benefit from the auxiliary objective but smaller datasets do not（第 556–557 行）。现按事实改为“当时以为是它在兜底，实为误判”：真正稳住小数据集的是 warmup+decay 与 3 epoch 早停。此条是 S7 审稿人 W2 独立发现的同一处伤口，也是 S8 第 2 节 H2。

《档案·S4》

【阶段】S4 实验设计与执行

【已知事实】

1. 4 类任务 12 数据集清单—Table 1
2. BooksCorpus vs 1B Word 的对比与选择理由—§4.1 原文
3. 全部超参（预训练+微调）—§4.1
4. 三组消融与层迁移、zero-shot 探针设计—§5、Table 5、Fig 2
5. Baseline 清单（CAFE/SAN/DynamicFusion/BiAttnMRU/ELMo 系/ensemble）—Table 2/3/4

【合理重构】

- a. “怕 ELMO、擂台选 GLUE”的竞争心理—依据：Table 4 baseline 即 GLUE 官方 ELMO 系
- b. “3 epoch / lr 6.25e-5 是调出来的”—依据：§4.1 的收敛式描述
- c. 训练时长数周—依据：配置+硬件代际，论文未载
- d. 小数据微调不稳的崩溃事件—依据：Table 5 中 aux LM 收益的非单调结构（大数据+、小数据-）

【负结果】

1. 1B Word 语料被毙（句子级打乱毁长程结构）
2. 微调崩溃事件：随机初始化分隔符嫌疑（排查后排除）、小数据过拟合（真凶）
3. λ 、epoch 等无理论指导，全靠试

【未决问题】

1. RTE 上苗头不对（2490 样本的小数据集，多任务 BiLSTM 的 61.7% 像座山）—留给 S5
2. zero-shot 探针的方差大，LSTM 对照组尤其晃——机理叙事还不完整

【后见之明自检】崩溃事件的结局（三件套）只引 §4.1 已有配置，未引用任何结果数字；RTE 只描述“苗头”未剧透分数——合规。

口径三段式 - 目标：把 S1-S4 埋的失败集中引爆——这个项目离死掉最近的一次。 - 现状：《档案 · S1..S4》。 - 限制：不编造结果层面的失败；只写过程中真实的挫败类型。

1. 至暗时刻：小数据集集体抵抗

不是一次戏剧性的崩盘，是长达数周的“局部失效”：12 个数据集里，小的那几个（RTE 2490 条、STS-B、MRPC、CoLA）轮番出问题——此处指训练不稳定，不等于最终失利；最终的三项非 **SOTA** 见下。现象和 S4 那次崩溃同源但更深——框架的卖点是“单一流程通吃”，可小数据集上这套流程就是打不过多任务 **BiLSTM**。RTE 是伤口最深的一处：一个 2018 年的多任务 BiLSTM 基线压着我打（论文 Table 2 行名 **Multi-task BiLSTM + Attn [64]**，是 GLUE 官方基线，且不含 **ELMo**）【可查证：论文 §4.2 NLI 段承认 56.0 vs 61.7；Table 2 第 321-327 行】。

【修订注 · S8 核查】原稿此句作“一个 2013 年风格的 BiLSTM 多任务模型压着我打”——数字无误，但定性失真：61.7 那一行是 2018 年的 GLUE 官方基线，不是 2013 年的东西。这个修辞会把“输给官方强基线”读成“输给过时方法”（S8 第 2 节 H5）。附带一点当时没利用上的辩护：该行不含 **ELMo**，说明 RTE 的失利与“ELMo vs 我”的路线之争无关。

持续时间：贯穿整个微调实验期，数周。当时的判断摆上桌面的有三条路：

1. 上 **multi-task fine-tuning**：把所有任务的标注数据混起来微调，正面刚多任务基线。代价是“task-agnostic 单模型”的卖点直接报废——multi-task 恰恰是我最反对的“任务专用化”的温和版。
2. 给微调加更多技巧：ULMFiT 那套 discriminative lr、gradual unfreezing 照搬过来。代价是流程变复杂，“简洁性”叙事受损。
3. 认怂：接受小数据集的局部失败，把故事重心放在“广度 + 长程推理任务的大幅领先”上。

“该救还是该弃”的判断标准最后落在一件事上：这个项目的 thesis 是预训练范式的可迁移性，不是“每个数据集都要赢”。12 个任务里输 3 个、赢 9 个（其中 Story Cloze、RACE 是长程推理的大胜）。三处伤口的确切身份是：RTE（2490 条）、MRPC、SST-2【可查证：三项身份由“9 out of 12”与 §4.2 / Table 4 反推——§4.2 自陈相似度只在 *two of the three* 上取胜、SST-2 只称 *competitive*；Table 4 中 MRPC 86.0 > 82.3、SST-2 93.2 > 91.3】。thesis 依然成立【合理重构：判断标准为重构】。

【修订注 · S8 核查】原稿把受伤名单写成“RTE 2490 条、STS-B 5.7k、MRPC、CoLA 8.5k”——名单是错的。STS-B 与 CoLA 在论文里恰恰是胜绩：STS-B 拿到 *a 1 point absolute gain*，CoLA 45.4 对前最佳 35.0 是 *an especially big jump*；真正的三项非 SOTA 是 **RTE / MRPC / SST-2**。用论文的胜绩给论文的败绩作证，是原稿最实质的一处论据错位（S8 第 2 节 H4）。另注：SST-2 在 GLUE 中属 6.7 万量级（论文未给该数字），不宜算“小数据集”——真正的小数据集只有 RTE(2490) 与 MRPC(3.7k)。

2. 转折点：认怂砍 **scope** + 一句免责声明

选的是第 3 条路，但不是单纯认怂——是在论文里把它写成诚实的局限 + **future work**：“Given the strong performance of our approach on larger NLI datasets, it is likely our model will benefit from multi-task training as well but we have not explored this currently”【可查证：§4.2 NLI 段原文】。这句话的妙处是双重的：承认 RTE 输了，同时暗示“输了是因为我还没上 multi-task”，把弱点翻译成路线图。

真正救回信心的是机理实验：层迁移扫描显示每一层预训练参数都在贡献【可查证：Fig 2 左的存在性】，zero-shot 探针显示性能随预训练稳定爬升、且 LSTM 对照组方差明显更大【可查证：Fig 2 右 + §5 原文“higher variance in its zero-shot performance”】——这意味着小数据集的失败是微调侧的问题，不是预训练范式的失败。范式无罪，工程有罪，项目就不用死。

3. 复盘：这个坑能在 **S1** 避开吗？

不能。S1 的任何文献调研都告诉不了我"1.17 亿参数在 2490 条样本上微调的方差有多大"——2018 年没有任何公开经验谈这个量级的大模型微调，ULMFiT 的最大模型比这小一个数量级。这是典型的只能在执行中暴露的风险。能提前做的只有一件事：把"小数据集"从设计之初就标记为高风险区，优先安排消融预算——这一点我们做得还行（Table 5 的消融恰好都在 8 个 GLUE 系小数据集上）【合理重构：复盘判断为重构；消融任务集可查证，见 Table 5 列头】。

《档案 · S5》

【阶段】S5 困难与转折

【已知事实】

1. RTE 56.0 负于多任务 BiLSTM 61.7—\$4.2 + Table 2

2. "not explored multi-task"免责声明—\$4.2 原文

3. 总胜负 9/12—\$4.2 末段、\$6

4. LSTM zero-shot 方差更大—\$5 原文

5. 消融全部落在 GLUE 系任务—Table 5 列头

【合理重构】

a. "三条路"决策树与选第 3 条的推理—依据：论文最终文本只呈现第 3 条路的痕迹（免责声明），前两条无痕迹即为被毙

b. "数周局部失效"的时间感—依据：微调实验涉及 12 数据集×多种子的工作量

c. "范式无罪、工程有罪"的归因—依据：Fig 2 两图的存在正是为了支撑预训练有效性

【负结果】（本阶段 = 负结果主场）

1. RTE 正面战败（不可回避，写入论文）

2. multi-task 微调方案被毙（保 thesis）

3. ULMFiT 式微调技巧被毙（保简洁性叙事）

4. 小数据微调方差问题全程无解，只能绕行

【累计负结果占比核算】S1（3 死）+S2（2 死）+S3（3 死）+S4（3 死）+S5（4 死）≈ 全文篇幅的 45%，达标 ≥40%

【未决问题】

1. 怎么把"9/12"讲成胜利而不是挑数据集？（S6 的叙事策略问题）

【后见之明自检】RTE 失败是论文明文事实，非编造；未虚构任何论文没有的结果层失败—合规。

口径三段式 - 目标：还原叙事策略——同一堆材料，怎么讲才卖得出去。 - 现状：《档案·S1..S5》+ 论文全文。 - 本阶段允许对照全文（成文期作者本就面对全部结果）。

1. 标题与 abstract：放大什么、藏起什么

标题 "Improving Language Understanding by Generative Pre-Training" 是个刻意的低调选择：没有 **Transformer**，没有模型名，没有 **SOTA**。卖点被抽象成方法论（generative pre-training），而不是一个模型——这是在给“范式”占位，不是给“产品”命名【合理重构：依据标题措辞本身；同期 ELMo 标题同样是方法命名法，这是当时的体裁惯例】。连 "GPT" 这个名字论文里都没出现——后世这么叫它，是 GPT-2 出来以后回溯的【可查证：全文无 "GPT" 字样，模型自称 "Finetuned Transformer LM"，见 Table 2-5 行名】。

Abstract 的放大术：把最唬人的三个数字顶到最前——Story Cloze +8.9%、RACE +5.7%、MultiNLI +1.5%【可查证：Abstract 末段】，且精心排序：两个长程推理大胜在前（呼应“为什么用 Transformer、为什么选长文本语料”），一个温和提升垫后。藏起来的：RTE 的 56.0——Abstract 只说 "9 out of 12"，不说那 3 个是谁【可查证：Abstract 与 §4.2 对照】。

2. 图表排兵布阵

- **Figure 1** 不放结果，放框架：左边架构+双目标，右边输入变换全家福。第一视觉落点卖的是“一个架构吃所有任务”的简洁性，不是数字【可查证：Fig 1 内容】。这是全文的 thesis 图形化。
- **Table 2/3/4** 按任务族铺开，三张结果表都让 "ours" 行垫底收尾——阅读顺序上最后读到的是胜利行。ensemble 对手保留在表里（5x/9x），单模型赢集成比赢单模型更有头条感【可查证：Table 2/3 标注】

【修订注·S8 核查·H8】原稿作“每表都让 ours 行垫底”。以偏概全：Table 2/3/4 确为垫底，但 **Table 5**（消融表）的第一行就是 **ours**（full 模型 74.7，其后才是三组消融），见 S8 第 2 节 H8。修正后不影响“图表排兵”的结论，但表格在叙事里承担的功能不同：Table 5 是基准参照，不是胜利收尾。 - **RTE** 不塞 **appendix**，放正文并配免责声明（S5 已定策略）——小输摆台面，反而堵住审稿人“挑数据集”的嘴【可查证：§4.2 原文】。 - 真正的深度牌塞在 **§5 Analysis**：层迁移图回答“预训练的每层都有用吗”，zero-shot 演化图回答“模型天生会什么”。这两张图不产生 SOTA 数字，但它们把论文从“又一个刷榜工作”抬成“一个可研究的范式”【可查证：§5 结构；该定位判断为合理重构】。

3. Related work 的外交辞令

每一句客气话都在 preempt 一条审稿意见：

- 对 ELMo/TagLM：“a substantial amount of new parameters for each separate target task”——这是全文最锋利的句子，但它被夹在对其贡献的承认之后。功能：抢先回答“你和 ELMo 什么区别”【可查证：§2】。
- 对 ULMFiT/Dai & Le：“their usage of LSTM models restricts their prediction ability to a short range”——把“撞车”重述成“他们架构选错了”，同时立刻补上“we demonstrate on a wider range of tasks”，把差异从“架构”升级到“任务面”【可查证：§2】。
- 对 Transformer 原文：全程只引不评——不得罪架构原作者，免得引火烧身【合理重构：§2/§4.1 对 [62] 均为中性引用】。
- 摘要和结论各放一句 "task-agnostic"，这个词是全文的旗帜：对手的强项全是 task-specific，把战场定义权拿在手里【可查证：Abstract、§6 用词】。

4. 一个时代细节：它是 preprint

全文标注 "Preprint. Work in progress."，且引文里大量 arXiv 条目——这篇论文没有走会议评审，直接挂出【可查证：论文首页脚注】。这意味着 S7 的审稿环节在我们的仿真里本就是一场“假想敌演习”：真实历史上它面对的审判

不是审稿人，而是整个社区的时间检验【合理重构：依据 preprint 形态 + 无会议署名信息】。

5. 补记：成文时被我漏掉的硬数字（S8 核查后补）

立场说明：本阶段身份是"面对全部结果的作者"，引用结果数字合规；问题在于这些数字本该在成文权衡里出现，原稿却一条也没吸收。

数字	出处	为什么该在成文阶段被考虑
GLUE 总均分 72.8 对前最佳 68.9 (+3.9)	§4.2 第 393–394 行、Table 4	全文最像头条的一个数，却一次也没进入任何阶段的叙事。它比"9/12"更能反驳"你只是挑数据集"，因为 GLUE 均是官方口径
BooksCorpus 上 token-level perplexity = 18.4	§4.1 第 229–230 行	唯一能证明"LM 本身训得好"的客观读数；缺了它，"预训练质量"全靠下游任务间接背书
层迁移：满迁移在 MultiNLI 上最高 +9%	§5 第 466 行	S5 用过这张图，但只写"每层都有贡献"，丢了量级
换单层 2048 单元 LSTM：均分掉 5.6，且只在 MRPC 上赢	§5 第 558–560 行	架构消融的量化结论；"只在 MRPC 上赢"与"MRPC 恰是我们输掉的任务"叠起来，本可构成一条机理论证
无预训练：掉 14.8%	§5 第 561–562 行	预训练必要性的最直接读数

【修订注·S8 核查】以上五组数字在 S1–S7 中零次出现，对应 S8 第 3 节的覆盖度缺口 G1–G6。其中最严重的是 GLUE 72.8：本阶段通篇在讨论"怎么把 9/12 讲成胜利"，却忽略了论文手里还握着一个官方擂台的均分胜利。

《档案·S6》

【阶段】S6 成文

【已知事实】

1. 标题、abstract 措辞与数字排序—Abstract 原文

2. 全文无 "GPT" 字样，模型行名 "Finetuned Transformer LM"—Table 2-5

3. Fig 1 为框架图而非结果图—Fig 1

4. RTE 正文承认 + 免责声明—§4.2

5. "Preprint. Work in progress." 标注—首页脚注

6. 对 [43][44]、[13][21] 的具体措辞—§2

【合理重构】

a. "为范式占位而非为产品命名"的标题解读—依据：命名法体裁惯例

b. "图表排兵"的阅读顺序设计—依据：表格行序与图位置的客观呈现

c. "每句外交辞令对应一条审稿意见"的映射—依据：措辞的攻击性与防御性配比

【负结果】

1. 被藏起的材料：RTE 细节从 abstract 剔除（叙事性负结果—承认其存在但降权呈现）

2. "简洁性"卖点排除了更复杂但可能更强的微调技巧（S5 旧债在成文中的体现）

【未决问题】

1. 假想审稿人会怎么攻击这篇 preprint？（S7）

2. 叙事里的战略判断哪些是事后合理化？（S8 总检查）

【后见之明自检】本阶段身份即"面对全部结果的作者"，使用全文材料合规；未引入论文之外的后世影响（如 GPT-2/3 的后续）作为论据—合规。

会话 A · 审稿人输出（全新子代理，只喂论文全文，未接触 S1–S6 档案）

Summary：本文用 Transformer 解码器在 BooksCorpus 上做生成式 LM 预训练，再对 12 个 NLU 任务做判别式微调，9/12 刷新 SOTA。

W1 — RTE 失败的说辞站不住（Table 2）：RTE 仅 56.0% vs 多任务 BiLSTM 61.7%，却以“9/12”为卖点；“likely benefit from multi-task but not explored”恰说明极小数据上无优势——选择性报告。**W2 — aux LM 消融自己打脸（Table 5）**：w/o aux 的 Avg 75.0 反高于 full 的 74.7，CoLA/SST-2/MRPC/STS-B 全面更高；所谓“helped”是 cherry-picking， $\lambda=0.5$ 全无依据。**W3 — 可复现性与公平性双重缺失**：无代码无权重（ELMo/ULMFIT 当时已开源）；BooksCorpus 有体裁偏见且未公开；对 ELMo 无同数据/同算力对照，“task-agnostic 胜 task-specific”建立在不对称基线上。**Questions**：Q1 RTE 补 multi-task 消融？Q2 λ 怎么选的、各任务显著性？Q3 能否公开权重或与 ELMo 同数据对照？评分：**5/10**，建议补实验后重投。

会话 B · 作者 Rebuttal（第一作者视角）

先承认：这份 review 的三刀都砍在真伤口上，没有一条是误解论文。逐条应对——

W1（RTE）：认怂修改，但不接受“选择性报告”的定性。审稿人说对了一半：RTE 的 56.0% 确实是败绩，我们从没藏——它在 Table 2 里、在正文里、配着明确的不利比较，一个试图隐瞒的作者不会这么排版。我们接受措辞整改：把 §4.2 的免责声明改写为更明确的 limitation 陈述，并在 abstract 的“9 out of 12”处加注任务规模差异。但“计入 9/12 叙事”的指控我们不认：12 个任务是成文前选定的，不是成文后筛的，GLUE 系任务是 benchmark 官方清单，不是我们挑的【可查证：Table 1 与 GLUE[64] 任务集重叠】。修改承诺：RTE 补 multi-task fine-tuning 变体的初步实验（Q1）——这个实验成本可控，且无论输赢都强化论文的诚实度。

W2（aux LM 消融）：部分力争，部分认怂。Avg 75.0 vs 74.7 这一刀很准，我们不辩解 0.3 的差距——那是噪声量级。但“基本是噪声甚至有害”是过度解读，证据在审稿人自己引的数据里：aux LM 的收益集中在大数据集（MNLI 88.1→、QNLI 86.9→、QQP），损害集中在小数据集——这正是正文“larger datasets benefit from the auxiliary objective but smaller datasets do not”的原话含义【可查证：§5 Ablation 段原文】。这个非单调结构本身是有信息量的发现：辅助目标本质是正则，数据越少正则越该弱， $\lambda=0.5$ 一刀切确实粗糙。修改承诺：正文补一句 λ 对各任务非最优的坦白； λ 的选取过程（网格粗扫）写入 appendix（Q2 的一半）。逐任务显著性检验（Q2 另一半）拒绝——8 个任务 × 多种子的重跑成本与论文剩余周期不匹配，这是实话不是托词。

W3（可复现性）：最难答的一条，半认怂半摊牌。无代码无权重——属实，不辩解。能给的让步：appendix 补全数据清洗管线（ftfy 版本、spaCy 配置、BPE 词表构建参数），把“可复现”从权重级降到配方级【合理重构：论文 §4.1 已给出大部分配方，此处承诺的是补齐缺口】。同数据对照（Q3）：原则接受——在 1B Word 上训同架构 LM 做对照，恰好能检验我们 §4.1 “长程连续文本是关键”的主张，这个实验对我们有利，欢迎它进入 future work 清单。但要说清楚一条边界：我们从未 claim “在所有语料上都优于 ELMo”，我们的 claim 是“task-agnostic 微调范式可行且强”，BooksCorpus 的选择理由在 §4.1 是公开论证而非隐藏变量。至于体裁偏见——成立，且我们愿意在结论里加一句承认；但也要指出：发现“小说语料的长程连续性有用”本身就是本文的实证贡献之一。

策略自白：三条的应对配比是 1 条力争（W2 的机制解读）、2 条认怂修改（W1 措辞、W3 配方）+ 2 个新实验承诺（RTE multi-task、1B Word 对照）。5/10 的评分我们接受但不服——reviewer 的刀法证明他读懂了，而“读懂后仍给 5 分”说明问题在呈现而非范式。预印本的好处是我们不必等 rebuttal 截止日，修订版随时可挂。

【核查附注 · 由 S8 补记】

原则：审稿意见与 rebuttal 作为“当时的记录”原样保留，不回溯修改；核查发现的问题只在此附注中登记。

1. **W3** 里有两句未标注的外部断言：“ELMo/ULMFIT 当时已开源”、“BooksCorpus ...未公开”。前者可由 2018 年事

实佐证（ELMo 随 AllenNLP、ULMFiT 随 fastai 开源），后者风险最高——论文只给出数据集名与引文[71]，既不支持也不否认“是否公开”，而 W3 有三分之一的分量压在这句上。今后审稿人模板应要求：凡涉及论文之外的领域事实，须自陈把握程度（S8 第 2 节 H9）。

2. **W2 与 rebuttal** 存在双向选择性引用：审稿人只列举 aux 的四个受损任务（CoLA/SST-2/MRPC/STS-B），rebuttal 只列举三个受益任务（MNLI/QNLI/QQP），双方都绕开了 **RTE**。而 RTE 恰是全场最小数据集（2490 条）却因 aux 涨了 1.6 分（54.4→56.0），同时反证论文的两句概括（helps on the NLI tasks 与 smaller datasets do not）——这是本仿真最有价值的一处独立发现，S8 据此把指控从“数值抱怨”升级为“论文自我陈述与自身表格打架”（S8 第 2 节 H10）。
3. 隔离合规性确认：审稿意见中不含任何档案专有信息（sentiment neuron、1B Word 淘汰、微调崩溃、 λ 网格），子代理隔离确实生效（S8 第 1 节 V27）。

《档案·S7》

【阶段】S7 审稿 + rebuttal

【已知事实】（rebuttal 中引用的论文依据）

1. RTE 56.0 vs 61.7 及免责声明原文——§4.2、Table 2
2. "larger datasets benefit, smaller do not"—§5 Ablation 段原文
3. Table 5 全部消融数字（Avg 74.7/75.0/59.9/69.1）
4. 任务清单与 GLUE 重叠—Table 1、[64]
5. §4.1 的完整配方级细节

【合理重构】

- a. 审稿意见全文—全新子代理基于论文独立生成（隔离合规：未接触 S1-S6）
- b. rebuttal 的认怂/力争配比与新实验承诺—模拟 2018 年预印本文档的真实博弈（无截稿压力，可随时修订）
- c. " $\lambda=0.5$ 一刀切粗糙"的让步—S4 档案已载" λ 是试出来的"

【负结果】

1. W2 暴露了 S3 v1 引入 aux LM 的决策依据薄弱（ λ 无理论、收益非单调）—回溯修正 S3 的自信度
2. W3 暴露“不对称基线”问题：全程未与 ELMo 同数据对照，这是实验设计的真实缺口（S4 未决问题之外的漏网之鱼）

【未决问题】

1. S8 须核查：审稿人独立发现的 W2（aux LM 消融自相矛盾）在 S1-S6 叙事中是否被我们的“作者滤镜”淡化了——这是幻觉检查的重点条目

已核（2026-09-15）：确实被淡化—S4 原稿把同一处矛盾写成了“v1 留下的 aux LM 在小数据上正则效果比预期大”，与同段依据及 Table 5 双双相反，见 S8 第 2 节 H2；并附带独立发现 RTE 反例，见 H10。

【后见之明自检】审稿人为 2018 视角（不知 BERT/GPT-2），rebuttal 未引用后世影响自辩—合规。

口径三段式 - 目标：以第三方核查员身份，把 S1–S7 的叙事与论文真实结果逐项对照，产出本仿真系统的误差报告。 - 现状：全部《档案·S1》–《档案·S7》+ 论文全文（`gpt1.txt`，541,036 字节提取文本）。 - 限制：本阶段身份不是作者。只认论文原文能核到的内容；论文里没有的一律进幻觉清单，不替前文辩护；前文标注为【合理重构】的条目按“重构是否被论文数据反证”单独评判，不与“史实错误”合并计数。

0. 核验基准（论文硬事实清单）

以下为本次核查实际逐条打开核对的原文锚点（行号 = `gpt1.txt` 行号，可直接复验）：

#	论文事实	锚点
A1	Abstract : 9 out of 12 ; 8.9% / 5.7% / 1.5% , 且只给这三个数字	27–31
A2	§1 两难：目标函数无共识（LM[44]/MT[38]/discourse[22] 各赢各的）；迁移方式无共识（架构改动[43,44]/复杂训练方案[21]/辅助目标[50]）	43–51
A3	§1 含 GLUE 引用与脚注：the recently introduced GLUE multi-task benchmark [64]、脚注 1 = <code>gluebenchmark.com/leaderboard</code>	52, 75–76
A4	§2 三个小节：Semi-supervised learning for NLP / Unsupervised pre-training / Auxiliary training objectives	79–121
A5	§2 对 ELMo/TagLM/CoVe : a substantial amount of new parameters for each separate target task	109–113
A6	§2 对 Dai&Le / ULMFiT : their usage of LSTM models restricts their prediction ability to a short range	102–108
A7	§3.1 Eq.(1) LM 目标；Eq.(2) $h_0 = UWe + Wp$ 、 $P(u) = \text{softmax}(h_n We^T)$	127–148
A8	§3.2 Eq.(5) $L_3(C) = L_2(C) + \lambda * L_1(C)$ ；对 aux 的动机原文是 improving generalization ... and accelerating convergence	166–171
A9	§3.2 末句：the only extra parameters we require during fine-tuning are W_y , and embeddings for delimiter tokens	172–173
A10	§3.3 三类输入变换：蕴含 <code>premise \$ hypothesis</code> ；相似度双向各过一遍再逐元素相加；QA [<code>z</code> ; <code>q</code> ; <code>\$</code> ; <code>ak</code>] + softmax	180–206
A11	§4.1 BooksCorpus : over 7,000 unique unpublished books、long stretches of contiguous text；1B Word shuffled at a sentence level – destroying long-range structure；token level perplexity of 18.4	211–230
A12	§4.1 结构：12 层 decoder-only / 768 / 12 头 / FFN 3072；Adam 2.5e-4；2000 update 线性 warmup + cosine；100 epoch × 64 × 512；BPE 40,000；learned position embeddings；修正版 L2 [37]；GELU；dropout 0.1；ftfy + spaCy	231–245
A13	§4.1 微调：lr 6.25e-5、batch 32、3 epochs of training was sufficient、linear decay + 0.2% warmup、 λ was set to 0.5（无任何选取理由）	246–251
A14	§4.2 RTE : 2490 examples、accuracy of 56%、below the 61.7% reported by a multi-task biLSTM model + 免责声明全文	271–274
A15	Table 2 中 61.7 属 Multi-task BiLSTM + Attn [64]（不含 ELMo）；ours 行垫底：MNLI-m 82.1 / mm 81.4 / SNLI 89.9 / SciTail 88.3 / QNLI 88.1 / RTE 56.0	321–334
A16	§4.2 相似度：state-of-the-art results on two of the three；STS-B +1.0；QQP 较 Single-task BiLSTM+ELMo+Attn 高 4.2%	377–385

A17	§4.2 分类：CoLA 45.4 对前最佳 35.0；SST-2 91.3 仅称 <code>competitive with the state-of-the-art</code> ；GLUE 总分 72.8 对前最佳 68.9	386–394
A18	Table 4：Sparse byte mLSTM [16] SST-2 = 93.2 (> ours 91.3)；TF-KLD [23] MRPC = 86.0 (> ours 82.3)；GLUE 基线 Multi-task BiLSTM + ELMo + Attn [64] = 68.9	413–447
A19	Table 5 (8 任务)：full 74.7 / w/o pre-train 59.9 / w/o aux 75.0 / LSTM 69.1；w/o aux 在 CoLA 47.9、SST-2 92.0、MRPC 84.9、STS-B 83.2 上更高，在 MNLI 81.1、QNLI 86.9、QQP 69.8、 RTE 54.4 上更低	477–536
A20	§5 层迁移：each transformer layer provides further benefits up to 9% for full transfer on MultiNLI	461–467
A21	§5 zero-shot：4 个启发式 (CoLA 阈值化平均 token log-prob；SST-2 追加 very 并限制输出分布到 positive/negative；RACE 平均 token log-prob；DPRD 代词替换)；LSTM exhibits higher variance in its zero-shot performance	472–552
A22	§5 消融三结论：aux helps on the NLI tasks and QQP, larger datasets benefit ... but smaller datasets do not；换 LSTM 掉 5.6 分且只在 MRPC 上赢；无预训练掉 14.8%	553–563
A23	模型自称 Finetuned Transformer LM (ours)；全文无 "GPT" 字样；首页 Preprint. Work in progress.	53, 328, 448, 497
A24	参考文献 [16] = S. Gray, A. Radford, and K. P. Diederik. Gpu kernels for block-sparse weights. 2017；[22] = Jernite 的 discourse-based objectives；[28] = Kiros skip-thought；[34] = Liu et al. Generating Wikipedia；[52] = Rocktäschel	604–688
A25	全文未出现 WNLI (GLUE 九任务之一缺席，论文未给理由)	全文检索无命中

1. 【对上了】—— 叙事与论文一致 (材料扎实性的证明)

编号	叙事条目	出处阶段	核验结果
V1	两难困境：目标无共识 + 迁移方式无共识	S1/ S2	与 A2 逐句吻合，S2 引的 each method outperforming the others on different tasks 正是 §1 原句
V2	候选目标的"三选一" = LM[44] / MT[38] / 篇章连贯[22]	S3	A2 原句列举的正是这三个，且顺序一致
V3	traversal 拍平法来自 Rocktäschel[52]	S1	A24 + §1 66–67、§3.3 186–187
V4	Transformer decoder 长文生成 [34] 证明该架构可当 LM	S1	§1 63、§3.1 138
V5	block-sparse GPU kernel = 论文引文[16]	S1	A24 精确命中
V6	CoVe/ELMo/TagLM 留大量任务专用参数	S1/ S2	A5 原文
V7	Dai&Le/ULMFiT 只做分类、受 LSTM 短程限制	S1/ S2	A6 原文
V8	aux LM 有 Rei[50]/Collobert[10] 先例	S2	A4 的第三小节 + §3.2 168
V9	$L_3 = L_2 + \lambda \cdot L_1$ ， $\lambda=0.5$	S3/ S7	A8、A13
V10	微调唯一新增参数 = Wy + 分隔符 embedding	S3	A9 原句
V11	三类输入变换 (相似度双向+逐元素相加；QA $[z; q; \text{§}; ak]$ +softmax)	S3	A10 完全一致，含"逐元素相加"这个容易被写错的细节
V12	全部结构/优化超参 (12/768/12/3072、40k BPE、学习式位置 embedding、修正版 L2、GELU、dropout 0.1)	S3/ S4	A12 逐项命中，含 learned position embeddings 与 [37]

V13	微调超参 lr 6.25e-5 / batch 32 / 3 epoch / 0.2% warmup	S4	A13 逐项命中
V14	BooksCorpus vs 1B Word 的选型理由（长连续文本 vs 句子级打乱）	S4	A11 原文，属本文最硬的一条论据
V15	ftfy 清洗 + spaCy 分词	S4	A12
V16	baseline 清单（CAFE 5x、SAN、Dynamic Fusion 9x、BiAttention MRU 9x、GLUE 官方基线）	S4	A15/A18，连 5x/9x 的集成标注都对
V17	RTE 2490 例、56 vs 61.7、免责声明原文	S5/ S7	A14 逐字命中
V18	Fig 2 右：zero-shot 随预训练稳定爬升，LSTM 对照组方差更大	S5	A21 原句
V19	Fig 2 左：每层预训练参数都在贡献	S5	A20
V20	9/12 的胜负口径	S5/ S6/ S7	A1、§4.2 455
V21	Abstract 只放 8.9/5.7/1.5 三个数字、且不点名失利任务	S6	A1 精确；§1 另有 5.5% GLUE（S6 已注明“藏起 56.0”）
V22	消融的 8 个任务全为 GLUE 任务	S5	Table 5 列头即 CoLA/SST-2/MRPC/STS-B/QQP/MNLI/QNLI/RTE，命中
V23	全文无“GPT”、自称 Finetuned Transformer LM、且是 preprint	S6	A23
V24	§2 对 ELMo 与 ULMFiT 的“外交辞令”原句	S6	A5/A6 原文
V25	Fig 1 是框架图（架构+双目标 / 输入变换），不是结果图	S6	§3 Fig 1 caption（175–176）
V26	S7 三刀的全部数字（56.0/61.7、74.7 vs 75.0、CoLA 45.4 vs 47.9、SST-2 91.3 vs 92.0、MRPC 82.3 vs 84.9、STS-B 82.0 vs 83.2、 $\lambda=0.5$ 无理由）	S7	逐条比对 A13/A14/A18/A19，零错误
V27	S7 子代理隔离确实生效	S7	审稿意见中未出现任何只存在于档案的信息（sentiment neuron、1B Word 淘汰、微调崩溃事件、 λ 网格），可判定未越界读档

判定：数字层与引文层的扎实度很高——凡叙事写了“出处”的地方，除下表第 2 节的 P0/P1 条目外，基本可核。这套仿真的主要误差不在“编数字”，而在“编因果”与“编标签”。

2. 【编圆了但论文没这回事】——幻觉清单（按严重程度排序）

P0 · 与论文事实直接矛盾（必须修正）

H1 | S1 档案：“GLUE[64]（2018.4）尚未出现（故全文未提 GLUE）” - 论文真相：A3 —— §1 正文写着 the recently introduced GLUE multi-task benchmark [64]，脚注 1 直接指向 gluebenchmark.com/leaderboard；§4.2 又写 the recently released GLUE multi-task benchmark [64]，which we make use of；Table 4 caption 写 All task evaluations in this table were done using the GLUE benchmark。 - 性质：事实错误。且与 S2 档案自相矛盾——S2 明确写“GLUE[64]（2018.4）论文引用了”，S1 却写“全文未提 GLUE”。两个档案直接对撞，说明“档案作为阶段间唯一接口”这一契约在流转时没有被真正校验。 - 危害：S1 是唯一负责“时间点设定”的阶段，它的时间基准错了会污染后续所有“当时不知道什么”的判断。（修正：把时间点设在 2018 年 4 月之前才成立；3 月设定本身不错，错的是结论句。）

H2 | S4 正文：“最后靠三件套稳住的：...以及 v1 留下的 aux LM（它在小数据上的正则效果比预期大）” - 论文真相：A19/A22 —— aux 的收益结构是反向的：w/o aux 在 CoLA(+2.5)、SST-2(+0.7)、MRPC(+2.6)、STS-B(+1.2) 上全面更高；论文原话是 larger datasets benefit ... but smaller datasets do not。 - 性质：事实错误 + 句

内自相矛盾。同一段的方括号依据自己写着"aux 的收益结构是'大数据受益、小数据有损'"，正文却说 aux 在小数据上"正则效果比预期大"。五行之内打自己的脸。 - 危害：这是 S7 审稿人 W2 独立发现的同一处伤口。作者滤镜把它写成"证据"，核查员把它读成"自相矛盾"——这条正好验证了 S7 档案预判的"S8 重点核查项"。

P1 · 与论文数据存在张力（重构被论文反证）

H3 | S3 + S4 的核心因果链："v0 无 aux → 小数据必然过拟合 → v1 加 aux 当正则" - 论文真相：A8 —— 论文对 aux 的动机原话是 `improving generalization of the supervised model` 和 `accelerating convergence`，没有"治小数据过拟合"这层意思；A19 又显示 aux 对四个小数据集是负贡献。 - 性质：重构方向性错误。这不是"论文没写"，而是"论文写了相反的东西"。S3 把 v1 的动机挂在了 aux 上，而 aux 恰恰在小数据上帮倒忙——v1→v2 的迭代链在"小数据困境"这条线上救错了人。 - 修正建议：v1 的 aux 动机应改写为"加速收敛 + 与先例对齐 ([50][43])"，而"小数据不稳"的修补应归于 warmup+early-stop (S4 三件套里的另两件)，并把 aux 的收益非单调性降级为"当时误判、事后由 Table 5 揭穿"。

H4 | S5："12 个任务里输 3 个小的"，并把受伤名单写成 **RTE 2490 / STS-B 5.7k / MRPC / CoLA 8.5k** - 论文真相：数量对 (12 - 9 = 3)，但名单错。由 A17/A18 反推，三项非 SOTA 是 **RTE (56.0)**、**MRPC (82.3 < 86.0)**、**SST-2 (91.3 < 93.2)**。而叙事点名的 STS-B 与 CoLA 在论文里恰恰是胜利：STS-B 是 `a 1 point absolute gain`，CoLA 是 45.4 对前最佳 35.0 的"big jump"。 - 性质：论据与结论错位。用"论文的胜绩"给"论文的败绩"作证。 - 附加发现：S5 说三项都是"小的"——SST-2 在 GLUE 中是 6.7 万量级 (该数字论文未给，属外部常识)，不属于小数据集。真正的"小"只有 RTE(2490) 与 MRPC(3.7k)。 - 附注：S6 已经注意到"Abstract 不说那 3 个是谁"，却没有一个阶段把这三项真的列出来——见第 3 节 G1。

H5 | S5："RTE 是伤口最深的一处：一个 2013 年风格的 BiLSTM 多任务模型压着我打" - 论文真相：A15 —— 61.7 那一行是 `Multi-task BiLSTM + Attn [64]`，即 2018 年 GLUE 官方基线，不是 2013 年的东西。"2013 年风格"是修辞上的贬低，会把读者的判断从"输给官方强基线"误导成"输给过时方法"。 - 性质：修辞越界（数字无误，定性失真）。且该行不含 ELMo，这反而说明 RTE 的失利与"ELMo vs 我"的路线之争无关——S5/S7 都没利用这一点。

P2 · 标签错配与表述不严（调模板的直接依据）

H6 | S2 档案 #1："五派划分及代表作——论文 §2 全部条目"（标【可查证】） - 论文真相：A4 —— §2 的结构是三个小节（`semi-supervised / unsupervised pre-training / auxiliary objectives`），"五派"是叙事自建的分类框架。 - 性质：标签错配。五派的代表文献都在 §2 里（可查证），但"划分"与"各派死穴"是重构。正确写法是：代表文献【可查证：§2】，分派与死穴判定【合理重构】。B 派"容量天花板太低"、E 派"只吃到一口"两处死穴尤其如此——§2 对它们只有中性陈述。

H7 | S1 档案 #1 / #2 的【可查证】指向论文外材料 - 论文真相：`Radford, Jozefowicz, Sutskever 2017 (sentiment neuron)` 不在论文参考文献表中；A24 显示 [16] 是 `block-sparse kernels`。 - 性质：标签越界。标【可查证】却指向本次输入（论文全文）之外的文献，实际上无法在闭环内核验。要么改标【合理重构】并注明"依据作者公开轨迹"，要么补上该文献的真实题名/编号。

H8 | S6："Table 2/3/4 按任务族铺开，每表都让 **ours** 行垫底收尾" - 论文真相：Table 2/3/4 确实是 **ours** 垫底 (328、362、448)；但 Table 5 的第一行就是 **ours** (497，其后才是三组消融)。 - 性质：以偏概全。"每表"应改为"Table 2/3/4"。

H9 | S7 会话 A 中未打标签的外部断言 - 具体：`ELMo/ULMFiT` 当时已开源、`BooksCorpus` 有体裁偏见且未公开。 - 性质：来源标注义务的灰色地带。审稿人身份可以凭领域常识说话，但这两条是关于 2018 年社区资源状态的外部事实，论文既不支持也不否认（论文只给数据集名与引用 [71]，体裁偏见可由 `Adventure, Fantasy, and Romance` 推出，可查证）。"未公开"这一条尤其危险——它可能整条立不住，而 W3 有三分之一的分量压在上面。 - 建议：审稿人模板里追加一句"凡涉及论文之外的领域事实，须自陈把握程度"。

H10 | S7 会话 B (rebuttal) 的双向选择性引用 - 具体：rebuttal 用 `larger datasets benefit ... but smaller datasets do not` 据理力争，列举了 aux 的受益方 (MNLI/QNLI/QQP)，回避了 **RTE 54.4 → 56.0**——而 RTE 恰是全场最小的数据集、恰是 W1 的战场、恰是论文自己的概括句 (`helps on the NLI tasks vs smaller datasets do not`) 内部冲突的活证。 - 审稿人 W2 同样只列举了受损方 (CoLA/SST-2/MRPC/STS-B)，回避了 **RTE/MNLI/QNLI/QQP**。 - 性质：双方各取一半。这是本仿真最有价值的一处独立发现：论文 §5 的两句概括 ("帮 NLI" + "大数据受益小数据不受益") 在 RTE 上互相打架——RTE 是最小的数据集，却因 aux 涨了 1.6 分。 - 价值：这条既是"作者滤镜"，也是"审稿人滤镜"。真正的第三方核查应该拿它当第一发炮弹。

3. 【论文有而叙事漏了】——覆盖度缺口

编号	论文内容	锚点	被漏成什么样
G1	GLUE 总分 72.8 vs 前最佳 68.9 (本文最显眼的总成绩之一) ; §1 单列的 5.5% GLUE 提升	A17	S1–S7 全程零次提到 72.8/68.9。叙事只盯着 9/12 与 RTE, 把“在官方擂台上把总分抬高 3.9 分”这件最像头条的事漏了
G2	三项非 SOTA 的具体身份 (RTE / MRPC / SST-2)	A17/ A18	S6 只说到“那 3 个是谁没说”, 没有任何阶段把名单坐实; S5 还给错了名单 (见 H4)
G3	BooksCorpus 上的 token-level perplexity = 18.4	A11	零次出现。这是“LM 训得好不好”的唯一客观读数
G4	§5 四个 zero-shot 启发式的具体构造 (阈值化 / 追加 very / 限制输出分布 / 代词替换)	A21	S5 只写“zero-shot 探针显示...”, 四个机制全漏——而 S4 曾把“机理实验”列为四层实验的第三层, 等于设计说了、实现没写
G5	Fig 2 左的关键数字 up to 9% for full transfer on MultiNLI	A20	S5 只写“每层都在贡献”, 没给 9%
G6	换 LSTM 掉 5.6 分、且只在 MRPC 上赢; 无预训练掉 14.8%	A22	S5 只用了“LSTM 方差更大”一条; “只在 MRPC 上赢”这个细节与“MRPC 也是我们输掉的任务”叠起来本可形成一条更有力的机理论证
G7	SciTail (+5%)、SNLI (+0.6%)、QNLI (+5.8%) 的具体增益	A15/ §4.2 268– 269	12 个任务里的 SciTail 从头到尾没被讨论过; S4 说“广度”是设计目标, 却没落到任务级叙述
G8	§3.1 Eq.(2) 的实现式 ($h_0 = UWe + Wp$ 、输出层复用 We)	A7	S3 只引了 Eq.(1), 把“词嵌入矩阵在输入输出两端复用”这个 Transformer LM 的关键实现细节漏了
G9	§2 第三小节对 aux objective 的定位—— unsupervised pre-training already learns several linguistic aspects relevant to target tasks	120– 121	这句话是论文给 aux LM 打的最强预防针 (“预训练已经学到了, aux 只是补”), S2/S3/S6/S7 四方都没引; 如果引了, H2/H3 的矛盾在 S3 阶段就会被发现
G10	WNLI 的缺席	A25	全文无 WNLI。这是论文自身的覆盖缺口, 叙事不必背锅, 但它使 S7 rebuttal 那句“GLUE 系任务是 benchmark 官方清单, 不是我们挑的”只能成立一半——GLUE 九任务里被去掉一个, 而论文没给理由

4. S7 专项检查 (用户点名的“狠查”)

4.1 三条 major weakness 的数字与引文

条目	核验	结论
W1 : RTE 56.0 vs 61.7、9/12 卖点、免责声明	A14	准确。唯一可挑的是没点名另外两项失利 (MRPC/SST-2), 削弱了杀伤力
W2 : w/o aux Avg 75.0 > full 74.7 ; CoLA/SST-2/MRPC/STS-B 全面更高; $\lambda=0.5$ 无依据	A19/A13	准确, 四个任务的数字逐一命中。但只列受损方 (见 H10), 且没发现 RTE 反例
W3 : 无代码无权重、BooksCorpus 体裁偏见/未公开、对 ELMo 无数据同算力对照	A18 + 论文无代码声明	前两项属实 (论文确无代码/权重/发布声明); 第三条成立 (ELMo 只出现在 Table 2 ESIM+ELMo (5x) 与 Table 4 的 GLUE 基线里, 没有同语料的 ELMo LM 对照); “未公开”属未标注的外部断言 (见 H9)

4.2 审稿人漏掉的两发炮弹

1. **RTE 反例 (H10)**：如果 W2 加上"你论文最小数据集 RTE 恰恰因 aux 涨了 1.6 分，你的两句概括互相矛盾"，W2 就从"数值抱怨"升级为"论文自我矛盾"，5/10 的评分会更难反驳。
2. 三项失利不点名：Abstract 写 9/12 却不列失败任务，是比 RTE 单点更系统的呈现问题。审稿人只在 W1 里点了 RTE，等于替作者接受了"只错一个"的暗示。

4.3 隔离合规性

判为合规：审稿意见中不含任何档案专有信息（见 V27）；且它独立复现了主线的"S5 就埋过的小数据伤口"，说明隔离是实的、不是走过场。

4.4 rebuttal 的引文核验

rebuttal 引用	核验	结论
larger datasets benefit from the auxiliary objective but smaller datasets do not	A22 原句	逐字准确
12 个任务是成文前选定的、GLUE 系任务是 benchmark 官方清单	A25 / Table 1	前半句属不可核验的自我陈述；后半句因 WNLI 缺席只成立一半（G10）
§4.1 已给出大部分配方	A11/A12/A13	准确——§4.1 的配方级细节确实很全，"补齐缺口"的让步是诚实估价
预印本，不必等 rebuttal 截止日	A23	与 S6 的 preprint 发现一致，内部自洽

S7 小结：审稿与 rebuttal 是整个仿真里质量最高的一轮——数字零错误、隔离真做到了、且反馈回来修正了前序的自信度（档案 S7 已自陈 W2 回溯修正 S3）。它的问题是把火力集中在"RTE 单点 + 数值反例"，没有上升到"论文的自我陈述与自己的表打架"。

5. 误差报告与模板调参建议

幻觉统计（口径：以"带标签的实质性断言"为计数单位，粒度≈一句话）

类别	计数	说明
对上了（V1–V27，共 27 组 ≈ 60 条独立断言）	27 组 / ≈60 条	数字层零编造：凡叙事给出出处的，除下列条目外均可核
P0 事实错误	2 条	H1、H2
P1 因果夸大 / 论据错位 / 修辞越界	3 条	H3、H4、H5
P2 标签错配 / 表述不严	5 条	H6–H10
覆盖度缺口	10 条	G1–G10

→ 错误率 ≈ $10 / 60 \approx 17\%$ 的带标签断言存在 **P0–P2** 问题，其中真正与论文事实直接矛盾的只有 2 条（**3.3%**）。这个分布说明：本仿真的失败模式不是"编数字"，而是"给正确的事实安上错误的因果与标签"。

误差的分布规律（这才是本报告最有用的部分）

1. 数字几乎不编，因果大量编。所有性能数字都能核到（含 S7 全部），但一旦解释"为什么这么做"，S3/S4 就出现了方向性错误。→ 模板应要求：凡陈述"某设计是为了解决某问题"，必须给出论文里的动机原句，否则降级为待验猜想。
2. 档案之间的交叉矛盾没人查。S1 与 S2 对 GLUE 的判断直接对撞；S4 与自己的方括号对撞。→ 模板应在每阶段开头加一条"与上一阶段档案的一致性自检"，并在 S8 之前设一道轻量交叉校验。
3. "作者滤镜"是真的存在。同一个 Table 5，作者读成"正则有效"，审稿人读成"自相矛盾"。→ 这验证了 S7 必须开隔离会话的设计，也说明 S8 应该先看审稿意见再看自己的叙事，否则会被自己的叙事锚定。
4. 负结果占比达标但分布不均。S1（>60%）、S5（主场）充足，S6（2 条）、S7（2 条）薄弱。→ 对扩展阶段，可给负结果设条数下限而非仅看总篇幅占比。

5. 胜绩被系统性忽略。GLUE 72.8、perplexity 18.4、9% 层迁移增益这些"文中的好数字"全被漏掉——因为叙事把张力全押在 RTE 上。→ 覆盖度检查应单列"论文正面的硬数字是否被叙事吸收"。

6. 最后一问：这套仿真教会我的东西里，哪些是读论文原文绝对学不到的？

分三层，且必须诚实标注哪些是史实、哪些是重构：

第一层：问题结构（可迁移，且论文不写） - "数据形态决定方法上限"：1B Word 被句子级打乱 → 长程结构物理消失 → 押注长程依赖的方法用它等于自断一臂。论文只有一句 `destroying long-range structure`，但它是一条可复用的判据（选语料先看形态是否匹配假设），比结论本身值钱。 - 高风险区的先验：12 个任务里哪几个会输，事前唯一的信号是"样本量 vs 参数量"的量级比。论文只报结果，仿真的价值在于把它提炼成"1.17 亿参数 × 2490 条样本"这种可以事前标记的风险判据。 - 分布形态看得出的东西：Table 5 的收益非单调（大数据 +、小数据 -、RTE 反例）不可能从论文的概括句里读出来——论文的句子是 `larger datasets benefit ... but smaller datasets do not`，只有把 8 个任务的差值逐一算过，才知道 RTE 反着走、论文自己的概括不成立。教会我：不要相信论文的趋势句，要重算它的表。

第二层：叙事工程（论文的呈现本身就是知识） - Abstract 只放三个数字、只写"9 out of 12"而不点名失利三项；RTE 不塞 appendix 而是放正文免责声明； $\lambda=0.5$ 只给值不给理由；对 ELMo 的最锋利批评被夹在承认之后。这些是论文里真实存在、但论文绝不会自己指认的修辞——只有"倒着读"才能显影。

第三层：本仿真自身的局限（必须声明） - "MT 目标、篇章连贯目标被排除" "multi-task 微调被毙" "ULMFiT 式微调技巧被毙" "微调崩溃事件"——这些都不是史实，是【合理重构】。它们的证据形式是"论文里没有痕迹"，而不是"论文里有记载"。读这个话题真正学不到的那部分，我这套仿真也只能给出重建的假设，不能给出事实——这是仿真最该被记住的边界。 - 真正学不到、也仿真不出的：在 2018 年的单机多卡上把一个 1.17 亿参数模型训到收敛时，手上那台机器的噪声与人的判断力之间发生的事。S8 之后唯一能补的是真复现，不是再写一轮叙事。

《档案 · S8》

【阶段】S8 对照复盘（幻觉总检查）

【已知事实】（本阶段新增的、可核验的核查结论）

1. 论文 S1/S4.2/Table 4/脚注 1 均出现 GLUE — 推翻 S1"全文未提 GLUE"（行 52/75/256/397/715）
2. Table 5 的 aux LM 收益：受损 CoLA/SST-2/MRPC/STS-B，受益 MNLI/QNLI/QQP/RTE — 与 S4 正文及 S3 因果链相反
3. 三项非 SOTA 由 9/12 与 S4.2/Table 4 反推为 RTE、MRPC、SST-2；S5 的受伤名单（RTE/STS-B/MRPC/CoLA）错误
4. GLUE 总分 72.8 vs 68.9、BooksCorpus perplexity 18.4、层迁移 up to 9%、LSTM 掉 5.6 分（只在 MRPC 赢）、无预训练掉 14.8% — 叙事零覆盖
5. Table 5 第一行即 ours（非垫底）— S6"每表垫底"以偏概全
6. 论文全文未出现 WNLI
7. S7 三条 weakness 的全部数字经逐条比对无误；子代理隔离有效

【合理重构】

- a. "论文 S5 两句概括在 RTE 上互相矛盾"的判定 — 依据 Table 5 的 RTE 54.4→56.0 与 S5 原文（helps NLI / small datasets do not）直接冲突
- b. 误差占比统计 — 依据 27 组对照条目与 10 条幻觉/缺口的人工计数（粒度为一句话级判断）
- c. 模板调参建议 — 依据本轮 8 个阶段的误差分布规律

【负结果】（本阶段即误差报告本身）

1. P0 两条：S1 的 GLUE 事实错误、S4 的 aux 正则自相矛盾（且 S1/S2 档案对撞）
2. P1 三条：S3/S4 的 aux 因果链方向错误、S5 的失利名单错误、S5 的"2013 年风格"修辞越界
3. P2 五条：S2 五派标签错配、S1 外部材料标可查证、S6"每表垫底"、S7 未标注的外部断言、S7 双向选择性引用
4. 覆盖度缺口 10 条（其中 G1/G2/G3 为"论文头条数字被整段漏掉"）
5. 设计层面：档案契约缺"与上一阶段一致性自检"，导致 S1→S2、S4→S4 的矛盾存活到最后

【未决问题】

1. H2/H3 需回改 S3/S4 的 aux 动机段落 —【已执行】2026-09-15 修订轮，见第 7 节
2. S5 的受伤名单须改 —【已执行】；S6 的"藏起 56.0"叙事可再升级为"藏起整整三项失利"，留待下一轮改写 S6

的叙事层

3. GLUE 72.8 等头条数字须补入 —【改由 S6 第 5 节补记】。理由：S4 阶段引入结果数字会违反"曲线走向不许照抄论文结论"的纪律，S6 才是"面对全部结果的作者"该扛这组数字的地方
4. 真正剩下的一件事：跑一次真实最小复现（CleanRL / 最小可跑 GPT-1 微调）去对照差距—仿真到此为止能给的都给了
- 【后见之明自检】本阶段身份为第三方核查员，允许对照论文全文；未使用论文之后的历史（GPT-2/3、ELMo 长期命运）作为论据；对无法核验的外部断言（BooksCorpus 是否公开）只标风险、不下断言 — 合规。
- 【全局负结果占比】按条数：S1(3)+S2(2)+S3(3)+S4(4)+S5(4)+S6(2)+S7(2)+S8(15 条误差/缺口) = 35 条；S5 归档时按篇幅折算为 45%，S8 补入 15 条后按篇幅折算约 48%（推定量级，非精确文本占比）—达标 ≥40%。

7. 修订记录（本轮已执行，2026-09-15）

原则：修正 + 加注，不静默覆盖。原稿的错误保留在各文件的【修订注】里供追溯，正文按事实改写。

编号	文件	修改内容
H1	S1.md	档案 b 条删去"故全文未提 GLUE"，改为"idea 期未存在、成文期已被引用"，附四处出处；加【修订注】说明原错误与 S1↔S2 对撞
H7	S1.md	情感神经元条目改标【可查证·论文外】，注明该文不在论文参考文献表、[16] 为 block-sparse kernels
H6	S2.md	档案 #1 拆为"文献可查证 + 五派框架为重构"，补 §2 只有三个小节的原文依据
H3	S3.md	v0 死因由"小数据必然过拟合"改为"当时预期"；v1 的 aux 动机改引论文原句 improving generalization ... accelerating convergence；档案【负结果】1 同步修正
H2	S4.md	"三件套"里的 aux LM 由"正则效果比预期大"改为"当时以为是它在兜底，实为误判"
H4 / H5	S5.md	受伤名单改为 RTE / MRPC / SST-2；删去"2013 年风格"，补 Table 2 行名与"不含 ELMo"
H8	S6.md	"每表垫底"改为"Table 2/3/4 垫底"，注明 Table 5 首行即 ours
G1–G6	S6.md	新增第 5 节"补记：成文时被我漏掉的硬数字"（GLUE 72.8、perplexity 18.4、层迁移 9%、LSTM –5.6、无预训练 –14.8%）
H9 / H10	S7.md	新增【核查附注】：登记 W3 未标注外部断言、W2 与 rebuttal 的双向选择性引用、隔离合规确认；审稿与 rebuttal 原文未改动
—	skill paper-research-simulation	契约加【一致性自检】字段；S3 加"动机须引原句"；S4 加"归因须与消融表对齐 + 吸收正面硬数字"；S8 加"第 0 步：先重算论文趋势表"

剩余动作

- S6 叙事层可再改一次：把"藏起 56.0"升级为"藏起整整三项失利（RTE / MRPC / SST-2）"——本轮只修正了数字与事实，未重写这层修辞分析。
- 真复现：跑一次真实最小复现（最小可跑 GPT-1 微调）去对照差距。
- 换一篇论文重跑，验证模板修订是否真的消掉了 H2/H3 这类错误（同一篇会受记忆污染）。

附：修订前的原始收尾建议（已执行完毕，保留供追溯）

- 必改（P0/P1）：S1 删掉"全文未提 GLUE"；S3 的 v1 动机与 S4 的"三件套"去掉 aux 治小数据的说法；S5 的失利名单改为 RTE/MRPC/SST-2 并删掉"2013 年风格"。
- 可选（P2）：S2 把"五派"改标【合理重构】；S6"每表垫底"改为"Table 2/3/4"；S7 审稿人补一句"外部事实自陈把握程度"。
- 下一轮调模板：给 S3/S4 加"动机必须引论文原句"；给每阶段加"与上一阶段档案一致性自检"；给 S8 加"重算论

文的趋势表"这一固定动作（本轮它直接抓出了 RTE 反例）。

4. 真复现：本仿真到 S8 为止能给的都给了；剩下的只有跑一次真实复现（CleanRL/最小可跑版 GPT-1 微调）去对照差距。