

GPT-2 · S9 成稿

语言模型自己会做任务，这件事我用了半年才敢说出口

基于公开材料的第一人称合理重构，不代表论文作者本人或 OpenAI 的真实经历、观点或言论

目录

语言模型自己会做任务，这件事我用了半年才敢说出口

语言模型自己会做任务，这件事我用了半年才敢说出口

——GPT-2 的第一人称复盘：一个被反向读出来的想法、三次亲手杀死自己的方案，和我一年后才敢承认的四件事

仿真声明：本文是基于公开材料的第一人称合理重构，不代表论文作者本人或其机构的真实经历、观点或言论。凡“我记得”“我当时猜”“这一点论文里没写”的段落属重构；凡带数字的事实均可在论文原文核对，依据见全文末的章末注。本文的对照核查结论（含我自己写错的十条）压缩在附录里。

第一幕·问题：我发现自己答不出“为什么赢”

本章论点：卡住我的不是模型不够大，是我做赢了一件事却说不清它为什么赢——而说不清的胜利，对理解没有任何贡献。

起点不在 2019 年，在 2017 年。

那一年我做了一个实验，很久以后我才知道它其实是我后来所有判断的源头：一个 byte 级的 LSTM，训练目标朴素到不能再朴素——猜下一个字节。训完以后，它的内部长出了一个专门管情感的神经元：我把它拧一下，生成的文本情感就跟着翻面（这一点可以在当年的那篇论文里查到）。没有人教过它“情感”这个概念，它自己长出来了。

这件事在我脑子里留下一个执念，后来我把它压缩成一句自问：

如果语言模型在预训练里已经学会了怎么读句子，那为什么每个下游任务还要从零学一遍怎么用它？

这句话听着像口号，但它其实是一个能拿来砍方案的标准——它砍掉的第一个方案，就是我自己的。

我们确实做成了一个

2018 年我们做了那篇后来被叫做 GPT-1 的东西：一个 Transformer 语言模型，预训练完以后，把判别式任务全部拍平成一条序列，只在最后加一个线性层微调。架构零改动，预训练里学的每一层都参与下游任务。结果不难看。

但我心里有个疙瘩一直没解开：我还是得给每个任务准备标注数据。

GLUE 的数据是人一条条标出来的，问答的数据是人一条条标出来的。模型越好，就越像是在把人的标注吃得更干净，而不是自己学会了。这跟我 2017 年那个执念是拧着的。

那年十月，有人把答案摊在了桌上

BERT 出来的时候我正在做别的事。他们用双向的目标加上微调，在 GLUE 上把我们一起架到了火上。

刺到我的不是输赢，是那条路的天花板。如果继续在“预训练加微调”这根轴上比，比的是谁的标注数据用得更狠、谁的目标函数更巧——而这根轴的上限是人类愿意标多少数据。人手是有价格的，所以这条路往上走，会撞墙。

我当时的第一个想法特别没出息：把 GPT-1 继续做大，去 GLUE 上把他们掀翻。四层变八层，十亿变五十亿。

它死了三次，我每次都想救。

第一次死，是因为它不回答任何新问题。打赢只证明我们的工程量更大，不证明“语言模型学会了任务”。哪怕赢了我也说不出为什么赢。

第二次死，是因为算术。当时的共识是：机器学习系统要泛化（学会的东西能用到没见过的例子上），需要成百上千个训练样本。多任务训练里，一个“数据集加一个目标函数”就算一个样本——照这个数，要兑现多任务的承诺，大概也需要成百上千个这样的“对”。而那些最激进的两项工作分别只做到 10 个和 17 个。这不是方向选错了，是规模指标选错了：继续堆，就是拿人手去填一个指数级的坑。

第三次死，是因为它和“泛化”这两个字背道而驰。再做一个单任务、单域的模型，就是往我们诊断出的那个毛病里，再添一笔。

一个把整件事翻过来的说法

我那时候反复盯 GPT-1 的目标函数看，看到的是一件当时让我愣了一下东西。

先说直觉：监督学习和语言建模，用的其实是同一本教材，区别只在批改的范围。语言建模要模型把整段话的每一个

位置都猜对；监督学习只把其中一小段圈出来批改。

再说机制：语言建模的目标是最大化一段序列的联合概率，也就是每个位置上"下一个符号"的条件概率的连乘；监督学习的目标是最大化"给定输入时输出的条件概率"。后者是把前者的求和范围限制在一个子集上。范围缩小，不会改变函数本身，只会改变我们考察它的位置。

写成式子是这样（这一段论文里是有的，而且它是全篇最要紧的一步）：

语言建模：	$\max \sum_t \log p(s_t s_1 \dots s_{t-1})$	对所有位置 t
监督学习：	$\max \sum_{t \in \text{输出区}} \log p(s_t s_1 \dots s_{t-1})$	只对答案那几个位置

两式是同一条式子，后者的求和是前者求和的一部分。于是有一件事在数学上是通的：让整段概率最高的那组参数，也一定让答案区间的概率最高——语言建模的全局最优解，就是监督学习的全局最优解。

结论听上去很香：那我们不需要为每个任务设计目标，只需要一个足够好的密度估计。

它哪里不像：这条结论只保证"存在一个既会说话又会答题的解"，完全不保证"我们优化得到"。而这两件事的距离，就是这个项目后来全部的痛苦所在——我说过一句很重的话留在论文里：这条路走得通，但比显式监督慢得多。

第二幕·直觉：如果任务本身就是文本

本章论点：把"教模型做任务"这件事从流程里删掉，前提是把任务说明看成文本的一部分——这句话我起初读反了方向，读对之后整条路才通。

那句让我通的话，是别人写的，而且写出来的时候不是给我用的。

decaNLP 那篇工作里有一句：语言提供了一种灵活的方式，把任务、输入、输出都表示为符号序列。他们举的例子是 `(translate to french, english text, french text)`。

他们用这句话论证"可以做一个多任务模型"——我读成了另一件事：任务说明本身就是一段文本，那它就可以是训练语料的自然成分。

差别看似很小，性质完全不同：他们要多标十个数据集，我连标都不用标——只要网上有人写过"英语句子 = 法语句子"。

先把这张地图画出来：我在哪儿，谁站在旁边

我不敢凭印象说"没人做过"。动手之前我把这块方向队伍数了一遍，分成四派：

- **A 派**，表征迁移——word2vec、GloVe、CoVe、ELMo 这一串。做法是把无监督学到的表示搬给下游任务。这一派的死穴是：搬过去的只有表示。ELMo 到了下游还得自己叠一层 BiLSTM 和注意力——也就是说无监督学到的东西只负责输入层，真正做判断的仍然是标注数据现场学。我把它归为"更好的初始化"，不是"自己会做任务"。
- **B 派**，预训练加微调——我的出生地。Dai & Le 2015、ULMFiT、GPT-1，还有 BERT。我的架构、优化器、训练配方几乎全是继承来的，这一点我不否认。但这一派每一篇的进展都可以被读成"如何更省地用标注数据"，而不是"可以不标注"。论文里我把这句写得很直白：这些方法仍然需要监督训练才能执行任务。
- **C 派**，显式多任务——decaNLP、One Model To Learn Them All。半个亲生：它给了我"语言可以描述任务"这把刀，但它的任务描述是人为发明的控制码，我的任务描述是语料里本来就有的自然文本。差这一步，性质完全不同：它造数据，我找数据。
- **D 派**，单点突破——Weston 2016 的对话学习、Schwartz 2017 的常识推理、Karpathy 2015 从 RNN 里读出来的可解释单元，还有我自己 2017 年那个情感神经元。血最亲的一派。但这派全是单任务、单数据集的定性观察，没有一篇做过系统评测——所以谁也说不清"这是普遍现象"还是"这是运气好"。

四派摆在一起，那个空位就清楚了：没有人把"不用微调、不预设任务"这件事，放到一个足够大的语料和足够大的模型上系统测过。我要占的就是那个空位。

一个让我在屏幕前坐了一会儿的发现

我本来准备在论文里写一句"零样本任务迁移是空白"（零样本：不给这个任务的任何训练样例，直接让它做）。写之前我去查了 Winograd Schema Challenge 的榜。

Trinh & Le 2018 已经用语言模型做过了，而且没在 WSC 上训练过。他们的做法是比较两种消解里哪个概率更高——这就是零样本任务执行，跟我打算做的事在性质上是同一件。

如果这件事已经有人做过，我那篇文章的第一句话就不成立了。

最后是两处细节救了我。

第一处是他们的语料。他们的最好结果建立在一个"小样本的 Common Crawl 子集"上，而这个子集的筛法是"只保留与目标数据集最相似的文档"。我盯着这句看了很久——这说明他们已经把任务知识预先注进语料里了，那是一个为 WSC 量身定制的语料。要是我能把语料做得完全不带任务偏好、还能赢，性质就完全不同。论文里我写下的那句话是：我们要避免预先对任务做假设。这句话表面上是方法论，实际上是我被抢先之后画的那条界线。

第二处是他们只做了一个任务。一个任务分不清"语言模型普遍会做任务"和"语言模型的某条路径恰好撞对了这一个"。要证明前者，就得换很多任务、换很多数据集——而这一点恰好是我唯一有优势的地方：我有容量，也有语料。于是"广度"成了我的护城河。后来论文里那七个任务探针，根子就在这个下午。

我为什么敢赌网上真的有这种东西

我不能只靠"网上什么都有"这种印象。当时我找到的依据是 Weston 那篇对话工作：他证明了不给奖励信号、直接靠"预测老师会说什么"也能学会一个问答任务。但他被"对话"这个设定框住了——需要有人陪你聊。

我的判断是：互联网上的信息是被动可得的，不需要交互。有人在网页里写"她是法国人，她说 Je ne suis pas un imbécile"，这条网页本身就同时包含任务说明、输入和输出。

它哪里不像：网页里的人是主动在理解和表达，模型只是在拟合条件分布。它可能学会的只是"翻译这件事的表层模式"，而不是翻译。这个疑问后来变成论文里整整一节（第四幕细说），而且它没有被彻底消掉——只能被压缩到一个很小的比例里。

顺手先把"字怎么进模型"这件事定了

这一路最容易被忽略、但工作量最实的是输入表示。我在这里死了两次。

第一次死：按码点做 BPE。（码点就是每个字符在电脑里的编号。）要覆盖全部 Unicode，基础词表就得超过 13 万——而当时 BPE 常用词表是 3.2 万到 6.4 万。代价不是钱，是分配：多出来的七万多个槽位本来可以装词。

先说直觉：BPE 就是把频繁一起出现的小单位粘成更大的积木——先有字母，粘成常见片段，再粘成词。词表就那么大的话，粘什么、不粘什么，决定了模型的"容量预算"花在哪里。

再说机制：它从最小单位出发，反复找出现频率最高的一对邻居，把它们合并成一个新单位，记进词表；重复到词表满为止。之后任何文本都按同一本词表切成块。"常用"在这里的定义就是出现次数多。

它哪里不像：频率高 ≠ 语义重要。按纯频率走，"的""the"这类会先被粘成整块，而"熵""不可约"这种信息量高的词反而被切成碎片。BPE 选择的是压缩效率，不是语义单元——它本来的目的就是把文本压短。

第二次死：干脆全部按字节来。字节级天然满足"任何字符串都能算概率"这个要求（别人 2015 年就做过），但字节级语言模型在大规模数据集上打不过词级模型——文献这么说，我自己在语料上重跑也看到了同样的差距。这是"文献说不行、我也验证了不行"的双重死刑。

活下来的版本是字节级 BPE：基础词表只有 256 个字节，然后在字节序列上做合并。但直接合并不行——我实测发现 dog、dog.、dog!、dog? 各自占了一个槽位。原因是 BPE 只看频率，不看它在什么位置出现。

修法是禁止跨字符类别合并：字母归字母、数字归数字、标点归标点，不许粘到一起。例外是空格——给空格开这个例外以后，压缩效率显著提升，而带来的词碎片化极小。这一条是全文少数给了"代价—收益"对比的设计，所以它是我记得最清楚的一条。

它哪里不像：这条"不许跨类"的规则自己就带着例外，说明它是一条工程妥协，不是一条原理。词表最后定在 50257 个。

到这里，输入修好了。但"答案在哪"这个最要命的问题，一点没动。

第三幕·试错：这一阶段真正的工作量在删东西

本章论点：从第一版到最后一版，我删掉的东西比留下的多；而每一个被删掉的版本，死因都比活着的版本更值得

记。

这张桌子上不止我一个人

论文首页有六位作者，前两位标星号、末两位标双星号，脚注写的是“同等贡献”。也就是说四个人被标为同等贡献，中间两位没有标记。这个结构本身就说明：这不是一个人写的故事，四条线都有话语权。

我把当时的账本摆一下：我这一本记的是“做出一个别人没做过的东西”，愿意为一句说不清能不能成的话烧掉几个月；资深作者那一本记的是“故事线站得住、发布不翻车”，他管我叙事的一致性；其余几位的账最杂——除了工程和算力，还多出一本“这东西放出去会不会被滥用”的账。他们的天然动作是砍 **scope**。

所以下面被砍掉的东西，都不是因为它们错，是因为没人手、没算力，或者怕风险。

被砍掉的两样（不是因为它们错）

第一样是多语言。这刀砍得最疼。我原来的想法很直白：“语料越杂越好，那多语言当然更杂。”被砍的理由不是学术，是分析成本：语料里一旦混进多语言，所有单语评测集的重叠分析和困惑度（困惑度衡量模型对下一个词的把握有多差，越低越好）口径都得重做一遍。最后一刀切，主动移除全部非英语网页。

这个砍法后来以一种很讽刺的方式回到了论文里（第四幕细说）：那台语言检测器发现，法语只残留了 10MB。而正是这 10MB，成了“完全没教过翻译、却冒出 11.5 BLEU（BLEU 是翻译质量的打分，越高越好）法译英”这一结果的解释材料。被砍掉的方向没有消失，它以证据的形式回来了。

第二样是把整套权重和语料直接开放。一开始的默认计划是全开——上一代就是这么做的，代码和数据都放出去了。这次被砍的理由不是工期也不是算力，是误用风险。最后的形态是分阶段的：先放小模型，最大的那个压着。论文里唯一那句关于开放的承诺，用的词是“小模型”——它是全文唯一一处模型开放承诺，而那个“小”字本身就是这次决议留下的痕迹。

我想强调这条的性质：它不是实验做得不够，是一次主动的、不可逆的自我限制。

v0：把微调那一刀砍掉

第一版的做法朴素到没什么可说：GPT-1 的流程是「预训练 → 拍平成序列 → 加线性层 → 微调」，我把最后两步直接删掉，只留「预训练 → 拍平成序列 → 采样」。任务是文本，就写一段，让模型接着写，从写出来的东西里取答案。

它有三个毛病，一个我当时就看得见，两个是后来才看清的。

看得见的那个是效率：预备实验里已经显示，足够大的语言模型确实能做这种玩具式的多任务学习，但比显式监督慢得多。慢意味着必须用规模和时间去换——这一条后来决定了整个项目的形态（第四幕）。

后来才看清的第一个是接口：模型续写的是网页文本的分布，不是答案的分布。它给的东西可能完全合法、完全通顺，但不在我要的位置上。这个道理，我是几个月后在 LAMBADA 上（一个要求猜出段落最后一个词的测试）才彻底看明白的：模型给出的大多是句子的合法续写，而不是合法的最后一个词。

这句话我后来写进了论文，因为它说明的不是“模型不会”，而是模型没有被告知“这里要的是那个词”。

后来才看清的第二个是防线：如果模型只是把语料里见过的问答原样背出来，那我做出来的东西叫检索，不叫零样本任务学习。这一层在 v0 阶段我甚至没有检验手段，只能把它挂成一根刺——结果它后来长成了一整节，而且成了这篇论文里我最自豪的一节。

至暗时刻：深层的模型训不起来

这一段持续了大概六周，是我在这个项目里最没底的时候。

模型往上堆层数，浅的几档还能出曲线，深的一上来就发散；学习率压得很小能稳住，但损失降得比浅模型还慢。换句话说，加参数没换来收益，只换来了不稳定。

我当时判断“该救还是该弃”的标准只有一条：这是超参问题还是结构问题？判它是结构问题，理由很直接——学习率调小能稳住，说明不是数据问题也不是目标问题，是尺度问题：信息在残差通路上逐层累积，深层拿到的量级和浅层根本不是一个数量级。

对症下药的药方是三处改动：把 LayerNorm 挪到每个子块的输入（类似 pre-activation 残差网络）、在最后一个自注

意力块之后再加一层 LayerNorm、把残差层的初始化权重按 1 除以根号 N 缩放。

这里是这篇文章我要说的一句实话：这三处改动，论文里只写了做法，一句动机都没给。而三处里只有第三处能对上一句描述——“为了照顾残差通路上的累积”——另外两处，一直到今天我也不知道它们当初是为了解决什么才加的。我在复盘里把它们写成“对症状开的药方”，那是我的重构，不是记录。这是整轮复盘里风险最高的一处说法，我在附录里把它列为我自己写错的第 2 条。

v1：第二条腿是“把任务写进上下文”

输入修好了，效率问题靠规模换，但“答案取不出来”这件事一直卡着。我试过用后处理去解——被我否了，理由不是技术，是立场：只要加一层任务专用的后处理，我这条路的性质就从“语言模型自己会做任务”塌成“我教语言模型做任务”。那条腿一旦装上，整篇文章就没有了。

真正的转折不是某个模块，是我换了个念头：别让模型自己知道要干什么，我来告诉它——用文本告诉它。

既然任务是文本，那我就在推理的时候把任务写进上下文。论文里所有任务都是用同一个约定做的：

- 阅读理解：把文档、对话历史、最后一个 A: 一起喂进去；
- 摘要：文章后面加 TL;DR:，然后生成 100 个 token；
- 翻译：上下文给若干 english sentence = french sentence 的样例对，最后以英文句子加等号收尾；
- 问答：用问答样例对做种，帮它推断这个数据集要的是短答风格。

这就是最后一块拼图，我把它命名为：零样本不等于零格式。

先说直觉：考试允许你带一张写着题型的纸条，但不许带答案。纸条不算作弊，因为它不含答案；但纸条确实帮了你。

再说机制：模型没有为任何任务更新过权重——这一点严格成立，因为推理时一个梯度都没算。我改的只是喂进去的那段文本。而条件概率的定义本身允许条件任意长： $p(\text{答案} \mid \text{文档, 历史, "A:"})$ 和 $p(\text{答案} \mid \text{文档})$ 是同一个函数在两个不同输入上的取值，函数没变。

它哪里不像：纸条是我写的。写什么、写多长、用什么格式，都影响成绩——而“写什么”这件事本身是很强的先验注入。所以“零样本”这个词我用得很小心：论文标题里我用的是 `unsupervised`（指没有监督信号），不是 `zero-shot`。这不是措辞讲究，这是防守。

语料：从“多就是好”到“多且被人筛过”

最后一件事是数据，也是这个项目里唯一一次我自己的立场被自己的实验打回来。

一开始要的是 Common Crawl：免费、大到近乎无限。但第一批样本拉下来，满屏是不可读的文档。更要命的是，早就有别人公开抱怨过这件事，还写明了他们的解法：只保留与目标数据集最相似的文档。

这句话把我的路堵死了一半。如果连他们都认为“语料的域匹配”比“语料的量”重要，那我“靠量硬吃”这条腿就断了。

转折不是技术突破，是一次立场转换：从“多即是好”改成“多且被筛过才是好”。而筛的办法不能花钱——人工筛选整份网页爬取的成本是异常昂贵的——所以只能找现成的人类信号。

当时想到的是 **Reddit**：只抓取至少拿到 3 个 karma 的出站链接。那 3 个 karma 就是“其他用户觉得这个链接有意思、有用或者只是好笑”的替代信号。

现在回头看，这一条是整条数据轨的支点。它用一个免费的人类投票，替换掉了一道买不起的人工工序。它不是一个数据源选择，是一次工序替代——而论文里只写了做法，没有写这一层。

最后语料定下来是：4500 万条链接，去重加启发式清洗之后，略多于 800 万篇文档，40GB 文本，只保留 2017 年 12 月之前创建的链接。抽取用两个开源内容提取器组合。

这个 **40GB** 不是上限，是这一次的余量。两处独立的内证：论文里写了所有模型都还在语料上欠拟合，给更多训练时间困惑度仍在改善；而训练集和测试集的性能是一条线一起往上走的。规模没有到顶，是工期和算力到顶了。

一次“规避偏差，反而换个方向撞上去”的返工

我们赌的是“字节级输入，所以不需要任何有损预处理”。这句话当时我觉得很漂亮。

然后评测集从另一个方向咬了我们一口。那些下游数据集大多经过激进标准化，带着“断开标点与缩写、打乱句子”这

类分词痕迹，甚至出现 <UNK> 这个字符串——而它在我的语料里极端罕见，四十亿字节里只出现了 26 次。

结果是我得反向造工具：一个可逆的去分词器，把尽可能多的预处理痕迹还原回去。"可逆"这两个字是硬要求，不然数据集的对数概率就算不出来。论文里我把它称作"一种简单的域适配"。

这条的教训很硬：我为"不引入分词偏差"而放弃了分词，最后不得不为别人的分词偏差写一个逆向器。规避一个偏差不会消除它，只是换了个方向撞上去。

顺带说一个被我们主动删掉的候选：Wikipedia。删它的理由我当时觉得挺反直觉——不是因为它脏，是因为它太干净、太大众：它是许多数据集的共同来源，与测试任务重叠会让后面所有的分析变复杂。为了少一份分析上的麻烦，我们删掉了一个质量最好的数据源。

一根刺长成了一节：怎么证明它不是背出来的

这是我前面挂的那根刺。做法是：

先说直觉：把整座图书馆的每一本书拆成七个字的片段，全部倒进一个大筛子；之后拿一段新的话来筛，筛得到就说明它见过。

再说机制：这个筛子叫 Bloom 过滤器——它用一组哈希函数把每个片段映射到一串位上，只要一个片段的所有哈希位都是 1，就认为"见过"。它的特点是只可能误报"见过"，不可能漏报。我把误报率的上界压到一亿分之一，并生成 100 万个字符串做验证，命中数为零。

它哪里不像：它不能给你"零"，只能给你"小于一亿分之一"。而且判定单位是 8-gram，也就是八个词的连续片段——八个词相同不代表意思相同，也不代表模型是"背"的，它只是说明这段文字在训练语料里出现过类似的片段。所以这个工具能反驳"整段照抄"，但反驳不了"在语义层面记住"。这个界限，我在论文里是用"小但一致的收益"这种说法绕过去的。

筛完的结论分三层。

第一层，常用语言建模数据集的测试集，与我的训练语料的重叠大概在百分之三这个量级；而它们与各自训练集的平均重叠还更高一些（这条后来被核查抓住了两个反例，见附录）。

第二层，也是我最想让人看到的一层：我自己的模型生成的文本，与训练语料的重叠比那更低——中位数只有 2.6%，超过三成的生成样本重叠为零。换句话说，模型给出的东西，大多不是从语料里搬来的。

第三层是三个很小的、但我认为最漂亮的数字。我把重叠检查反过来用在最难的那个任务上：Winograd 的 273 个样例里只有 10 个与训练语料有 8-gram 重叠，其中 2 个还是假匹配，剩下 8 个里只有 1 个出现在"会泄露答案"的语境中。而 LAMBADA 上，把任何有重叠的样本剔除之后，困惑度从 8.6 只变成 8.7、准确率从 63.2% 只降到 62.9%。这不是漂亮的数字，是很小的数字——而这正是我要的那种数字。它说的是：那些分数不是从语料里翻出来的。这张重叠分布图是全篇最硬的"自证不是背"材料，但我把它放进了附录。这一点我在第五幕里要交代。

第四幕·定型与打脸：四档曲线，和三道墙

本章论点：我们赌的是"四档规模的完整曲线"，不是任何单个设计的作用——这个赌注决定了我后来挨的每一顿打，而且我认了。

那个把我从"报一个数"逼到"报四个数"的争辩

关于模型尺寸，团队里有过一次我至今记得的争辩。管算力的一方的账很简单：训一个 15 亿参数的模型已经很贵，训四个就是四份钱；而且如果 claim 是"零样本能做任务"，那报一个数、做出来就行。

我的理由不是学术，是逻辑：我的 claim 不是"能做任务"，是"容量是这件事的关键"。这个 claim 里"容量"是自变量，一个点画不出因果关系。只报最大的那一个，我说的每一句关于容量的话都变成不可验证的断言。

最后是条件性让步：报四档，尺寸近似对数均匀铺开，但不能再加第五个。这四个点后来撑起了全文三张主图，也撑起了摘要里那句"性能随规模对数线性改善"。

先说这个赌注的核心：容量是自变量

直觉：水深不到一百米，有些鱼就是不会出现。不是这些鱼笨，是环境没到位。

机制：语言建模的损失是“平均每单位文本的负对数概率”。当模型的参数容量相对于语料的复杂度不够时，它只能先把高频、简单的结构学好——语法、常见搭配。要它同时把“翻译”、“问答”这些低频结构学好，就必须先有足够的容量把这些结构分开存放。容量不够的时候，这些结构是互相冲突的，模型只能记住平均。所以这项能力看起来是“突然出现”的——它不是突然学会的，是容量跨过某条线之后，那些结构才第一次有地方放。

它哪里不像：水的临界点是常数，一百度永远是开水；模型的能力阈值不是常数，它随任务变化，而且有些任务越给容量越没用——这一点很快就被打脸了（见下面那道拆不掉的墙）。

打脸一：赢了 8 个里的 7 个，那个 1 是最大的数据集

结果出来是：刷新了 8 个语言建模数据集里 7 个的记录。LAMBADA 的困惑度从 99.8 干到 8.63，儿童读物测试拿到 93.3%（常用名词）和 89.1%（命名实体），Winograd 拿到 70.70%，比之前的最好结果高 7 个百分点。阅读理解上更漂亮：在不使用那 12.7 万条人工问答对的前提下，CoQA 上（一个对话式阅读理解测试）拿到 55 F1（问答类任务的打分，越高越好），追平或超过了四个 baseline 里的三个。

但那个 1，是最大的那个数据集。

One Billion Word Benchmark，我拿到的数是 42.16，而之前的最好结果是 21.8。不是我略输，是差了一个量级。而这件事最难受的地方在于它的方向：我全篇的主轴是“数据越多、模型越大越好”，结果最大的数据集反而最差。

这个反常我们按 bug 排查了很久。最后落到的解释是：这个数据集同时是最大的、也是预处理破坏性最强的——它做了句级打乱，而句级打乱移除了全部长程结构。

我们的长处恰好是长程依赖，这个数据集把我们的长处切掉了。

这不是一次被挽救的失败，是一次被理解的失败。代价是我必须承认：“规模越大越好”这句话有前提，而那个前提写在正文第三段，不在标题里。

打脸二：LAMBADA 的那两个数

这一段我打算讲得比论文里更直接，因为论文里我把它写得偏靠后。

LAMBADA 上我有两个数：不加任何后处理，准确率 **52.66%**；加一个停用词过滤器（把最常见的那些功能词排除掉），**63.24%**。而既有最好结果的记录是 59.23%。

也就是说：不加那个过滤器的我，没有超过前人。

那个过滤器在干什么？它只是把“答案必须不是虚词”这条约束近似了一下——因为模型给出的错误大多是“这是一句合法的续写，只是不是合法的最后一个词”。它不训练任何东西、不动任何权重，论文里我用的是“一种近似”这个词。

我到现在仍然坚持：这不矛盾。论文里那句“不改任何参数与架构”，限定的是参数和架构，不是解码过程——否则所有基于解码策略的工作都会被一并否掉。

但我承认审稿人指出的呈现顺序问题：我在正文里的写法是“从 19% 提升到 52.66%，再加过滤器到 63.24%”，读者沿路读下来会以为 59.23 这个对照不存在——可它明明就印在我自己的表里。这是编排上的回避，不是学术上的错误，而它同样不该发生。

打脸三：摘要只赢了随机抽句 0.42 分

摘要这个任务我从一开始就知道会难看。结果确实难看：

平均 ROUGE 是 21.40，而“从文章里随机抽三句”是 20.98。差了 **0.42**。而且只在加上 **TL;DR:** 提示的时候才勉强赢——去掉提示掉到 15.03，一次掉 **6.4** 分。对照组的 SOTA 是 32.75。

还有一处细节是在核查阶段才被挖出来的：在 **R-2** 这个单项上，随机抽三句（**8.63**）是赢我的（**8.27**）的。

它的失败形态不是“写不出摘要”，是“写出来的摘要关注错了地方”。论文里我留了几个具体的错误案例：模型会去纠结“车撞了几辆”“logo 是在帽子上还是衬衫上”这类细节，而把真正的主干丢了。这个诊断其实比分数重要，因为它指向的瓶颈不是容量，是目标错配——摘要的评分指标（ROUGE）数的是词重叠，跟“生成一段像人写的摘要”本来就不是同一件事。再加一个大模型不会改变这个诊断，只会多烧一次钱。

翻译更惨：英译法 5 BLEU，比用双语词典逐词替换还略差；法译英好一些，11.5 BLEU，比几个无监督基线强，但当前最好的是 33.5 BLEU。

而法译英这个 **11.5** 的来由，是整篇论文里我最喜欢的一个讽刺。

我们在内部争过要不要多语言，最后的决定是主动移除全部非英语网页——理由是分析成本。后来我跑了一个字节级的语言检测器，想确认一下滤干净了没有。答案是没滤干净：还残留大约 **10MB** 法语。

当时这是一条坏消息。写论文的时候它变成了证据：我们主动删掉了非语言数据，只因为没删干净那 **10MB**，模型就冒出了 **11.5 BLEU**。被砍掉的那个方向没有消失，它以证据的形式回来了。

打脸四：一个我一年后才发现的分母问题

问答任务上，我的模型在 Natural Questions 上答对 4.1%，而一个“不管问什么都答最常见答案”的极简基线是 1.0%。我在正文里写了一句：“GPT-2 多答对了 5.3 倍的题。”

一年后做核查的时候我才发现：**4.1** 除以 **1.0** 等于 **4.1**，不等 **5.3**。

5.3 倍的分母其实是最小那档模型自身的准确率，大约是 0.77%——而这个数字我根本没写出来。读者的眼前只有 4.1% 和 1.0%，只能拿它们相除。这是我的表述缺陷，不是口径差异。审稿人指出了它，我在回应里认了，然后在最终稿里没有改。

还有一道拆不掉的墙，和一道我自己撞出来的

拆不掉的那道是评测协议。LAMBADA 的前人最好结果是在“受限预测”下取得的：模型的输出被约束成只能从上下文里出现过的词里选。我照抄了这个设定——结果它在我身上起的是反作用：**19%** 的答案根本不在上下文里。

这个坑的性质很值得记：不是我的方法有问题，是“继承别人的评测协议”这个动作本身有风险。协议里可能藏着一条只在别人模型上成立的隐含假设。这个反例后来救了我——它把一件事从“我们不行”改判成了“口径不同”。

自己撞出来的那道是《丛林之书》。做儿童读物测试的数据重叠分析时发现，测试集里有一本书就在我的训练语料里。处理方式是放弃测试集、改报验证集。

这一条完全是我们没做功课。评测集清单一确定，跑一次 n-gram 重叠检查只需要几小时。而这件事的后果是：它催生了整篇论文里我最自豪的那一节（记忆与泛化的对照分析）。用一场事故换来一节方法论，净赚还是净亏，取决于有没有别人先替你付过学费。

一个我至今仍觉得很难看的数：CBT 那句“持续改善”

最后一处，是核查阶段从论文自己的表里挖出来的，而且是我自己论文里的错。

我在儿童读物测试一节里写了“性能随模型规模增大持续改善”。

但我的表里不是这样。常用名词这一列：87.65 → 92.35 → 93.45 → **93.30**。最后一步是往下的。也就是说，我宣称的那个“93.3% 的新记录”，低于我自己 **7.62** 亿参数那档的 **93.45**。

对外它仍然是新记录（压过了 85.7），对内它和我自己的话打架。这句话我写的时候是顺手的，表格里的数字是对的，中间那一步没人对。

第五幕·讲法：同一堆材料，怎么讲才卖得出去

本章论点：到这一步数据已经不会变了，能改的只有说法——而我在说法上做的每一个决定，都是在防守。

标题里那三个词，我改了很久

论文的标题是 `Language Models are Unsupervised Multitask Learners`。这个标题里有三个决定，每一个都是为了防守。

第一，主语是“语言模型”，不是“我们的模型”。换成“我们的模型不用监督就能学会任务”，一个现象级的发现立刻降级成一次产品发布。用复数主语，claim 的层级就从“我们做出来了”升到“这件事本来就成立，我们只是第一个把它说清楚的人”——顺手也降低了被指“夸大自研方法”的攻击面：我们没有自研方法，我们只是把规模推到位了。

第二，动词用 **are**，不用 **can be**。前者是断言，后者只是可行性陈述。

第三，我用的是 **unsupervised**，不是 **zero-shot**。三个决定里最关键的一个。因为整篇流程里明明有一个地方不零样本：我给每个任务都写了上下文格式。用“无监督”，描述的是“没有监督信号”，这一条完全站得住；用“零样本”，会被追问“你那几个前缀算不算提示工程”。选这个词的动机是防守，不是形容。

摘要放大了三样，藏了四样

放大的是三样。

一是开场那个体感最强的数字：CoQA 拿到 **55 F1**，而且紧跟着“不使用那 127,000 多条训练样本”。这是全文最强的一句，因为它把“标了多少数据”这个变量直接扣掉了。

二是一句能被反复引用的机制断言：容量对零样本任务迁移必不可少，性能随规模呈对数线性改善。

三是一个可数的事实：**8** 个语言建模数据集里的 **7** 个刷新了记录。

藏起来的是四样。

藏起 **LAMBADA** 的真实口径。摘要一个字都没提那个 63.24% 是靠停用词过滤器拿到的，也没提不加过滤器只有 **52.66%**。

藏起那个失败列。摘要把 7/8 说出来了，那个 1 是什么，要翻到后面才知道。

藏起摘要和翻译的真实水位。摘要只比随机抽三句高 0.42 分、英译法只有 5 BLEU——摘要里一个字都没有。

藏起“这是我们自己的口径”。非英语是我们主动删的，但法译英那 11.5 BLEU 被拿出来当正面结果；这层因果在摘要里不可能看到。

三句外交辞令，后来被人逐句拆过

第一句，把规模那篇经验分析拉来当护墙。审稿人的第一句话一定是“这不就是把模型做大吗”。我的做法是先把 Hestness 2017 那篇“深度学习里规模是可预测的”分析摆进来，再把自己定位成“该趋势在任务子集上与十亿参数以上的延续”。这样“做大”就不再是我的方法，而是一条已被确立的经验规律——我的贡献变成“这条规律的适用范围比想象中广”。同一句里我还主动认了个怂：“while much noisier across tasks”，把“我们的曲线不干净”提前说掉。审稿人提出来的第一遍是攻击，作者自己先说的就是坦诚。

第二句，把缺席的实验写成计划中的实验。论文最后一段有一句“我们计划研究 decaNLP 与 GLUE 上的微调”。这句话在博弈上的作用是双份的：对内部，它是“我们没忘，只是下一篇”；对外部，它是一道提前封口的胶带。而且我在这句里主动把最不利的可能性说了出来——我们的单向表征可能补不上——这样别人再提“你们没和 **BERT** 比”，就显得是在复述我自己的话。

第三句，抢在别人之前认怂两处。一处是把摘要里那个“前景可观”立刻压回“离可用还很远”；另一处更狠，是我自己拆自己的台：前面那个 55 F1 里，有一部分是靠“问谁就从文档里挑个人名”这种检索式启发式拿到的——这一句我写进了正文。在公开场合主动交出这一点，比被人查出来代价小得多。

还有一句我处理得很轻：对那篇抢先的工作，我一句批评都没写。我只把他们的做法称为“务实”，然后声明我们想避免预先假设任务。把一次分界说成一次取向差异，把他们语料里带任务偏好这件事留给读者自己补。

哪张图放主文，哪张塞进附录

主图给了“多任务零样本性能随模型规模变化”那张网格图。它的选型逻辑很清楚：它同时承载三件事——曲线向上（容量假设）、任务横跨阅读理解翻译摘要问答（广度）、以及有些任务的绝对水平很难看，但趋势线是正的。反过来说：它是最有效的一张能让“我们表现很差的任务”为论文加分的图。那个任务单独出现在正文里就是失败；放进这张网格图里，它变成“容量是自变量”的证据。这是整篇排版上最聪明的一处。

主表十列并排放。列数本身就是一层遮蔽：那个失败的数据集被放在最右边一列，与七个成功列并排时被视觉稀释。如果它单独成表，它就是这篇论文的一个洞。

摘要那张表留在主文，但只用它的差值。正文引用的是“去掉提示后掉 6.4 分”，不是那个 21.40 的绝对值——差值证明了“任务提示能召唤任务行为”，绝对值只会告诉读者我们打不过专门的摘要模型。

而那张最硬的自证图，被我放进了附录。就是第三幕那张重叠分布曲线。理由我当时没写下来，但逻辑是清楚的：把它放正文，等于把“我们可能是在背”这个问题提到台面上讨论；放附录，它就在那儿，但不引导读者去想。这是一次有意的降噪。

第六幕·反思：我留在这篇论文里的最大问题

本章论点：一年后回头看，这篇论文最大的问题不是我算错了什么，是我有一整套设计，从一开始就没打算证明它们

各自有用。

整篇没有一张消融表

上一代那篇（GPT-1）里，我有一张逐任务的微调消融表，所以每个“某组件救了我”的说法都能对着差值行被验一遍。

这一篇一张都没有。

改动列了四处：归一化位置、末端再加一层归一化、残差层初始化按 1 除以根号 N 缩放、上下文从 512 提到 1024 并把 batch 提到 512。这四处里，哪些真的起了作用、哪一条是顺带加的，这篇论文永远没有回答。

最接近消融的只有两处，而且都不算消融：去分词器只给了“2.5 到 5 的困惑度增益”这个区间、没有对照表；摘要那节的“去掉提示”是全文唯一一处能做逐格差值的单变量对照。

为什么不做？诚实的原因是：我赌的是那四档曲线本身，不是任何单点消融。我认为“容量是自变量”这件事一旦被曲线画出来，单个设计有没有用就不重要了。

这个赌注让我付出了代价。如果审稿人问“那三个 LayerNorm 相关的改动到底哪个有用”，我至今答不出来——我在第四幕说的“药方”，有一半是我事后把日志和改对起来的，见附录。

我把它写成“结构性缺口”而不是“我们的疏忽”，不是美化：把它说成疏忽就等于承认“我们本来能补”。真实情况是，做这篇论文的时候我根本不认为这些设计需要单独证明。

我们确实被人往死里审过——只不过不是在会场里

这一篇从来没有经过正式的同行评审。它是一份技术报告，真实的把关发生在两个地方：投稿前的内部草案反馈（致谢里列了四位给过意见的人），以及发布前的误用风险评估。

我让一个完全没有看过我任何内部记录的人，只拿着论文本身审了一遍。他给了三条 major weakness 和两条 minor，总评是弱拒。三条里：

- **LAMBADA** 那条（依赖任务特定后处理）我部分力争——零样本界定的是权重，不是解码；但我接受把 52.66% 和 59.23% 的对照提到前面。
- 摘要那条（把定量上只比随机抽句好 0.42 的任务和真正的 SOTA 并列）我接受。
- **5.3 倍**那条我完全认错。

然后我写了回应。核查阶段把我那份回应逐条对到最终稿上，结论是：五条可以落地的修改承诺，零条完全落地，一条部分落地。

这个统计我觉得比论文里任何一个数字都更能说明问题：在一份技术报告里，回应意见不是修改流程的一环，它是一次“说完就完了”的表述。原因有三条，前两条查得到（没有程序委员会来催终稿；论文的核心叙事不依赖任何一条被质疑的地方），第三条是我更愿意承认的——那五条里四条都只是“补一个数字”，而我当时更想赶在发布窗口前把实验收尾。

核查阶段挖出来的一件事，比我自己写的错更值得记

我让两个互不相通的人做核查。一个的角色是“我会怎么攻这篇论文”，另一个的角色是“把每张表逐行做差值”。

结果是：一共 11 类发现，两者的交集只有 2 类。攻击型的那个人找到了 LAMBADA 的界定问题、摘要的水位问题，但完全没发现儿童读物那列的单调性断裂；差值的那个找到了单调性断裂、重叠表的两个逐列反例，但完全不会去问“这个词用得是否过头”。

两类都漏了一处：论文里 **CoQA** 的域数，在第三节说 7 个、第四节说 5 个。

这条经验我打算一直用下去：核查不是一件可以委托给一个人的事，因为注意力框架本身就决定了你会看见什么。

我自己写错的十条

核查阶段把我这份复盘里的实质判断逐条拿去对论文，查出十条有问题的：一条是与论文事实直接矛盾（我把“论文没给动机”写成了“论文没有任何引用”——论文对其中一处是给了引用的，这跟我当年犯的另一类错一模一样：把“我没注意到”写成“论文里没有”）；三条是程度过头或论据来源错位（包括我在第四幕说的那三处“药方”、以及我凭印象描述的一张图的曲线形态）；六条是“标签贴对了、话却说太满”。

和上一轮相比，最硬的错从 2 条降到 1 条，但“话说过头”这一类的绝对数量没有下降。这句话是我对自己这套工作方法最诚实的一次评价：标注能挡住“编事实”，挡不住“加着标注把话说满”。

最后：哪些是读论文原文绝对学不到的

分三层，我把性质标清楚。

第一层是论文里只留了痕迹、没留理由的决策。3 个 karma 不是“选了个数据源”，是用免费的人类投票替换掉买不起的人工工序；四档尺寸不是“顺手多训了几个”，是“容量作为自变量”这个 **claim** 的必要代价；末尾那句微调承诺不是研究计划，是防御性安排（它的位置在全文最后一段、形式上只有一句）。这一层的做法是史实，理解是重构。

第二层是过程里真实的判断和失败。第一版“答案是合法续写但不是合法末词”、一度让我考虑退回微调；1BW 失败曾按 bug 排查；回应意见五条零落地。这一层全部是重构，依据逐条记在文末章末注里，不能当史实引用。

第三层是这次复盘独有的产物。我自己的误差基线（约 55 条断言里 18.2% 有问题）、两个核查视角发现集合几乎不重合、以及论文自身的六处问题——其中儿童读物那列的单调性断裂和 CoQA 的 7 域对 5 域是硬冲突。

而这里面最出乎我意料的一条是：这篇论文摘要级的数字（7 个里面的 7 个）是对的，但它用来概括自己表格的那句话是错的。

写论文最难的地方大概就在这儿——你最容易搞错的，从来不是你算出来的数，是你为了让别人好懂而顺口写下的那半句概括。

章末注（重构点留痕，每条一行：哪个判断、依据是什么）

1. 2017 年情感神经元作为动机主线——依据：作者公开研究轨迹的连续性；该文不在 GPT-2 参考文献表的闭环内核验，属论文外材料。
2. 时间点设为 2018 年 10 月、触发场景为 BERT 公开当周——依据：参考文献时间差与论文中 BERT 的对标位置。
3. “标注数据的成本是这条路的天花板”这一第一动机——依据：论文把“采集数据集与设计目标的规模化困难”列为动机主轴，但未写成第一人称动机句。
4. 三条 naive 想法的次序与死因——依据：论文对多任务对数规模的算术批评、对“不预设任务”的定位。
5. “先试字词级 BPE、再试纯字节级”的顺序——依据：按致命程度重排；论文实际叙述序与此相反（见附录第 3 条）。
6. 深层的三处改动对应“训不稳定”这一症状——依据：仅“残差通路上累积”一句可作半锚点，另两处零锚点；重度重构。
7. 在推理时把任务写进上下文是“最后一块拼图”——依据：四处任务格式在论文中承担了零样本 claim 的全部实现。
8. 语料来源之争的翻盘台词——依据：论文从“拒绝 Common Crawl”直接跳到“只用人类策展的链接”，中间取舍痕迹由此补出。
9. “3 个 karma 是一次工序替代”——依据：论文同时写了“人工筛选异常昂贵”与“karma 是他人觉得有趣或有用的启发式指标”两处。
10. 40GB 是工期余量而非算出的上限——依据：两处独立的“仍欠拟合”表述。
11. “把生成样本与训练语料的重叠图放进附录是有意降噪”——依据：该图的存在性与所在位置（附录）。
12. 摘要任务的失败“补实验也没用”——依据：论文把该任务的失误形态诊断到具体细节层面，瓶颈指向解码目标与生成式输出的错配。
13. 回应意见的承诺普遍未落地归因于技术报告的流程性质与发布窗口——依据：前两条原因可由论文形态查证，第三条为重构。
14. 两个核查视角的注意力差异解释为“观察框架不同”——依据：两者独有发现的重合度统计（交集 2 / 共 11 类）。
15. 至暗时刻的时间跨度与心理活动——依据：由三处改动的症状侧反推，属重型重构，不可当作史实。
16. “改动的动机有一半是事后把日志和改对上的”——依据：论文对这些改动零动机句。
17. 四档尺寸之争的具体争点与让步形态——依据：论文“四个、近似对数均匀”的措辞与“尺寸不能再加”的隐含边界。
18. 团队账本的三分法与“天然动作是砍 scope”——依据：首页四位同等贡献标记的分布与致谢中的算力依赖；账本内容为重型重构，论文无任何第一人称立场记录。

19. 分阶段发布的动机是误用风险、"small"一词是决议痕迹——依据：论文脚注 5 只承诺公开小模型，以及论文外公开的分阶段发布事实。
20. 删 Wikipedia 的理由是"太干净太大众"——依据：§2.1 原句写明移除理由是它是许多数据集的共同来源、重叠会复杂化分析；把"太干净"读成痛感属重构。
21. 标题三个词各自的防守功能——依据：论文全文以复数主语陈述一般性结论、四处任务格式均需人工书写；作者动机为重构。
22. 摘要"放大三样、藏起四样"的取舍清单——依据：Abstract 三处表述与 §3.1、§3.3、§3.6、§3.7 之间的信息缺口对照；取舍动机为重构。
23. 三句外交辞令的功能定位（护墙、胶带、提前认怂）——依据：§5、§6、§3.5、§2.1 四处原句的措辞与位置；功能读法为重构。
24. 排版决策（网格图容纳低分任务、十列并排稀释失败列、只用摘要表差值、自证图进附录降噪）——依据：各图表的结构、位置与正文引用方式；动机无原文，属重构。

附录 · 勘误与对照（原核查报告压缩版）

A. 我自己写错的十条（按严重程度）

#	错误断言	实况	严重度
1	论文的架构改动"没有任何引用"	其中一处明确引用两篇文献	P0（与论文事实直接矛盾）
2	"那三处改动就是对症状开的药方"	三处中仅一处有半句描述性依据，另两处零依据	P1
3	在第一版的死因里写出了"后来它长成了一整节"	在明令不得预知论文形态的阶段里泄漏了未来章节	P1（后见之明泄漏）
4	凭印象描述了一张图的曲线形态	该图无法从文本核验，真实依据是正文水平	P1（论据错位）
5	"BERT 是唯一被当作对标对象引用的同期工作"	另有两篇同期工作被引用	P2
6	宣称两条死路的顺序"接近论文叙述序"	实际叙述序与此相反	P2
7	原样照抄了论文的"1–6%"重叠区间	表内实际区间是 0.88%–6.31%	P2
8	把"5.3 倍"的分母擅自补全	论文未写明分母	P2
9	两处"唯一"	另有图表具备同样性质	P2
10	"数据集被前人净化过"	论文归因于数据集自身的激进标准化	P2

误差基线对照：约 55 条实质断言中，P0 + P1 + P2 合计 18.2%；其中 P0 仅 1 条（1.8%）。与上一轮相比，P0 从 2 条降到 1 条，但"话说过头"这一类没有下降。

B. 论文自身的六处问题（不是我写的，是核查算出来的）

#	论文的概括句	反例（精确数字）
R-1	"性能随模型规模增大持续改善"	常用名词列 762M→1542M： 93.45 → 93.30 （下降 0.15 ）；且宣称的 93.3% 低于同表 762M 的 93.45
R-2	测试集与训练语料重叠"在 1% 到 6% 之间"	实际 0.88% （PTB）到 6.31% （enwik8）（平均值 3.2% 无误）
R-3	"许多数据集与自身训练集的重叠更大"	两个反例：WikiText-2（0.66% < 1.63%）、text8（2.34% < 3.94%）（平均值 5.9% 无误）
R-4	摘要"仅仅比随机抽三句好一点"	聚合指标成立（21.40 > 20.98，差 0.42），但 R-2 单项反例： 8.27 < 8.63
R-5	"在 Penn Treebank 这类小数据集上有大幅提升"	小模型 117M 在 PTB 上是 65.85，劣于既有最好结果 46.54
R-6	第三节称 CoQA 含 7 个域，第四节称开发集指标在 5 个域上取平均	论文内部两处域数不一致，两个核查视角都漏了

C. 覆盖度缺口（论文有、阶段叙事没用上的）与成稿的补法

△ 这一节的“缺口”指的是阶段叙事正文（S1–S8）的缺口。成稿（本文正文）允许跨阶段取材，故必须逐条声明是否补上，否则本节会与正文口径打架。

#	阶段叙事的缺口	成稿是否补上
1	主表的完整数值矩阵（十列乘四档）从未被完整吸收——本轮最大缺口	✗ 未补（成稿只用了 8.63、63.24、93.3、89.1、42.16 五个格）
2	最自信那 30 条答案的表，除了“最有信心 1% 上 63.1%”这一个数之外从未被使用	✗ 未补
3	生成样本与训练语料的重叠分布图（中位数 2.6%、超过三成样本零重叠）从未被吸收——它是全篇最硬的自证材料	✓ 第三幕已补（含 273 / 10 / 2 / 1 与 8.6→8.7、63.2%→62.9% 两组剔重叠复算）
4	附录里的摘要失败案例、翻译样例、阅读理解实例从未被吸收；尤其摘要那一节，论文用具体错误案例做了诊断，而复盘全程只用了 ROUGE 数字	△ 部分补（第四幕补了摘要的错误形态，翻译样例与阅读理解实例仍未用）
5	儿童读物一节“已追平人类表现的大半”这一说法未被使用（人类基线未被引入）	✗ 未补
6	论文全部五张图无法从纯文本核验，只能借图注与正文旁证——这是数据源的物理限制，不是叙事的疏漏	△ 成稿在章末注第 24 条与“论据来源”处一律声明，不假装看过图内形态

一处“漏得正确”的例子：阶段叙事与成稿都从未复述 R-1 那句被证伪的单调性概括。漏掉论文的一个错误，反而避免了把它抄进自己的稿子——缺失与错误是两码事。

一处“补得对但越了界”的例子：第 3 条是阶段叙事漏掉、成稿单方面补上的。这属于跨阶段取材，性质上比“从 S1–S8 改写”多走了一步——它让成稿比它的素材更完整，但也意味着成稿里的这一节无法在阶段叙事中逐字回溯。

D. 隔离审稿专项

- 三条 major weakness 的全部数字逐条复验成立；两条 minor 成立。
- 唯一失准处：把一句只在第一节出现的表述说成“摘要与第一节反复强调”。
- 他自己数的那张表是 22 对 8 错（30 条），与另一位核查者的 21 对 9 冲突；机器按符号码位复核为 22 对 8 错。
- 我那份回应的 5 处引文与落地对照表的 5 处引文全部零悬空；“5 条承诺 0 条完全落地、1 条部分落地”的统计成立。
- 隔离合规：两位核查者的输出中都不含任何内部记录术语。

外行闸记录（模板第 6 条）

做法：抽三段——第四幕·打脸二（LAMBADA 的那两个数）、第二幕·字节级 BPE 的直觉层、第五幕·摘要放大三样藏四样——交给一个隔离子代理：只喂这三段的原文，不喂论文、不喂任何《档案》、不喂本文其余部分。它的角色设定是“聪明但完全没有机器学习背景的外行”，并被告知：答错说明写作者写得不够外行友好，请如实说“我没看懂”，不要编一个听起来合理的答案。

结果：三段的复述与两道理解题全部答对（3/3）。包括三处最容易讲糊的地方——“什么时候算超过前人、什么时候不算”、“词表大小为什么是一种代价、代价花在哪儿”、“为什么扣掉‘标了多少数据’会让结果显得更强”。

但它同时交出了一份很长的“只能靠上下文猜”的词表：LAMBADA、停用词与虚词、权重与参数、架构、解码过程、码点、Unicode、熵、语义单元、困惑度、F1、BLEU、零样本、对数线性、口径。也就是说：故事线与因果过关了，术语裸用没过关。

处置：对八处首现术语补了括号内的一句话释义（泛化、零样本、码点、困惑度、BLEU、LAMBADA、F1、停用词）。没有补的是基准名（CoQA、Winograd、1BW）与“对数线性”这类只在语境里起修饰作用的词——给每一个专有名词都加释义，会把文章变成词典，得不偿失。

诚实结论：这一关只能证明“外行能跟上故事与因果”，证明不了“术语已经不构成门槛”。GPT-1 首跑的外行闸是 3/3 不合格，这一轮是 3/3 合格；但两次暴露的是同一个毛病，只是这次没有烂到影响理解。

【阶段】S9 成稿（面向外行的第一人称长文）

【已知事实】

1. 本篇全部带数字的事实均可回溯到论文原文，依据见正文与章末注
2. 全文按六幕故事弧重排（问题 → 直觉 → 试错 → 定型与打脸 → 讲法 → 反思），不按 S1 到 S8 的时间线
3. 分支：本篇在正文中保留了全部负面硬数字（LAMBADA 无过滤器 52.66%、摘要只赢随机抽句 0.42、1BW 42.16、En→Fr 5 BLEU、CBT 那列 93.45→93.30），一个都没删
4. 成稿含《档案·S9》之前的三个附件：章末注、附录《勘误与对照》、外行闸记录；三者都不计入正文篇幅

【合理重构】

1. 二十四处重构点已在章末注逐条留痕（哪个判断、依据是什么）；其中第 6、15、16 条属重度重构，风险最高
2. 行内标签已按模板转为语气承载（“我记得”“我当时猜”“这一点论文里没写”），可核验性由章末注承接
3. 新增的七处重构（第 18–24 条：团队账本、分阶段发布的动机、删 Wikipedia 的痛感、标题三词、摘要取舍、外交辞令、排版决策）只有“做法/位置/措辞”这一层史实，动机层是重构，已在章末注逐条标注

【负结果】

1. 负结果占比：第三幕（试错与被砍 scope）、第四幕（打脸四连 + 一道拆不掉的墙）、第五幕（藏起来的四样）、第六幕前半（无消融表 + 零落地的回应）合计为全文主体，估算约 50%
2. 篇幅比：正文汉字 13058，基线（S1 至 S8 叙事正文，含 S8）19497 汉字，比值 67.0%（模板要求 60–70%）；漏掉 S8 会把同一稿件算成 84.3%，按字符数算只有 40.2%
3. 外行闸：抽三段由隔离子代理复述并答理解题，首轮 3/3 通过（GPT-1 首跑为 3/3 不合格）；但外行仍列出一长串只能靠上下文猜的术语，已对八处首现术语补释义，其余基准名不补——详见上方“外行闸记录”
4. 本篇未写入论文自身六处问题之外的任何新指控；六处问题全部有精确数字支撑

【未决问题】

1. 三处类比（水温、筛子、题型纸条）中，“题型纸条”一条的边界最模糊，可能需要在下一轮重写为更强的限定
2. 章末注第 6 条（三处改动与“训不稳定”这一症状的对应）在成稿中仍以叙事语气出现，虽已声明是重构，但语气强度高于证据强度——这是本篇留下的最大残余风险
3. 跨阶段取材：附录 C 第 3 条（生成样本重叠分布）是阶段叙事漏掉、成稿单方面补上的。它让成稿比其素材更完整，但也意味着这一节无法在 S1–S8 中逐字回溯——本轮选择保留并显式声明，下一轮应改为“先把缺口补进 S4/S8，再写 S9”

【一致性自检】本篇与 S8 的三张表无冲突：幻觉清单十条已压缩入附录 A，第 1 条 P0（“没有任何引用”）在正文与附录中只以改正/勘误形态出现（机器检索命中 2 次，均在改正语境）；论文自身六处问题在正文第四幕明写“这是我自己的错”，与附录 B 一致。迷你 S8 机器核查（口径：排除《档案》块自身，因为它会把关键词自己数进去）：S8 的 P0 指纹“没有任何引用”命中 2 次、两次都在改正/勘误语境（正文第六幕的自陈 + 附录 A 第 1 行）、未以断言形态复活；“几乎平的曲线”命中 0 次（论据错位的原句未复活）；新增内容里的每一个数字都已在 gpt2.txt 中核到原样出处（30% 零重叠与 2.6% 中位数、273/10/2/1、8.6→8.7 与 63.2%→62.9%、10MB 法语、26 次 `<UNK>`、6 位作者与四位同等贡献）。

【后见之明自检】本篇按模板定位为“项目结束一年后”的回顾，允许引用结果；但重构与史实的边界已在章末注逐条声明，未把事后解读写成作者自陈；“它后来长成了一整节”一类表述均带“后来”这一显式时间标记，不冒充阶段内的判断。