

GPT-2 科研全仿真

Language Models are Unsupervised Multitask Learners (Radford et al., 2019)

目录

- S0 · 选材阐 —— GPT-2 科研全仿真
 - S1 · idea 诞生 —— GPT-2 科研全仿真
 - S1.5 · 内部博弈 —— GPT-2 科研全仿真
 - S2 · 文献调研 —— GPT-2 科研全仿真
 - S3 · 建模迭代 —— GPT-2 科研全仿真
 - S4 · 数据 + 实验（双轨）—— GPT-2 科研全仿真
 - S5 · 困难与转折 —— GPT-2 科研全仿真
 - S6 · 成文 —— GPT-2 科研全仿真
 - S7 · 审稿 + rebuttal —— GPT-2 科研全仿真
 - S8 · 对照复盘（幻觉总检查）—— GPT-2 科研全仿真
- 语言模型自己会做任务，这件事我用了半年才敢说出口

口径三段式 - 目标：判定《Language Models are Unsupervised Multitask Learners》（Radford et al., 2019）是否适配本仿真流水线，给出放行/拒绝结论与理由。 - 现状：论文全文已入库（24 页，含 Appendix A 生成样本 Table 7-17）。无上一阶段档案。 - 限制：只做防御性检查，不做叙事；不放行就终止，不"带病推进"。

论文基本信息

项	内容
标题	Language Models are Unsupervised Multitask Learners
作者	Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, Ilya Sutskever（OpenAI，San Francisco）；首页以星号标注前两位与末两位共四人同为"同等贡献"【可查证：论文首页作者行与脚注"Equal contribution"】
形态	技术报告 / 预印本，24 页；非会议投稿（无 venue、无 camera-ready 信息、无审稿致谢）【可查证：全文无 venue 字段；Acknowledgements 唯一列出的反馈人是四位草稿读者】
发布	2019 年 2 月 14 日【可查证：论文外：OpenAI 官方博客与该仓库发布时间；论文文本本身不含日期】
核心 claim	语言模型在零样本、不改任何参数与架构的前提下即可执行下游任务；容量是这一能力的关键【可查证：Abstract 第 3 句、§1 末段、§7】
主实验	Table 3（零样本，10 列 × 5 行）+ Figure 1（多任务 scaling 曲线）+ §3.2-3.8 七个任务探针

逐条过闸

闸门	判定	依据
单方法论文（非综述/非 benchmark/非大系统报告）	通过	全文围绕一个方法（WebText 上训练的 Transformer LM）展开；七个任务只是同一模型的探针，不是七个方法
有明确核心 claim 与可定位的主实验	通过	claim 见上；主实验可定位到 Table 3 与 Figure 1-4
主实验数 ≤5 为佳	有条件通过	"数据集 × 任务"共 8 个数据集 + 7 个任务探针，超出 5；但它们共享同一个模型、同一套评测脚本，属"一个主实验的多面孔"。判定：可跑，但 S3/S4 必须以 method 与表 3 为主轴，否则篇幅失控
有开源代码或足够方法细节，支撑"建模迭代"	通过（有缺口）	脚注 5 给出 github.com/openai/gpt-2 （【可查证】）；§2.2-2.3 给了输入表示、层数、d_model、pre-LN、残差初始化缩放、context 1024、batch 512。缺口：§2.3 的三个架构改动全部只给做法不给动机，S3 必须据此把动机降级为待验猜想
用户具备前置知识	通过	需要：自回归 LM、Transformer decoder、BPE、困惑度、零样本评测。用户方向为 RL/推理模型，具备

三条必须随行标注的风险（本轮新增，供模板复用）

1. 无消融表：GPT-1 有 Table 5（逐任务消融差值）可作 S4 的归因对齐物；GPT-2 全文没有任何消融表。最接近消融的只有两处：§3.1 的 de-tokenizer 增益"2.5 to 5 perplexity"（无表）与 Table 4 的 `GPT-2 no hint` 行（-6.4 R-AVG）。→ 本论文的 S4 无法执行"归因必须与消融表逐任务差值对齐"这条纪律，只能整条降级为待验猜想。这是与 **GPT-1** 首跑最大的方法论差异，必须在 **S4/S8** 显式声明。
2. 无同行评审：GPT-1 的 S7 可以借"投会议被审"的博弈规则；GPT-2 从未经过正式评审，真实的把关发生在（a）四位草稿读者的内部反馈（【可查证：Acknowledgements】）与（b）发布前的误用风险评估【可查证：论文外：2019 年分阶段发布安排；论文脚注 5 只承诺"downloading and using the **small** model"】。S7 的会话设定须据此改写，不得虚构审稿人来自某个会议。
3. 被引文献时间跨度大：参考文献里含 2019 年 1 月的 Transformer-XL（[Dai et al., 2019]）与 2019 年 1 月的

Natural Questions ([Kwiatkowski et al., 2019])【可查证：References】。→ S2 的"只许引用发表日之前文献"这条限制，须以 2019 年 2 月为界，不能沿用 GPT-1 的 2018 年 3 月。

结论

放行。与 GPT-1 相比，本论文更适配数据驱动型仿真的强项（WebText 的构建与清洗本身就是主战场），但缺消融表这一条会削弱 S4 的归因纪律，S8 需相应加大"覆盖度缺口"的核查权重。

《档案·S0》

【阶段】S0 选材阐

【已知事实】

1. 论文为一篇单方法技术报告，6 位作者，前两位为同等贡献，末两位 (Amodei、Sutskever) 标注为通讯/资深等价符号【可查证：论文首页脚注】
2. 论文无 venue 字段，无审稿致谢；Acknowledgements 仅列出四位草稿反馈人与 Google 训练基础设施的协助者【可查证：Acknowledgements 段】
3. 核心 claim 有三处同源表述：Abstract (原句 reach 55 F1 on the CoQA dataset ... without using the 127,000+ training examples)、§1 末段 (原句 without any parameter or architecture modification)、§7 (原句 without the need for explicit supervision)【可查证：三处原文】
4. 主实验可定位：Table 3 (零样本 10 列乘 5 行)、Figure 1 至 Figure 4、§3.2 至 §3.8 七节任务探针【可查证】
5. 方法细节给到层数、d_model、pre-LN、残差初始化按 1 除以根号 N 缩放、context 由 512 增至 1024、batch 512、词表 50,257【可查证：§2.2 至 §2.3、Table 2】
6. 论文不含任何消融表；最接近的两处是 §3.1 的 de-tokenizer 增益区间 (2.5 至 5 perplexity，无表) 与 Table 4 的 GPT-2 no hint 行【可查证：全文检索"ablation"零命中】
7. 参考文献含 2019 年 1 月的工作 (Transformer-XL、Natural Questions)，故文献边界为 2019 年 2 月【可查证：References】

【合理重构】

- a. 论文形态为技术报告而非会议投稿，故 §7 的审稿人设定改为"投稿前内部评审加发布风险评审"——依据：Acknowledgements 的反馈人名单与脚注 5 只公开小模型这一事实互相印证 (重构)
- b. 六个作者的资历结构支持 §1.5 的三方博弈设定 (一作、资深、合作者)——依据：同等贡献标记与资深标记的分工 (重构)

【负结果】

1. 候选考虑过的替代做法是把 §7 仍然写成"投顶会被审"——被否，死因是虚构不在场的评审流程，违反来源标注义务
2. 候选考虑过跳过 S0 直接进 S1 (用户要求一次性跑完)——被否，死因是闸门的作用正是拦掉"无消融表加非投稿"这类隐性风险，跳过等于把风险推到 S8 才暴露
(本阶段负结果占比不足 40%，是 S0 的性质所致：闸门阶段以判定为主，负结果在 S1 起成为主体)

【未决问题】

1. 无消融表这一缺口，S4 的归因纪律如何改写？(留给 S4)
2. 非投稿论文的 rebuttal 该对着谁写？(留给 S7)
3. Table 3 有 10 列却称 8 个数据集，计数口径如何？(留给 S8 第 0 步已并行处理)

【一致性自检】本阶段无上一阶段档案，不适用；已确认本阶段判断不与论文任一事实冲突。

【后见之明自检】未使用任何实验结果支撑闸门判定；"适配性强"仅以论文形态与章节结构论证，未引用性能数字——合规。

口径三段式 - 目标：还原“语言模型可以不做微调就直接做任务”这个 idea 诞生前一周的第一作者视角。 - 现状：上一阶段《档案 · S0》（论文形态、claim 定位、无消融表）。时间点设为 2018 年 10 月——GPT-1 已挂出四个月，BERT 刚公开。 - 限制：只用 2018 年 10 月前公开材料；禁止引用论文任何实验结果；禁止预知 1.5B、WebText、Table 3。

1. 我当时在做什么，什么刺到了我

GPT-1 那篇是我们自己发的，结果不算难看，但我心里有个疙瘩一直没解开。

我们把判别式任务拍平成一条序列、只在最后加一个线性层，架构零改动——这一步走通了。但走通的代价是我原来那个执念的退让：我还是得给每个任务准备标注数据。GLUE 的数据是人一条条标出来的；QA 的数据是人一条条标出来的。模型越大、越好，就越像是在把人的标注吃得干净，而不是“自己会了”。这跟 2017 年那个情感神经元给我的直觉是拧着的——那个模型没人教它做情感分类，它自己长出了一个管情感的单元【可查证：Radford, Jozefowicz, Sutskever 2017, arXiv:1704.01444】。

然后十月初 BERT 挂出来了【可查证：Devlin et al., arXiv:1810.04805, 2018 年 10 月】。他们把双向的目标加上微调，在 GLUE 上把我们一起架在火上。GLUE 那个榜是当时所有人的靶心。

刺到我的不是输赢，是那条路的天花板：如果继续在“预训练 + 微调”这条轴上比，比的是谁的标注数据用得更狠、谁的目标函数更巧。这条路的天花板是标注数据的总量。而标注数据是人力做出来的，人力是有价格的。也就是说，我们这条路往上走，会撞到“人类愿意标多少”这堵墙。

2. 我的第一个 naive 想法

最直接的：把 GPT-1 那套继续做大。四层变八层，10 亿参数变 50 亿，语料从 BooksCorpus 换成能爬到的一切网页，然后去 GLUE 上把 BERT 掀翻。

这个想法甚至不需要论证，它是当时实验室里的默认档位。

3. 它卡在哪，为什么死

它死了三次，我每次都想去救，每次都没救活。

第一死：它没有回答任何新问题。打赢 BERT 只证明“我们的工程量比他们大”，不证明“语言模型学会了任务”。哪怕我们赢了，我也说不出为什么赢。这对我没用——我要的是理解，不是名次。

第二死：它撞在数据上。GLUE 就那么点数据。多任务方向已经有人把 (dataset, objective) 对堆到 10 个和 17 个【可查证：§1 原文 the two most ambitious efforts to date have trained on a total of 10 and 17 (dataset, objective) pairs respectively, 指 McCann et al. 2018 与 Bowman et al. 2018】。我当时写下的一句自问后来原样进了论文：当前机器学习系统需要成百上千个样本才能归纳出泛化良好的函数，按这个数，多任务训练大概也需要成百上千个有效的 (dataset, objective) 对才兑现得了它的承诺。继续堆数据集，就是拿人手去填一个指数级的坑。这条路在算术上就是死的。

第三死：它和“泛化”这两个字背道而驰。论文 §1 里那句“当前系统的普遍毛病是单任务、单域训练”，我当时是自己拿它来打自己的：再做一个单任务单域的 GLUE 模型，就是又往这个毛病里添一笔。

4. 转机

三件事撞在了一起，时间是一周内。

一是那个玩具式的论证。我盯着 GPT-1 的目标函数看的时候，意识到一件事：监督学习的目标和语言建模的目标是同一条式子，只是监督只在一段序列上算 loss【可查证：§2 原文 Since the supervised objective is the the same as the unsupervised objective but only evaluated on a subset of the sequence】。如果这是同一函数，那“能不能做任务”就不是能力问题，是优化到没到收敛的问题。也就是说，任何监督任务，都是语言建模分布里的一个子集。这意味着不需要为每个任务设计目标——只需要一个足够好的密度估计。

二是 McCann 他们递过来的那把刀。decaNLP 里那句"语言提供了一种灵活的方式把任务、输入、输出都表示为符号序列"【可查证：§2 原文 language provides a flexible way to specify tasks, inputs, and outputs all as a sequence of symbols】。他们举的例子是 (translate to french, english text, french text)。他们用这句话论证"可以做一个多任务模型"，我读成了另一件事：任务说明本身就是文本的一部分，那它就可以是训练数据的自然成分。他们要多标 10 个数据集，我连标都不用标——只要网上有人写过"英语句子 = 法语句子"。

三是我想通了互联网的性质。Weston 2016 那篇对话学习的工作证明了一种可能：不给奖励信号，直接从前向预测里学【可查证：§2 引用 Weston 2016, Dialog-based language learning】。但他被"对话"这个设定框住了。我当时的判断是：互联网上的信息是被动可得的，不需要交互。有人在网页里写"她是法国人，她说 Je ne suis pas un imbécile"——那条网页本身就同时包含任务说明、输入和输出。

拼图合上：不做微调，不设计目标，把语料做得足够大足够杂，然后假设一个容量足够的语言模型会为了把下一个词预测得更准，被迫去学会这些示范里的任务。这不是"我们教它做任务"，是"它为了预测得更准不得不学会做任务"。

我对这个想法毫无把握。§2 里我留了那句退路："preliminary experiments confirmed that sufficiently large language models are able to perform multitask learning in this toy-ish setup but learning is much slower than in explicitly supervised approaches"【可查证：§2 原文】——这是我在动手之前就看到的：这条路走得通，但慢。慢意味着要靠规模去换。

《档案·S1》

【阶段】S1 idea 诞生

【已知事实】

1. 作者 2017 年做过情感神经元工作 (arXiv:1704.01444)，论文 §1 引为 Radford et al., 2017【可查证：§1 引用行】
2. GPT-1 发表于 2018 年，论文 §2 多处以其为架构基线 (原句 The model largely follows the details of the OpenAI GPT model)【可查证：§2.3】
3. BERT 于 2018 年 10 月公开，论文将其列为"最小的第二个模型等同 BERT 最大模型"的对照【可查证：§3 开头】
4. 多任务学习当时最激进的两项工作分别只训了 10 与 17 个 (dataset, objective) 对【可查证：§1 原文】
5. 论文自陈的 meta-learning 类比：每个 (dataset, objective) 对就是从数据集与目标分布里采出的一个训练样本；当前系统需成百上千样本才能归纳出泛化良好的函数【可查证：§1 原文】
6. 监督目标与无监督目标同式、仅 evaluand 子集不同；故无监督目标的全局最小点也是监督目标的全局最小点【可查证：§2 原文，本论文的核心理论论证】
7. decaNLP (McCann et al., 2018) 已论证可用符号序列表达任务、输入、输出，并给出 translate to french 的样例格式【可查证：§2 原文与所举序列样例】
8. Weston 2016 在对话设定下做过无奖励信号的直接学习证明【可查证：§2 引用】
9. 作者自陈的预备实验结论：足够大的 LM 能做这种玩具式多任务学习，但远比显式监督慢【可查证：§2 原文】

【合理重构】

- a. 时间点设为 2018 年 10 月、触发场景为 BERT 公开当周——依据：引文 [Devlin 2018-10] 与 [Radford 2018-06] 的时间差；BERT 是论文里唯一被当作"对标对象"引用的同期工作 (重构)
- b. 用"标注数据的成本是这条路的天花板"作为第一动机——依据：§1 原文把"采集数据集、设计目标"的规模化困难列为动机主轴 (重构，论文未写成第一人称动机句)
- c. 第三个 naive 想法 (自建带标注的 web QA 对) 被否决的场景——依据：§2.1 明确拒绝"对任务做预先假设"的做法 (原句 we want to avoid making assumptions about the tasks to be performed ahead of time) (重构)

【负结果】

1. naive 想法一"把 GPT-1 继续做大去打 GLUE 榜"被毙，死因三条：不回答新问题；标注数据是天花板；与泛化背道而驰
2. naive 想法二"把 (dataset, objective) 对继续堆到几十上百"被毙，死因是算术：兑现承诺需要成百上千对，人手填不起
3. naive 想法三"自己造带标注的任务数据"被毙，死因是它把任务选择权交还给了研究者，等于放弃"不预设任务"这一唯一优势
4. 预备实验已显示要走的路比监督慢一个量级，故"不靠规模也能赢"这一分支当场死亡 (本阶段负结果即主体内容，占比约 65%)

【未决问题】

1. 语料从哪来、怎么保证它既大又杂还不脏？（留给 S4 数据轨）
2. 容量到多少才够？需要多大才"够用"？（留给 S3 与 S4 的模型矩阵）
3. 零样本怎么评？没有任务专用输出层，答案怎么从生成文本里取出来？（留给 S3）
4. 别人的 LM 已经做过零样本单任务，我们的边界在哪？（留给 S2）

【一致性自检】上一阶段《档案 · S0》的两条已知事实与本阶段无冲突：S0 记录论文无消融表，本阶段未依赖任何消融结论；S0 记录 claim 的三处同源表述，本阶段的动机推断与之同向。

【后见之明自检】未引用任何论文实验结果、未出现 1.5B 与 7/8 等数字；"靠规模换速度"仅以预备实验的定性结论论证，未预知规模必然有效——合规。

【修订注 · S8 核查 · H-G2-01】《合理重构》a 条写作"BERT 是论文里唯一被当作对标对象引用的同期工作"。"唯一"不成立：Universal Transformer (Dehghani et al., 2018) 同为同期工作，在 §3.3 被引作 LAMBADA 准确率的 19% 对照【可查证：§3.3 原文】；Transformer-XL (Dai et al., 2019) 则被引作 Table 3 若干列的 SOTA 来源【可查证：Table 3 caption】。现改为"论文中最主要的同期对标对象"。严强度 P2 (表述不严)，不触及 S1 的任何实质判断。

S1.5 · 内部博弈 —— GPT-2 科研全仿真

口径三段式 - 目标：还原“零样本任务迁移”这个方向在团队内部被质疑、砍 scope、最终定型的过程。 - 现状：上一阶段《档案·S1》（三个 naive 想法之死、监督目标与无监督目标同式的论证）+ 论文作者列表与致谢。 - 限制：时间点同 S1（2018 年 10 月）；无人知道论文最终成功；每个立场必须有利益动机；每个判断打标签。

作者结构与各自的账本

六位作者，前两位标单星号、末两位标双星号，脚注文字是“Equal contribution”（即星号所标者代表同等贡献）【可查证：论文首页脚注原句】。也就是说，四个人被标为同等贡献，中间两位（Rewon Child、David Luan）没有标记。这个结构本身就说明：这不一个人写的故事，四条线都有话语权。

我按仿真需要把立场归成三角（作者数、分工结构为【合理重构】，依据是同等贡献标记的分布与致谢里“Google 训练基础设施协助者”这条线索所指向的算力依赖）：

- 一作（我）：账本是“做出一个别人没做过的东西”。愿意冒险，愿意为了一个说不清能不能成的 claim 烧掉几个月。
- 资深作者（Sutskever 位）：账本是“故事线站得住、投稿/发布不翻车”。求稳，管叙事的一致性。
- 合作者（Amodei 位 + 另两位同等贡献者）：账本最杂——Amodei 那边还多一本“这东西放出去会不会被滥用”的账；Child / Luan 那边是工程与算力的账。他们的天然动作是砍 scope。

分歧一：语料用 Common Crawl 还是自己爬

谁和谁：我一作 vs 合作者。

争什么：Common Crawl 免费、量大到近乎无限，而且不是我一个人在用——直接下就行。合作者的反击很直接：这东西脏。而且不是猜的，Trinh & Le 那篇已经公开抱怨过 Common Crawl 里存在大量“content are mostly unintelligible”的文档【可查证：§2.1 原文引用】。

我为什么不让：自建爬虫意味着至少一个月工期，而且爬下来还是脏的。我在会上说过“我们是在做语言模型，模型自己会从噪声里学”。

收口：合作者赢了一半，但赢的方式很漂亮——他没有说“不许用网页”，他说“网页可以，但要有人替我们筛过”。Reddit 上至少 3 个 karma 的出站链接【可查证：§2.1 原文】是全网唯一一个现成的、免费的、由人投票产生的内容质量信号。这一句一出来，我就没法再争：爬虫还是要自己写（我输），但爬的对象不用我造（他让）。先例被推翻、方案被保留，这是团队里最常见的妥协形态。

分歧二：这一篇要不要给微调结果

谁和谁：我一作 vs 资深作者。这是最激烈的一次。

争什么：资深作者的意思是——必须给 GLUE 或 decaNLP 的微调数字。理由不是学术，是防御：“你这篇一个微调数字都没有，审稿人第一句话就是‘你们没跟 BERT 比’。我不用你说服我，我要的是别人挑不出这个口子。”

我的立场：不能给。原因也不纯是学术——只要论文里出现一个微调数字，整篇的叙事就从“语言模型自己会做任务”塌缩成“我们的模型微调也不错”。而后者我们大概率打不过 BERT，因为我们用的是单向模型，他们自己那篇的卖点就是双向【可查证：§6 末段原文承认这一不确定性：“it is unclear whether the additional training data and capacity of GPT-2 is sufficient to overcome the inefficiencies of uni-directional representations demonstrated by BERT”】。

收口：用一句承诺换掉一组实验。§6 最后一段写下“we plan to investigate fine-tuning on benchmarks such as decaNLP and GLUE”【可查证：§6 末段原文】。这句话在博弈上的作用是双份的：对内部的资深作者，它是“我们没忘，只是下一篇”；对外部的审稿人，它是一道提前封口的胶带。这是一个纯粹的叙事决策，被写成了科研计划的口吻。

分歧三：只出最大的那个模型，还是出一串

谁和谁：合作者（算力与工期）vs 我一作。

争什么：合作者的账很好算——训一个 15 亿参数的模型已经很贵了，训四个就是四份钱。而且如果只报最大的，论文短、进度快、风险少。他的原话大意是：“你的 claim 是零样本能做任务，那就报一个数字，做出来就行。”

我为什么死活要四个：因为我的核心 claim 不是“能做任务”，是“容量是这件事的关键”。这个 claims 里“容量”是自变量，只有一个点就画不出因果关系。只报最大模型，等于我说的每一句关于容量的判断都变成不可验证的断言。

收口：合作者条件性让步，代价是尺寸要 **log-uniform** 均匀铺开、不能再加第五个【可查证：§3 开头原句 We trained and benchmarked four LMs with approximately log-uniformly spaced sizes】。这四个点后来撑起了全文三张主图（Figure 1、Figure 2、Figure 3）与摘要里那句“improves performance in a log-linear fashion across tasks”。一次被折价的坚持：我要四档，得到四档，但失去了继续往上加的自由。

被砍掉的 scope（不是因为它错，是因为没人手 / 没算力 / 怕风险）

1. 多语言。这是最疼的一次。我原来想的是“语料越杂越好，那多语言当然更杂”。被砍的理由不是学术而是分析成本：一旦语料里混进多语言，所有单语评测集的重叠分析与困惑度口径全都得重做一遍；而团队要用同样的时间交一份能站住的分析。结果是一刀切：主动移除所有非英语网页【可查证：§3.7 原句 we deliberately removed non-English webpages from WebText as a filtering step】。这个砍法后来以一种很讽刺的方式回到论文里：那台字节级语言检测器发现 WebText 里仍然残留 10MB 法语——滤不干净【可查证：§3.7 原文】。而正是这 10MB，成了“完全没教过翻译任务，却出现 11.5 BLEU Fr→En”这一结果的解释材料。被砍掉的方向没有消失，它以证据的形式回来了。
2. 把整套权重和语料直接开放。一开始的默认计划是全开——GPT-1 就是这么做的，代码和数据都放出去了。这次被砍，砍的人是合作者，理由不是工期也不是算力，是风险。最终的形态是分阶段：先放小模型，最大的那个压着【可查证·论文外：2019 年 2 月的分阶段发布安排；论文脚注 5 可作内证——它承诺公开的只是 “Preliminary code for downloading and using the small model”，“small” 这个词是全文唯一的模型开放承诺】。我想强调这条的性质：它不是实验做得不够，是一次主动的、不可逆的自我限制。
3. 给每个任务设计专用 **prompt** / 后处理。这是我在 S3 里一直想偷偷加回来的一条腿，砍它的过程放在 S3 讲。

《档案 · S1.5》

【阶段】S1.5 内部博弈（多作者分歧）

【已知事实】

1. 作者共 6 位，Radford 与 Wu 标星号，Amodei 与 Sutskever 标双星号，脚注写明二者均代表同等贡献；Child、Luan 无标记；全体单位均为 OpenAI【可查证：论文首页作者行与脚注】
2. 致谢明确感谢“all the Googlers who helped us with training infrastructure”并列 10 位以上的具体人员，说明训练基础设施依赖外部协作【可查证：Acknowledgements 段】
3. 论文拒绝直接使用 Common Crawl，理由是质量；并引用 Trinh & Le 2018 对 Common Crawl 中大量文档“content are mostly unintelligible”的抱怨；作者自陈在初始实验中观察到类似问题【可查证：§2.1 原文】
4. 最终语料采用“Reddit 出站链接 + 至少 3 karma”这一人类策展代理启发式【可查证：§2.1 原文】
5. 论文全文不含任何微调数字；§6 末段以计划口吻承诺后续研究 decaNLP 与 GLUE，并自陈不确定单向表征的劣势能否被数据量与容量补上【可查证：§6 末段原文】
6. 共训练并评测四档模型，规模为近似对数均匀分布【可查证：§3 开头原文】
7. 主动移除全部非英语网页；但字节级语言检测仍发现约 10MB 法语残留【可查证：§3.7 原文】
8. 论文脚注 5 只承诺公开可下载并使用小模型所需的初步代码【可查证：论文脚注 5 原文】

【合理重构】

- a. 三方立场模型（一作冒险 / 资深求稳 / 合作者砍 scope）与三次分歧的具体争点——依据：同等贡献标记的分布、致谢中的算力依赖、以及论文里三处“留下了折价痕迹”的原文（Reddit 启发式、四档 log-uniform、末段的微调承诺）（重构）
- b. 语料来源之争的具体翻盘台词（“网页可以，但要有人替我们筛过”）——依据：§2.1 从“拒绝 Common Crawl”直接跳到“只用人类策展过的链接”，中间的取舍痕迹只能由这条逻辑补上（重构）

c. 全量开源的默认计划被安全考量否决——依据：脚注 5 的 small 一词与公开的分阶段发布事实（重构加论文外查证）

【负结果】

1. 分歧一：自建爬虫方案被否，死因是工期与收益不成比例
2. 分歧二：本篇给出微调结果被否，死因是会把整篇叙事从"自己会做任务"塌缩为"微调也不错"
3. 分歧三：追加第五个更大模型请求被否，死因是算力
4. 被砍 scope 一：多语言，死因是分析成本（后续以 10MB 法语残留的形式部分复活）
5. 被砍 scope 二：全量权重与语料开源，死因是误用风险，是一次主动的自我限制（本阶段负结果为主体内容，占比约 55%）

【未决问题】

1. 既然不移除任务假设、又不给微调，答案怎么从生成文本里取出来？（留给 S3）
2. 语言检测器没滤干净的非英语数据，会不会污染评测？（留给 S4）
3. 分阶段发布意味着"1.5B 的参数细节可公开到什么程度"要在成文时一并决定（留给 S6）

【一致性自检】本阶段与上一阶段档案无冲突：S1 记录"语料从哪来"列为未决问题，本阶段给出了内部博弈版本的答案且与 S4 数据轨的锚点一致；S1 记录"B 与 C 派划清界限"，本阶段分歧二正是那条划界在团队内部的投影，方向一致。

【后见之明自检】未引用 Table 3 或任何性能数字；"容量是关键"仅以论证结构说明为何必须四档，未断言四档必然呈现某种趋势——合规。

口径三段式 - 目标：还原“我站在哪”——零样本任务迁移这个问题在 2019 年 2 月之前的前人工作地图。 - 现状：上一阶段《档案·S1》《档案·S1.5》（方向已定：不做微调、不预设任务、靠容量）。 - 限制：只许引用 2019 年 2 月之前的文献。论文 related work 未提但当时已存在的关键工作可以补，但必须注明“论文未引”。

1. 四派地图，各派代表作与死穴

A 派：表征迁移（用别人的表征，跑自己的任务）

代表作：word2vec / GloVe / Skip-thought【可查证：§5 引用 Mikolov 2013、Pennington 2014、Kiros 2015】、CoVe【可查证：§5 引用 McCann 2017】、ELMo【可查证：§5 引用 Peters 2018】。

死穴：迁过去的只是表示，任务模型本身还得任务专用。ELMo 在下游要叠自己的 BiLSTM 与 attention【可查证：§2 引用链】——也就是说无监督学到的东西只负责输入层，真正的判断仍然由标注数据现场学。

我对它的态度：划清界限，而且是硬的。这一派的极限就是“更好的初始化”，不是“自己会做任务”。

B 派：预训练 + 微调（我的出生地）

代表作：Dai & Le 2015【可查证：§1 引用】、ULMFIT【可查证：§5 引用 Howard & Ruder 2018】、GPT-1【可查证：§2.3 原句 The model largely follows the details of the OpenAI GPT model】、BERT【可查证：§3 开头】。

死穴：必须有监督数据。这一派的所有进展都可以被读成“如何更省地用标注数据”，而不是“可以不标注”。

亲缘：这是我的亲生母亲，我不否认。架构、优化器、训练配方几乎全是继承的。但我这次要走到她的反面去——我要证明没有她那个尾巴（微调步）也能活。§1 那句话我写得很清楚：这一派“仍然需要监督训练才能执行任务”【可查证：§1 原句 These methods still require supervised training in order to perform a task】。BERT 尤其关键：它的双向目标本身就规定了下游要接一个任务头，它在结构上就宣布零样本是不可能的——这就给了我们一个别人不会来抢的空位。

C 派：显式多任务 / 任务描述

代表作：decaNLP/MQAN【可查证：§2 引用 McCann et al. 2018】、One Model To Learn Them All【可查证：§2 引用 Kaiser et al. 2017】、Yogatama 2019 与 Bowman 2018【可查证：§1 引用】。

死穴（我认为是致命的）：每个 (dataset, objective) 对都得是人造出来的，并且都要标注。“最激进的两项工作分别只训了 10 与 17 个对”【可查证：§1 原文】。按机器学习系统动辄需要成百上千样本才能泛化的经验，这条路要兑现就得要成百上千个对。它不是一个方向选错了，它是一个规模指标选错了。

亲缘：半个亲生。它给了我“语言可以描述任务”这把刀（S1 已记），但它的任务描述是人为发明的控制码；我的任务描述是语料里本来就有的自然文本。就差这一步，性质完全不同：它造数据，我找数据。

D 派：无监督任务学习的前身（单点突破）

代表作：Weston 2016 对话式语言学习【可查证：§2 引用】、Schwartz 2017 常识推理【可查证：§1 引用】、Radford 2017 情感神经元【可查证：§1 引用】、Karpathy 2015 的 RNN 可解释单元【可查证：§5 引用】、Liu 2018 的 Wikipedia 生成模型顺带学会跨语言译名【可查证：§5 原文 the observation of Liu et al. (2018) that a model trained to generate Wikipedia articles also learned to translate names between languages】。

死穴：全是单任务、单数据集的 proof of concept，而且大多止于定性观察。这一派没有一篇做过系统评测，所以谁也没法说“这是普遍现象”还是“这是运气好”。

亲缘：血最亲的一派。§5 里我自己承认了：真正鼓舞我的不是别人，是 Liu 2018 那个“生成维基百科的模型顺带学会了翻译人名”【可查证：§5 原句 More inspirational to our work was...】。这句话之所以鼓舞我，是因为它说明“顺带学会”不是我们那篇情感神经元的孤例。

2. 惊魂时刻：我以为没人做过，查到发现有人做过

这个时刻发生在我准备写“零样本任务迁移是空白”这句话的时候。

我去查 Winograd Schema Challenge 的榜，发现 **Trinh & Le 2018** 已经用语言模型做过了，而且没在 **WSC** 上训练【可查证：§2.1 与 §3.4 都引用了 Trinh & Le 2018】。他们的做法是“比较两种消解哪个概率更高”。这就是零样本任务执行——跟我打算做的事在性质上是同一件。

当时我盯着屏幕坐了一会儿。如果这件事已经有人做过，我那篇论文的第一句话就不成立了。

后来是怎么活下来的，靠的是去读他们那篇的两处细节：

1. 他们用的是一个“小样本的 **Common Crawl** 子集”，而且这个子集是“只保留与目标数据集最相似的文档”筛出来的【可查证：§2.1 原文 Trinh & Le (2018)'s best results were achieved using a small subsample of Common Crawl which included only documents most similar to their target dataset, the Winograd Schema Challenge】。这句话救了整篇论文。因为“只保留与目标任务最相似的文档”意味着他们已经把任务知识预先注入了反——这是一个针对 WSC 量身定制的语料。而我要是能把语料做得完全不带任务偏好，还能赢，性质就不同了。§2.1 里我写了这句自我定位：我们要避免预先对任务做假设【可查证：§2.1 原文 we want to avoid making assumptions about the tasks to be performed ahead of time】。这句话表面上是方法论，实际上是我在被抢先之后画的那条分界线。
2. 他们只做了一个任务。一个任务无法区分“语言模型普遍会做任务”和“语言模型的某条路径恰好撞对了这个任务”。要证明前者，就得换很多任务、换很多数据集，而这一点恰好是我这边唯一有优势的地方——我有容量和语料。于是“广度”就成了我的护城河。§3 里七个任务探针的排布，根子在这个惊魂时刻。

3. 补记：论文没引、但当时已经存在、我认为该引的两条

（本节的标签性质不同：以下两条是论文未引的同期工作，我按 S2 的纪律补上，供 S8 判断是否构成覆盖度缺口）

1. **Xiong et al.** 关于 **Pre-LN** 的工作——论文 §2.3 用了“把 LayerNorm 挪到子块输入”这个改动，却没有任何引用【可查证：§2.3 原文只写做法不给引用与动机】。当年这类“深层 Transformer 训练稳定性”的知识主要散在代码与口头传播里。这一条对 S3 很关键：它意味着 §2.3 的三个架构改动在论文里是无引用、无动机的，S3 只能把它们写成待验猜想。
2. **Universal Transformer (Dehghani et al., 2018)** ——论文只在 LAMBADA 一节把它当作对照数字引用（19%）【可查证：§3.3 引用】，没有在 related work 里讨论它“用循环深度换容量”的路线。这条路线与“靠参数规模换能力”是直接竞争的假设，不讨论它，等于回避了本文最核心的自变量之争。

《档案·S2》

【阶段】S2 文献调研

【已知事实】

1. 表征迁移一派的代表与引用位置：GloVe (§5)、Skip-thought (§5)、CoVe (§5)、ELMo (§5)、词向量与上下文表征的迁移谱系 (§1)【可查证：各引用行】
2. 预训练加微调一派：Dai & Le 2015 (§1)、ULMFiT (§5)、GPT-1 (§2.3 明示本模型沿用其细节)、BERT (§3 开头)；§1 明言这些方法仍需要监督训练才能执行任务【可查证：§1 原句】
3. 多任务一派：decaNLP (§2，含任务可表示为符号序列的论证)、One Model To Learn Them All (§2)、Yogatama 2019 与 Bowman 2018 (§1)；最激进的两项仅训 10 与 17 个 (dataset, objective) 对【可查证：§1 原文】
4. 单点突破一派：Weston 2016 (§2)、Schwartz 2017 (§1)、Radford 2017 (§1)、Karpathy 2015 (§5)、Liu 2018 (§5, §5 明言其“更具启发性”)【可查证：各引用行】
5. Trinh & Le 2018 已用语言模型在 Winograd Schema Challenge 上取得零样本性质的结果；其最佳结果建立在“只保留与目标数据集最相似的文档”的 Common Crawl 子样本上【可查证：§2.1 与 §3.4 原文】
6. 论文明确以“避免预先对任务做假设”作为与 Trinh & Le 的分界策略【可查证：§2.1 原文】
7. 论文 §2.3 列出三处架构改动 (LayerNorm 前移、末层后追加 LayerNorm、残差路径初始化按 N 的平方根反比缩放)，三处均无引用、无动机句【可查证：§2.3 原文】
8. Universal Transformer 在论文中仅作为 LAMBADA 对照数字出现 (19%)，未进入 related work 讨论【可查

证：§3.3 引用，§5 无其条目】

【合理重构】

- a. "惊魂时刻"的具体场景与两处救命细节的读取顺序——依据：§2.1 对 Trinh & Le 语料筛选方式的批评写得极为具体，这类具体性通常来自"被抢先之后的逐句复盘"（重构）
- b. 与 C 派的本质差异定位为"造数据 vs 找数据"——依据：§2.1 拒绝预先假设任务、§2.1 用人类策展信号替代人工筛选，两处锚点共同指向这条边界（重构）

【负结果】

1. 最初假设"零样本任务迁移是空白"被证伪，Trinh & Le 2018 已做过单任务版本，该假设当场作废
2. 想用"我们是第一个"作为卖点的分支死亡，被迫改为用"广度"作为卖点
3. 想在 related work 里把 BERT 归入"另一条路线、不作比较"的处理被否，死因是它是同期唯一直接竞争物，回避会引火烧身

（本阶段负结果占比约 45%；第 8 条已知事实另构成一处覆盖度缺口候选，交 §8 判定）

【未决问题】

1. §2.3 三处架构改动的动机无处可查，§3 该怎么处理？（留给 §3，纪律要求降级为待验猜想）
2. 语料要做到"完全不带任务偏好"，具体怎么实现？（留给 §4 数据轨）
3. 广度这条护城河要挖到多宽才够？七个任务是够还是不够？（留给 §4 实验轨与 §6）

【一致性自检】本阶段与《档案·S1》《档案·S1.5》无冲突：S1 把"C 派只是给刀"写为转机来源，本阶段把它写为"半个亲生但路线不同"，两处一是借鉴其论证、一是划清其做法，方向一致；S1.5 记录"多语言语料被砍"，本阶段 A 派地图里未出现跨语言迁移的替代路线，不构成新的可选分支。

【后见之明自检】未引用任何论文自身的性能数字来评价前人；对 Trinh & Le 的处理只用了其做法描述，未用任何"我们后来赢了"的口吻——合规。

【修订注·S8 核查·H-G2-02】《已知事实》第 7 条写作"三处均无引用、无动机句"，其中"无引用"不实。§2.3 原句为 Layer normalization (Ba et al., 2016) was moved to the input of each sub-block, similar to a pre-activation residual network (He et al., 2016)——归一化前移这一处有 Ba et al., 2016 与 He et al., 2016 两处引用。另两处（末端追加 LayerNorm、残差权重按 $1/\sqrt{N}$ 缩放）确实无引用。正确表述应为：四处改动均无动机句；其中归一化前移一处有两处引用，其余三处无引用。说明：S3 依据本条做出的"整批降级为待验猜想"这一决定不受影响——降级依赖的是"引不出论文的动机原句"，而不是"没有引用"（引用 ≠ 动机）。但原稿把"无引用"写成了降级的辅助理由之一，属于论据错位，**严重度 P1**。同一处错误在 S3.md 中重复出现，见该文件对应修订注。

【修订注·S8 核查·H-G2-02b】《合理重构》b 条中"造数据 vs 找数据"的定位保持不变；但第 3 节补记第 1 条的标题"论文没引、但当时已经存在"对 Pre-LN 路线而言亦不严谨：论文对所引的 He et al. 2016 pre-activation 残差网络的类比是有引用的，缺的是对"深层 Transformer 的归一化位置选择"这一具体做法的引用。现改为："论文未引深层 Transformer 归一化位置的具体做法文献，仅有 pre-activation 残差网络的类比引用。"**严重度 P2**。

S3 · 建模迭代 —— GPT-2 科研全仿真

口径三段式 - 目标：还原方法从 v0 到论文最终形态的迭代链，中间版本一个都不许跳。 - 现状：上一阶段《档案·S1》《档案·S1.5》《档案·S2》（方向定型：不做微调、不预设任务、任务描述来自自然文本；且 §2.3 三处架构改动无引用无动机）。 - 限制：v0/v1 可以是【合理重构】，但每一版的死因必须让内行信服。凡陈述“某个设计是为了解决某个问题”，必须引出论文里的动机原句，否则降级为待验猜想。

v0：把微调那一刀砍掉，其他原样不动

最直接的形式化：GPT-1 的流水线是「预训练 → 拍平成序列 → 加线性层 → 微调」。我把最后两步直接删掉，留下「预训练 → 拍平成序列 → 采样」。

具体做法是：把任务写成一段文本，喂进去，让模型接着写，从写出来的东西里取答案。比如问答就写“问题……答：_____”，让模型续写。

它为什么不够——三个层次：

1. 接口层：答案取不出来。模型续写的是网页文本的分布，不是答案的分布。我问“谁是第一个被弹劾的总统”，它接着写“这个问题在历史上有很多讨论。安德鲁·约翰逊是第一位……”——答案在里面，但不在开头，我不知道该切哪一段。注意这不是工程问题，是目标函数的问题：语言建模只保证“整段文本的概率高”，从不保证“答案出现在某个固定位置”。这一条后来在 LAMBADA 上以最干净的形式复现：模型给出的大多是句子的合法续写，但不是合法的最后一个词【可查证：§3.3 原句 most predictions are valid continuations of the sentence, but are not valid final words】。它证明的不是模型不会，而是模型没有被告知“这里要的是那个词”。
2. 效率层：慢一个量级。论文 §2 留下了我自己写的预备实验结论：足够大的语言模型确实能做这种玩具式的多任务学习，但远比显式监督慢【可查证：§2 原文 learning is much slower than in explicitly supervised approaches】。慢意味着必须用规模和时间去换——这是全篇最终走向“四档 log-uniform 模型矩阵”的真正原因，也是合作者在 S1.5 里让步的代价。附带一句理论上的安慰：监督目标与无监督目标是同一条式子，只是 evaluated 是子集，所以无监督目标的全局最小点也是监督目标的全局最小点【可查证：§2 原文】。这句话的用处是防线，不是进展：它保证这条路“原则上能到”，但不保证“我们能到”。
3. 风险层：我拿什么证明它是“学”的？如果模型只是把训练语料里出现过的问答原样背出来，那我做出的东西叫检索，不叫零样本任务学习。这一层在 v0 阶段我甚至不知道怎么设计检验，但它像根刺一样留在计划里——后来它变成了整整一节（§4 Generalization vs Memorization）。

v1：先救输入——表示层死了两回

v0 的接口问题我不打算用后处理硬解（S1.5 已经砍掉那条腿）。换个思路：如果不改模型，能不能改“文本怎么进模型”？

第一条死路：字符 / 词级 **BPE**。参考的 BPE 实现是在 Unicode 码点上做的【可查证：§2.2 原文 reference BPE implementations often operate on Unicode code points and not byte sequences】。这意味着要覆盖全部 Unicode 字符串，基础词表就得超过 130,000【可查证：§2.2 原文 This would result in a base vocabulary of over 130,000 before any multi-symbol tokens are added】——而当时 BPE 任务上常用的词表是 32k 到 64k【可查证：§2.2 原文 the 32,000 to 64,000 token vocabularies often used with BPE】。代价不是钱，是分配：词表是有限的，多出来的 7 万多个槽位本来可以装词。

第二条死路：直接上字节级 **LM**。字节这个粒度天然满足“任何 Unicode 字符串都能算概率”这个要求【可查证：§2.2 引用 Gillick et al. 2015 作为该思路的先例】。但字节级语言模型在 One Billion Word Benchmark 上打不过词级模型【可查证：§2.2 原文 current byte-level LMs are not competitive with word-level LMs】；而且我自己在 **WebText** 上重跑，也看到了同样的差距【可查证：§2.2 原句 We observed a similar performance gap in our own attempts to train standard byte-level LMs on WebText】。这一条是“文献说不行，我自己也验证了不行”。

活下来的版本：字节级 **BPE**。

它的定位是“字符级与词级之间的实用中间态”【可查证：§2.2 原文 a practical middle ground between character and

word level】。三个具体决策：

- 基础词表 256（字节）而不是 13 万【可查证：§2.2 原文 only requires a base vocabulary of size 256】；
- 禁止跨字符类别合并：直接把 BPE 用在字节序列上会产生次优合并，因为它是频率贪婪的启发式，结果会把 `dog`、`dog.`、`dog!`、`dog?` 各占一个槽位【可查证：§2.2 原文，含这四个具体形态】——"limited vocabulary slots and model capacity 的次优分配"【可查证：§2.2 原文 sub-optimal allocation of limited vocabulary slots and model capacity】；
- 对空格开一个例外：这一条例外"显著提升压缩效率，同时只带来极小的词碎片化"【可查证：§2.2 原文 We add an exception for spaces which significantly improves the compression efficiency while adding only minimal fragmentation of words across multiple vocab tokens】——这是全文少数给出"代价—收益"对比的一句话，所以它是动机可查证的。

最终词表 50,257【可查证：§2.3 原文 The vocabulary is expanded to 50,257】。

v1 暴露的新问题：输入表示修好了，"答案在哪"的问题一点没动。v1 只让模型能把任何字符串读进来、算得出概率，读得进来 ≠ 答得对。

v2：最后一块拼图不是架构，是"接口约定"

到这里我卡了很久。真正的转折不是某个模块，是我放弃了"让模型自己知道要干什么"这个念头。

McCann 他们那句"语言可以把任务、输入、输出都表示为符号序列"【可查证：§2 原文】在 S1 时被我读成"任务说明可以是训练数据的自然成分"。到 v2 我才意识到它的另一半用途：它同时是推理时的接口约定。既然任务是文本，那我就在推理时把任务写进上下文——不是改模型，是改我给它的那段文本。

论文里七处探针全部是这个约定的实例【可查证：以下逐句取自 §3】：

任务	接口约定（论文原句）
阅读理解（CoQA）	条件于文档、对话历史、以及最后一个 token A：【§3.5】
摘要（CNN/DM）	在文章后加上 <code>TL;DR:</code> ，再生成 100 个 token【§3.6】
翻译（WMT-14）	上下文给若干 <code>english sentence = french sentence</code> 样例对，最后以 <code>english sentence =</code> 收尾【§3.7】
问答（Natural Questions）	用问答样例对做种，帮助模型推断该数据集的短答风格【§3.8】

这就是最后一块拼图：零样本 ≠ 零格式。模型不需要微调，但需要接口；接口不是新参数，是一段人写的自然文本。它把 v0 的"答案取不出来"降级成了"答案在哪一段"的工程细节——语义上仍然是零样本，因为模型没有为任何任务更新过权重。

然后是架构侧的四刀。§2.3 列出的改动是：

1. LayerNorm 移到每个子块的输入，类似 pre-activation 残差网络【可查证：§2.3 原文】；
2. 在最后一个自注意力块之后追加一个 LayerNorm【可查证：§2.3 原文】；
3. 一个新的初始化，把残差层权重按 $1/N$ 缩放，N 为残差层数【可查证：§2.3 原文】；
4. 上下文从 512 提到 1024，batch 从（GPT-1 的）更小值提到 512【可查证：§2.3 原文】。

纪律自检（这一节必须扣死）：以上四条，论文全部只写"做了什么"，一句动机都没给，也没有任何引用。按 S3 的纪律，任何"某设计是为了解决某问题"的说法都必须引出论文原句——这里引不出来。所以这四刀在本阶段一律降级为待验猜想，标注如下：

改动	论文给出的动机句	本阶段判定
LayerNorm 前移	无	待验猜想（深层网络训练稳定性的常见处方之一）
末端追加 LayerNorm	无	待验猜想

残差初始化按 $1/\sqrt{N}$ 缩放	无	待验猜想（"account for the accumulation on the residual path with model depth"是描述、不是动机）
context 512→1024 / batch 512	无	待验猜想

这几行是本轮与 **GPT-1** 首跑最大的一处方法论差异。GPT-1 当年 S3 犯的错，是把 v1 的辅助目标动机写成“治小数据过拟合”——而论文 §3.2 的动机原句是“提升泛化并加速收敛”，Table 5 的逐任务差值更是反着的：动机写错，整条迭代链就救错了人。那一轮的教训是“必须引出原句”；这一轮的处境更硬：原句根本不存在。所以这里没有可救的错，只有必须承认的不可知——四条架构改动的真实动机，任何仿真都只能重构，S8 必须把它们整批列入“编圆了但论文没这回事”的高危区。

4. 对照论文最终方法：我的迭代链和它的距离

（本段允许看论文，其余段落不许）

我的版本	论文最终形态中的对应物	距离
v0 删微调 + 采样	§2 的“零样本、不改参数与架构”总纲	无距离，v0 就是论文的第一性原理
v0 的接口问题	§3.3 承认部分预测是合法续写而非法未词；用 stop-word filter 近似补救	论文没有消灭这个问题，只是给它加了一个近似补丁。这是本文最诚实也最脆弱的一处
v1 字节级 BPE + 禁跨类合并 + 空格例外	§2.2 全文	无距离，逐条对上；唯一未获动机的是空格例外之外的合并策略
v2 的上下文接口约定	§3.5–§3.8 四处格式	无距离，且这四处是“零样本”claim 得以成立的实际承载物
v2 的四刀架构改动	§2.3	有距离，且这个距离无法测量：论文不给动机，所以我无法判断我的重构是否与真实决策同因。这四刀整批降级

《档案 · S3》

【阶段】S3 建模迭代 【已知事实】 1. 预备实验结论：足够大的语言模型能在玩具式设定下做多任务学习，但比显式监督慢得多【可查证：§2 原文】 2. 监督目标与无监督目标同式，仅 <code>evalund</code> 为子集，故二者的全局最小点重合【可查证：§2 原文】 3. 参考 BPE 实现在 Unicode 码点而非字节上操作；覆盖全部 Unicode 需超过 130000 的基础词表；当时常用 BPE 词表为 32000 至 64000【可查证：§2.2 原文】 4. 字节级 LM 在 One Billion Word Benchmark 上不及词级；作者在 WebText 上的自行尝试观察到同样差距【可查证：§2.2 原文】 5. 字节级 BPE 基础词表为 256；直接对字节序列做 BPE 会因频率贪婪启发式产生次优合并，例如 <code>dog</code> 的多种形态各占槽位；故禁止跨字符类别合并，并对空格例外；空格例外显著提升压缩效率且碎片化极小【可查证：§2.2 原文，其中空格例外是全文少数给出代价收益对比的动机句】 6. 最终词表扩至 50257【可查证：§2.3 原文】 7. §2.3 四处架构与训练改动（LayerNorm 前移、末块后追加 LayerNorm、残差层权重按 $1/\sqrt{N}$ 初始化缩放、context 由 512 增至 1024 与 batch 512）全部只给做法，无动机句、无引用【可查证：§2.3 原文，全文无相关引用】 8. 七处任务探针的实际接口约定：CoQA 条件于文档加对话历史加末 token A:；摘要为文章后加 TL;DR: 并生成 100 token；翻译为若干 english sentence = french sentence 样例对加英文句子等号收尾；问答为问答样例对做种【可查证：§3.5、§3.6、§3.7、§3.8 原文逐句】 9. LAMBADA 的误差形态：多数预测是句子的合法续写，但不是合法的最后一个词；作者据此认为模型没有利用“必须是句末词”这一约束【可查证：§3.3 原文】 【合理重构】 a. v0 的形态（删去微调与任务头、直接续写取答案）与它的三层死因——依据：§2 的总纲与预备实验结论、§3.3 的误差形态描述（重构） b. v1 的两条死路顺序（先试字词级 BPE、再试纯字节级、最后落到字节级 BPE）——依据：§2.2 的叙述顺序本身即为该

顺序（重构程度低，接近论文叙述序的还原）

c. v2 的转折点定位为“任务写进上下文的接口约定”而非任何模块——依据：§3.5 至 §3.8 四处格式在论文中承担了零样本 claim 的全部实现（重构）

【负结果】

1. v0 被毙，死因三层：接口层答案不可定位、效率层比监督慢一个量级、风险层无法排除记忆解释
2. v1 第一方案（字词级 BPE）被毙，死因是 130000 以上的基础词表挤占有限的词表槽位与模型容量
3. v1 第二方案（纯字节级 LM）被毙，死因是文献与自己实验双重验证的不及词级性能
4. v2 的四刀架构改动动机不可查证，整批降级为待验猜想——这是本阶段最重的一条负结果：不是方案被否，而是“归因资格”被否
5. 想用后处理抽取答案的路线在 v0 阶段即被否（§1.5 已记录的 scope 砍除）
（v0 与 v1 的死因构成本阶段负结果主体，连同第 4 条，占比约 60%）

【未决问题】

1. 语料要大多多杂才会自发出现任务示范？需要的规模是能估算还是只能试？（留给 §4 数据轨）
2. 四条架构改动的真实动机如果永远查不到，§8 该怎么给它们定级？（留给 §8）
3. 记忆解释要怎么被排除？（★ 本阶段明确挂起的最大钩子，正文里没有任何一节能绕过它，留给 §4 与 §8）

【一致性自检】与《档案·S1》《§1.5》《§2》无冲突：§1 记“预备实验显示比监督慢”，本阶段 v0 死因第 2 条与之一致；§1.5 记录“给每任务设计专用后处理被砍”，本阶段 v2 用的上下文接口不是后处理（不改输出、只改输入），不构成对 §1.5 决议的回退，已在此显式说明；§2 记录“§2.3 三处改动无引用无动机”，本阶段据其执行了降级，处理方向一致。

【后见之明自检】未引用 Table 3 任何数值；v2 的容量预期只写“必须靠规模换速度”，未断言某档规模必然奏效，也未提及最终四档的具体尺寸——合规。

【修订注·S8 核查·H-G2-02】正文写“以上四条，论文全部只写‘做了什么’，一句动机都没给，也没有任何引用”——“也没有任何引用”不实。§2.3 的归一化前移一处带两处引用（Ba et al., 2016；He et al., 2016）。正确表述：四处均无动机句；归一化前移一处有两处引用，其余三处无引用。降级决定不变（降级依赖的是“引不出动机原句”）。严重度 P1，与 §2.md 同源。

【修订注·S8 核查·H-G2-03】《合理重构》b 条把 v1 的两条死路顺序写成“先试字词级 BPE、再试纯字节级”，并标注“重构程度低，接近论文叙述序的还原”。这个标注不成立：§2.2 的实际叙述序是先讲字节级（优雅但打不过词级）→再讲 BPE 作为折中→再讲参考实现按码点操作导致 13 万词表的问题→最后给禁止跨类合并的修补【可查证：§2.2 段落顺序】。即真实顺序与我的写法相反。现改标为中重度重构，并说明顺序系按“致命程度”重排（13 万词表更像先被撞上的墙）。严重度 P2。

【修订注·S8 核查·H-G2-03b】§4 对照表 v1 行写“无距离，逐条对上；唯一未获动机的是空格例外之外的合并策略”，句式含混。现改为：“逐条对上；其中空格例外有明确的代价—收益对比句，属动机可查证；禁止跨类合并本身只有理由（BPE 频率贪婪导致 dog 的多种形态各占槽位）而无引用；三处架构改动与训练侧改动均无动机句。”严重度 P2。

【修订注·S8 核查·H-G2-09】v0 死因第 3 层结尾写“……但它像根刺一样留在计划里——后来它变成了整整一节（§4）”。这是本阶段的一处后见之明泄漏：本阶段开头的纪律明令“每一版的死因必须说得让内行信服”且全阶段不得预知论文最终形态，而“后来它变成了整整一节”直接引用了论文的章节编排（后见）。现改为：“这一层在 v0 阶段甚至没有检验手段，只能作为悬置的钩子记下来（见本阶段《档案》未决问题第 3 条）。”严重度 P1（后见之明泄漏）。该处由 S8 的“反向后见之明核查”查出，是全部七个阶段里唯一一处泄漏。

口径三段式 - 目标：还原"数据从哪来、为什么这么测"背后的博弈。本论文的数据轨是主战场，篇幅不低于实验轨。 - 现状：上一阶段《档案·S3》（v0/v1/v2 定型：字节级 BPE + 上下文接口约定；四条架构改动无动机、整批待验）。 - 限制：承认算力与工期限制；实验叙事里的曲线走向不许照抄论文结论（那属于 S8 的对照材料）。另加一条本论文专属的限制：全文无消融表，故本阶段的归因纪律无法执行，只能整条降级——见第 9 条。

【数据轨】

1. 数据从哪来：四个候选，三个被否

候选	谁支持	否决理由（论文依据）
Common Crawl	我（一作，理由：免费、近乎无限）	两种否决叠加：文献层面，Trinh & Le 2018 已公开抱怨其中大量文档"content are mostly unintelligible"，且他们的解法是"只保留与目标数据集最相似的文档"，这等于把任务知识预先注进语料；作者层面，我们在自己的初始实验里观察到了同样的质量问题【可查证：§2.1 原文两处】
Wikipedia	合作者（理由：干净、可控）	被主动移除，理由不是脏而是"干净得太大众"：它是许多数据集的共同来源，与测试任务重叠会让分析复杂化【可查证：§2.1 原句 We removed all Wikipedia documents from WebText since it is a common data source for other datasets and could complicate analysis due to overlapping training data with test evaluation tasks】
单域语料（新闻 / 小说 / 书籍）	无	与核心 claim 直接冲突：我们要的恰恰是域的多样性，单域语料在定义上做不到
Reddit 出站链接	合作者（S1.5 分歧一的收口）	——被采纳

采纳方案的两句关键原文必须逐字记住： - 「只抓取经过人类策展/筛选的网页」，因为"人工筛选整份网页爬取会异常昂贵"【可查证：§2.1 原文】； - 「抓取 Reddit 上至少获得 3 个 karma 的所有出站链接」，这可以看作"其他用户是否觉得这个链接有趣、有教育意义或只是好笑"的启发式指标【可查证：§2.1 原文】。

"至少 3 个 karma"这个数字是整条数据轨的支点：它用一个免费的、由人投票产生的代理信号，替换掉了"人工筛选"这个买不起的工序。它同时也是 §2.1 里我们与 Trinh & Le 划界线的物质基础——他们的语料带任务偏好，我们的不带。

抽取器：Dragnet 与 Newspaper 的组合【可查证：§2.1 原文】。

2. 清洗与筛选：三次返工（本阶段第一条负结果重点区）

返工一：<UNK> 和分词痕迹反过来咬了我们。我们在 S3 赌的是"字节级输入 → 不需要任何有损预处理与分词"，这句话我们当时觉得很漂亮。但下游数据集的另一个方向是脏的：那些评测集大多经过激进的标准化的，带着"断开标点与缩写、被打乱句子"这类分词痕迹【可查证：§3.1 原文 aggressively standardized text, tokenization artifacts such as disconnected punctuation and contractions, shuffled sentences】，甚至出现 <UNK> 这个字符串——而它在 WebText 里极端罕见，40 亿字节里只出现 26 次【可查证：§3.1 原文】。结果是我们要反向造工具。论文的解法是造"可逆的去分词器"，把尽可能多的预处理痕迹还原掉，并且特别强调它们可逆，所以数据集的对数概率仍然算得出来；论文把它定位为"一种简单的域适配"【可查证：§3.1 原文 invertible de-tokenizers ... can be thought of as a simple form of domain adaptation】。这条的教训很硬：我们为了"不引入分词偏差"而放弃分词，结果不得不为别人的分词偏差写一个逆向器。规避一个偏差，不消除它，只是换了个方向撞上去。

返工二：非英语滤不干净。按 S1.5 的决议，我们主动移除全部非英语网页【可查证：§3.7】。然后语言检测器给出的答案是：WebText 里还剩 10MB 法语【可查证：§3.7 原文 detected only 10MB of data in the French language】。当时这是一条"过滤器没做干净"的坏消息，写进论文时它变成了一条证据（见 S5）。

返工三：评测集自己也不干净。我们在做 CBT 的数据重叠分析时发现，测试集里的一本书——吉卜林的《丛林之书》——就在 WebText 里【可查证：§3.2 原文 Data overlap analysis showed one of the CBT test set books, The Jungle Book by Rudyard Kipling, is in WebText】。处理方式是放弃测试集、改报验证集【可查证：§3.2 原文 we report results on the validation set which has no significant overlap】。这条后来直接催生了 §4 整节——我们知道“要查重叠”这件事，是《丛林之书》教的，不是反过来。

3. 数据规模怎么定的

坦白讲：不是算出来的，是过滤器的边界决定的。

- 抓取始点是全部 Reddit 出站链接，规模是 **4500** 万条链接【可查证：§2.1 原文 these 45 million links】；
- 去重与启发式清洗之后，得到略多于 **800** 万篇文档、总计 **40GB** 文本【可查证：§2.1 原文 slightly over 8 million documents for a total of 40 GB of text】；
- 时间上切成 **2017 年 12 月** 之前的链接，这一版被明确称作 WebText 的“初步版本”【可查证：§2.1 原文 a preliminary version of WebText which does not include links created after Dec 2017】。

“**40GB** 不是上限，是这一次的余量”——这一点有两处独立内证：1. 论文 §3 说所有模型都还在欠拟合 **WebText**，给更多训练时间，留出集的困惑度仍在改善【可查证：§3 原文 All models still underfit WebText and held-out perplexity has as of yet improved given more training time】；2. §4 用 Figure 4 展示训练集与测试集性能一起随模型规模上升而改善，并据此再次得出“即便 GPT-2 在很多方面仍在 WebText 上欠拟合”【可查证：§4 原文】。

这两句是整篇论文在数据轨上的自白：规模没有到顶，是工期和算力到顶了。

【实验轨】

4. 核心问题 → 倒推出需要哪几个实验

我要回答的核心问题有三个，每个都倒逼出一组实验：

核心问题	倒推出的实验	论文落点
容量是不是这件事的关键？	训练四档规模（近似对数均匀），在全部指标上铺出曲线	§3 开头、Table 2、Figure 1（多任务）、Figure 2（CBT）、Figure 3（WSC）、Figure 4（WebText 自身）
零样本到底能不能真做任务？	七个任务探针，每个都用该领域自己的指标	§3.2 CBT、§3.3 LAMBADA、§3.4 WSC、§3.5 CoQA、§3.6 摘要、§3.7 翻译、§3.8 问答
这是任务学习还是记答案？	用 8-gram Bloom 过滤器量化重叠	§4，Table 6 + Figure 5

第三组实验是我在 **S3 v0** 就埋下的那根刺。它的设计细节值得记下来：Bloom 过滤器装 WebText 训练集的 8-gram，字符串先归一化为“只含小写字母数字词、单空格分隔”以提高召回；误报率上界压到 $1e-8$ ，并用 100 万个字符串做验证，命中数为零【可查证：§4 原文三处】。

5. baseline 选谁、最怕被谁比下去

原则：每个任务用它自己领域的既有最好结果，不另造统一 baseline。论文 Table 3 的 SOTA 行来自五个不同来源并逐列标注【可查证：Table 3 caption】。

最怕的三处（按怕的程度排）：1. **One Billion Word Benchmark**。这是我们主动认输的那一列——它是最大的数据集，而且它自己的预处理最有破坏性：句级打乱“移除了全部长程结构”【可查证：§3.1 原文 1BW's sentence level shuffling removes all long-range structure】。我们模型的长处正好是长程依赖，这一列把我们的长处切掉了。2. 摘要。我们心里有数：定性上像模像样，定量上会很难看。3. 翻译。En→Fr 方向我们完全没底，因为语料里非英语是被我们主动删掉的。这一列的预期本来是“随便报个数、承认不行”。

6. 超参数怎么定的

只有一句可查证的交代：每个模型的学习率是人工调的，目标是在 WebText 的 5% 留出样本上取得最好的困惑度【可查证：§3 原文 The learning rate of each model was manually tuned for the best perplexity on a 5% held-out

sample of WebText】。

其余全部无交代：batch 512、context 1024、优化器细节、训练步数、warmup、权重衰减——论文一个数都没给【可查证：§2.3 与 §3 均无对应文字】。这是一篇技术报告在可复现性上最大的缺口，S8 必须把它算成覆盖度缺口而不是幻觉。

7. 消融实验：本论文没有消融表，纪律无法执行

这是本节的结论，也是整轮仿真最重要的一条方法论差异。

GPT-1 有 Table 5（逐任务的微调消融差值），所以它的 S4 可以执行“凡归因必须与消融表逐任务差值对齐”这条纪律——那次正是靠这条纪律，把“辅助目标在小数据上帮助更大”的叙事抓成反例。

GPT-2 全文不存在任何消融表。 全文最接近消融的只有两处，且都不是消融：

1. 去分词器：只给了“对 GPT-2 有 2.5 到 5 的困惑度增益”这个区间【可查证：§3.1 原文】，没有对照表，无法逐行核；
2. **Table 4 的 GPT-2 no hint 行**：这是真正的单变量对照（去掉 TL;DR: 提示），也是全文唯一一处可以逐格做差值的对照——它的差值在 S8 处理。

所以本阶段的归因纪律执行方式是：整批降级。任何“某个设计起了作用”的说法，在本论文里都只能停留在待验猜想，因为没有可对齐的差值表。这不是我们偷懒，是论文没给对齐物。**S8 应把“S4 归因纪律无法执行”本身记为一条结构性发现。**

8. 至少一次“实验崩了”（本阶段负结果重点区）

崩溃一：照抄前人的评测设定，结果被坑。LAMBADA 的既有最好结果是在“受限预测设定”下取得的——模型的输出被约束成只能从上下文里出现过的词里选。我们按最稳的做法照搬了这个设定。它在我们身上起的是反作用：**19%** 的答案根本不在上下文里【可查证：§3.3 原文 For GPT-2, this restriction is harmful rather than helpful since 19% of answers are not in context】。这个坑的性质很重要：不是我们方法有问题，是“继承别人的评测协议”这个动作本身有风险——协议里可能藏着一条只在别人的模型上成立的隐含假设（“答案一定在上下文里”）。

崩溃二：数据重叠把测试集判了死缓。CBT 的《丛林之书》（见数据轨返工三）。排查路径：做分词与语料统计时顺手跑了一次 n-gram 重叠 → 命中 → 只能改报验证集。

崩溃三：目标数据集被前人净化过，而我们的模型没见过净化后的文本。这是数据轨返工一在实验侧的表现：<UNK> 与断开标点让模型在“它明明读过的东西”上表现变差。

9. 本阶段必须吸收的正面硬数字（对照清单，供 S8 使用）

△ 这一节的写法需要单独声明：以下数字属于“最终报出来的结果”，不是“当时的预期”。它们写在这里的唯一目的是让 S8 有据可对——上一轮 GPT-1 的首跑把 GLUE 72.8 对 68.9 整段漏掉了，导致覆盖度缺口没被发现。本节的列表是交付物，不是叙事中的预测，也不得被 **S8** 之外的阶段引用。

（a）主表与核心结果 - 零样本刷新 **8 个** 语言建模数据集集中的 **7 个** 的记录（摘要、§3.1、§7 三处同源）【可查证】；
- Table 3 十列 × 四档模型 + SOTA 行的完整数值矩阵（数值经 S8 第 0 步重算，此处不重复抄录，只登记“必须全数吸收”）；
- LAMBADA 困惑度 **99.8 → 8.63**（摘要口径写 8.6）；准确率无过滤 **52.66%**、加停用词过滤器 **63.24%**，相对既有最好结果提升 **4%**【可查证：§3.3、Table 3】；
- CBT：常用名词 **93.3%**、命名实体 **89.1%**【可查证：§3.2】；
- Winograd Schema Challenge：**70.70%**，比既有最好结果提升 **7%**【可查证：§3.4】；
- CoQA：**55 F1**，在不使用 **127,000+** 条人工问答对的前提下追平或超过 **4 个 baseline** 中的 **3 个**【可查证：§3.5、摘要】。

（b）失败与接近失败的两列（必须吸收，不许只报赢的）
- One Billion Word Benchmark：**42.16**，显著劣于既有结果（SOTA 行 21.8）【可查证：Table 3】；
- 摘要（Table 4，ROUGE F1）：**GPT-2 TL;DR: R-1 29.34 / R-2 8.27 / R-L 26.58 / 平均 21.40**，只“刚刚超过”随机抽 3 句（Random-3 平均 **20.98**），而 SOTA Bottom-Up Sum 平均 **32.75**【可查证：Table 4】；
- 摘要去掉任务提示后平均下降 **6.4 点**（21.40 → 15.03）【可查证：§3.6、Table 4】；
- 翻译：WMT-14 En→Fr **5 BLEU**（略差于双语词典逐词替换），Fr→En **11.5 BLEU**（优于若干无监督基线，但远低于当前最好 **33.5 BLEU**）【可查证：§3.7】；
- 问答：Natural Questions 精确匹配 **4.1%**，最小模型不超过简单基线的 **1.0%**，正文称 GPT-2 “**5.3 倍**”于最小模型；在其最有信心的 **1%** 问题上准确率 **63.1%**；与开放域问答系统的 **30% 至 50%** 区间相比“仍然差得多得多”【可查证：§3.8】。

(c) 重叠与记忆分析 (第三组实验) - 常用 LM 数据集测试集与 WebText 训练集重叠 1–6%，平均 3.2%；这些数据集与各自训练集的重叠平均 5.9%【可查证：§4】；- 1BW 与自身训练集重叠接近 13.2%；WikiText-103 测试集只有 60 篇文章，至少重叠 1.6%【可查证：§4】；- LAMBADA 平均重叠 1.2%；剔除任何重叠的样本后，困惑度由 8.6 变为 8.7、准确率由 63.2% 降至 62.9%【可查证：§4】；- CoQA 新闻域约 15% 文档已在 WebText 中，模型在这些文档上表现好约 3 F1；跨域平均增益约 0.5–1.0 F1【可查证：§4】。

(d) 定性侧的两条 - Winograd：273 个样例中只有 10 个与 WebText 训练集有 8-gram 重叠，其中 2 个是假匹配，剩下 8 个里只有 1 个出现在“泄露答案”的语境中【可查证：§4】；- 三个级别的奇怪事实：<UNK> 在 40 亿字节里只出现 26 次；WebText 里法语只有 10MB；CBT 测试集的一本书在训练语料里【可查证：§3.1、§3.7、§3.2】。

《档案 · S4》

【阶段】S4 数据与实验 (双轨)

【已知事实】

1. 候选语料四个：Common Crawl (被否)、Wikipedia (被主动移除)、单域语料 (不适用)、Reddit 出站链接 (采纳)；Common Crawl 的否决理由是文献抱怨加作者自验的双重质量问题，Wikipedia 的移除理由是它是许多数据集的共同来源、重叠会复杂化分析【可查证：§2.1 原文】
2. 采纳方案：抓取 Reddit 上至少获得 3 个 karma 的全部出站链接，理由是可作为“其他用户是否觉得有趣或有教育意义”的启发式；人工筛选整份网页爬取因昂贵被排除【可查证：§2.1 原文】
3. 规模：4500 万条链接，去重与启发式清洗后略多于 800 万篇文档、40GB 文本；只保留 2017 年 12 月之前创建的链接，该版本被明确称为初步版本【可查证：§2.1 原文】
4. 文本抽取使用 Dagnet 与 Newspaper 的组合【可查证：§2.1 原文】
5. 下游数据集带激进标准化与分词痕迹 (断开标点与缩写、打乱句子)；字符串 <UNK> 在 WebText 的 40 亿字节中仅出现 26 次；解法是可逆去分词器，被定位为一种简单的域适配【可查证：§3.1 原文】
6. CBT 测试集的一本书《丛林之书》在 WebText 中，故改报无显著重叠的验证集【可查证：§3.2 原文】
7. 非英语网页被主动移除，但字节级语言检测仍发现约 10MB 法语残留【可查证：§3.7 原文】
8. 训练了四档近似对数均匀间隔的模型；学习率人工调节以在 WebText 的 5% 留出样本上取得最佳困惑度【可查证：§3 原文】
9. 所有模型仍欠拟合 WebText；训练集与测试集性能随规模同步改善 (Figure 4)【可查证：§3、§4 原文】
10. 记忆检验使用 8-gram Bloom 过滤器，误报率上界 $1e-8$ ，并用 100 万个字符串验证且命中数为零；字符串归一化为小写字母数字加单空格以提升召回【可查证：§4 原文】
11. 论文全文无消融表；最近的两处是去分词器增益区间 (2.5 至 5 困惑度，无表) 与 Table 4 的 GPT-2 no hint 行 (全文唯一可逐格做差值的单变量对照)【可查证：全文】
12. 论文未交代 batch 512 与 context 1024 之外的任何训练超参 (优化器、步数、warmup、权重衰减均无)【可查证：§2.3、§3 均无对应文字】

【合理重构】

- a. 三次返工的真实顺序 (先撞 <UNK> 与分词痕迹、再发现非英语残留、再撞评测集重叠)——依据：论文各节的叙述顺序与“数据重叠分析”这个动作只在 CBT 一节被提及 (重构)
- b. “最怕被谁比下去”的三处排序及其理由——依据：§3.1 对 1BW 预处理破坏性的专门解释、§3.6 对摘要质量的自我贬低、§3.7 对非英语被删除的自陈 (重构)
- c. 40GB 是工期余量而非算出的上限——依据：§3 与 §4 两处独立的“仍欠拟合”表述 (重构程度低，接近论文自陈)

【负结果】

1. Common Crawl 方案被否，死因是文献与自己实验双重验证的质量问题
2. 摘要任务的本体两次接近失败：只比随机抽三句好 0.42 个平均分；去掉任务提示后掉 6.4 分
3. 1BW 一列主动认输，死因是它自身的句级打乱摧毁了长程结构
4. 翻译 En 到 Fr 只有 5 BLEU，略差于词典逐词替换
5. 数据轨三次返工：去分词器逆流、非英语滤不干净、评测集自污染
6. 消融纪律在本论文无法执行，全部组件归因整批降级为待验猜想——本阶段最重的一条负结果 (本阶段负结果占比约 45%)

【未决问题】

1. LAMBADA 上 52.66% 与 63.24% 两个口径如何在成文时处理？(本阶段已挂号，留给 S6 与 S8)
2. 正文的“5.3 倍”与它自己给出的 1.0% 基线无法直接对账，是笔误还是另一个分母？(本阶段已挂号，留给 S8)
3. 四条架构改动永远拿不到动机，S8 如何给它们定级？(沿用 S3 的钩子)
4. 摘要任务只赢随机基线 0.42 分，成文时要不要放在显眼位置？(留给 S6)

【一致性自检】与上一阶段档案无冲突：S3 记“v0 的答案不可定位”与 v2 的上下文接口，本阶段 §3.5 至 §3.8 的接

口约定即为其实例；S3 记“四条架构改动无动机”，本阶段第 12 条进一步确认训练超参同样无交代，方向一致；S1.5 记“多语言被砍”，本阶段 10MB 法语残留即为该决议的后果，并在此明确：该残留后来成为翻译结果的解释材料，不构成对 S1.5 决议的推翻。

【后见之明自检】第 9 节吸收了正面硬数字，属于本阶段设计好的对照清单，已在节首显式声明它不代表当时的预期；本阶段其余部分未以任何曲线走向或结论口吻叙述，Table 3 的完整数值矩阵留待 S8 第 0 步重算后引用——合规。

【修订注·S8 核查·H-G2-04】第 9 节（c）第 1 条原样登记了论文的表述“常用 LM 数据集测试集与 WebText 训练集重叠 1–6%，平均 3.2%”。该区间与论文自己的 Table 6 不符：表中 WebText-train 列的实际范围是 PTB 0.88% 到 enwik8 6.31%【可查证：Table 6】。作为“论文声称的登记”，原样记录本身无错，但必须加注，否则本清单会把论文的口径错误向下游传递。现补注：该区间为论文原话，实际区间为 0.9%–6.3%；平均值 3.2% 复核无误。本条属 S4 的连带风险，严重度 P2。

【修订注·S8 核查·H-G2-05】第 9 节（b）最后一条写作“正文称 GPT-2 ‘5.3 倍’于最小模型”。论文并未写明这个倍数以谁为分母——§3.8 原句只说 GPT-2 answers 5.3 times more questions correctly，紧邻的两个明确数字是 4.1% 与 1.0%。我在登记时擅自补全了口径，属于过度解读。现改为原样登记：“正文称 5.3 倍，未写明比较对象；与它自己给出的 1.0% 基线直接相除只能得到 4.1 倍”（该矛盾由 S7 隔离审稿人独立发现，S8 认定成立）。严重度 P2。

口径三段式 - 目标：把前四个阶段埋下的失败集中引爆，找出这个项目离死掉最近的那一次。本阶段负结果是主角，不是点缀。 - 现状：《档案·S1》《S1.5》《S2》《S3》《S4》。 - 限制：不许编造论文结果层面的失败（论文确实成功了）；只能写过程中真实的挫败类型——方向误判、实现 bug、理论证不出、审稿人预判。

至暗一：深层的模型训不起来（持续约六周）

症状：模型往上堆层数的时候，浅的那几档还能出曲线，深的那几档一上来就发散；把学习率压到很小能稳住，但损失降得比浅模型还慢。换句话说，加参数没有换来收益，只换来了不稳定性。

我当时怎么判断该救还是该弃：判断的依据不是“能不能训起来”，而是“这个不稳定是超参问题还是结构问题”。判定为结构问题的理由很简单——学习率调小能稳住说明这不是数据或目标的问题，是尺度的问题：信息在残差通路上逐层累积，深层拿到的量级和浅层不是一个数量级。

转折：§2.3 里那三刀就是对这个症状的处方——LayerNorm 前移到子块输入（类似 pre-activation 残差网络）、在最后一个自注意力块之后追加一层 LayerNorm、并把残差层权重按 $1/\sqrt{N}$ 初始化缩放【可查证：§2.3 原文三处】。第三刀尤其对症下药：论文那半句话是“account for the accumulation on the residual path with model depth”——“残差通路上的累积”这几个字，正是我当时在日志里看到的东​​西的名字。

△ 但必须在这里扣死一句话：论文没有给这三刀任何动机，也没有引用。上面那段“症状—处方”的对应关系，是我按症状重构的，属于【合理重构】，不是论文的记载。真实的原因可能是这三刀，也可能其中两刀是另一件工作的副产品、或者是为了别的目的顺带加的。这一段是本轮仿真风险最高的一处重构，S8 必须把它列为高危项。

至暗二：我们差点相信“模型会自己从噪声里学”（持续约三周）

Common Crawl 拉下来之后，第一批样本里满屏是不可读的文档。我在 S1.5 的会上说过“我们是在做语言模型，模型自己会从噪声里学”——这句话被我自己的实验数据打回来了。

关键的一击不是“数据脏”，是论文里我们自己写下的这条对照：Trinh & Le 2018 拿到好结果的办法是“只保留与目标数据集最相似的文档”【可查证：§2.1 原文】。这说明连他们那样做的人也认为语料的域匹配比语料的量更重要——如果我们承认这一点，那“靠量硬吃”这条路线的一整条腿就断了。

转折：不是技术突破，是一次立场转换——从“多即是好”改成“多且被筛过才是好”。而筛的办法不能花钱（人工筛选整份爬取“异常昂贵”【可查证：§2.1】），所以只能找现成的人类信号。这就是 S1.5 分歧一的收口动作在技术侧的完整形态。

至暗三：零样本跑出来了，但跑出来的是“合理的废话”（最接近死掉的一次）

这是整个项目最危险的两周。

LAMBADA 的第一版结果出来的时候，我盯着预测看了很久。模型每次都给出一段非常像样的话——语法没错、主题没错、风格没错——但不是题目要那个词。

论文 §3.3 把那次的诊断写得非常克制：多数预测是句子的合法续写，但不是合法的最后一个词，这说明“模型没有利用这个词必须是句子的最后一个词”这一额外且有用的约束”【可查证：§3.3 原文】。

我当时的判断是：这个失败可能是致命的，原因不在评测，在目标函数。语言建模的损失函数从头到尾只知道“整段文本的概率要高”，它从来没有被告说过“这里有一个人在等你给一个词”。如果这就是根本困难，那么零样本这条路的天花板可能就在“合理续写”这一层，永远越不过去。而只要这个怀疑成立，S1 里那三个 naive 想法立刻全都复辟——因为它们至少能报数字。

我用了两个标准决定“救”：1. 这个失败是“能力不足”还是“约束缺失”？判据是：如果给模型加上那个缺失的约束，它会不会立刻变好。会，那就不是能力问题。2. 补救动作会不会污染 **claim**？这是我当时最怕的地方——加一个后处理把答案从候选里挑出来，看起来就是“微调”的软版本。

转折：停用词过滤器【可查证：§3.3 原文 Adding a stop-word filter as an approximation to this further increases

accuracy】。它的性质是"对缺失约束的近似"，不是学习、不是训练、不碰任何参数；而且论文里它被明确写成 approximation，没有伪装成方法的一部分。同时还有第二个更硬的确认：既有的最好结果是在"受限预测"设定下取得的——答案被约束为只能从上下文里出现过的词里选，而我们照抄这个设定之后反而变差，因为 19% 的答案根本不在上下文里【可查证：§3.3 原文】。这个反例救了我：它证明"约束的取舍"不是我们的短板，是这个任务的评测协议本身就有立场；既有的最好结果吃到了那个立场的红利。于是这件事从"我们不行"改判成"口径不同"。这一改判后来直接决定了成文时的写法（见 S6）。

至暗四：唯一的失败是最大数据集（持续到写论文的那天）

1BW 出来的时候是 42.16，显著劣于既有结果。而且它不是在边缘上输，是输了一个量级。

这件事很难消化的地方在于它的方向：我们自己全篇的主轴是"数据越多、模型越大越好"，结果最好的数据反而最差。如果这个反常是随机的，那我们的核心叙事就有裂缝。

我们花了很长时间排查它是不是 bug，最后落到论文 §3.1 的那句解释上：1BW 同时是最大的数据集、又有最有破坏性的预处理——它的句级打乱"移除了全部长程结构"【可查证：§3.1 原文】。

这条把裂缝补上了，补的方式不是"我们没错"，而是"数据规模不是独立的变量，它和预处理捆绑在一起"。一个更大的数据集如果被自己的预处理切碎了长程依赖，它对我们模型的难度可以比一个小数据集更高。这不是一次被挽救的失败，是一次被理解的失败——而理解它的代价是我们必须承认：本文"规模越大越好"这句话是有前提的，前提写在 §3.1 的第三段，而不是标题里。

复盘：这些坑能不能在 S1 就避开？

诚实回答，分三类：

能避开的（三条，都是"本该更谨慎"而不是"运气不好"）：

1. **CBT** 的《丛林之书》重叠。评测集清单定下来的时候，跑一次 n-gram 重叠检查只需要几小时。这一条完全是我们没做功课。事后它反过来催生了 §4 整节——用一个大数据换来一节方法论，是净赚还是净亏，取决于有没有别人先替我们付过学费。
2. **LAMBADA** 的受限预测设定。我们照抄了一个评测协议而没读它的隐含假设（"答案一定在上下文里"）。读一眼前人的评测脚本就能避开。
3. **Common Crawl** 的质量。论文自己引了 Trinh & Le 的抱怨——也就是我们在动手之前，就已经有一份写在纸上的警告，只是被我的"多即是好"压过去了。避开它的代价是要自己写爬虫，那是工期问题，不是认知问题。

不能避开的（两条，属于当年的知识边界）：

4. 深层训练不稳。2018 年这套知识主要散在代码、邮件和口头传播里，没有一篇能引的文献说清"残差累积 + 归一化位置 + 初始化尺度"该怎么配。我们今天能把它写成三段因果链，靠的是事后把日志和处方对起来——当时我面对的就是一片发散的数字。
5. "合理续写 ≠ 合法末词"这个错配。这不是失误，是发现。它只有在跑完之后才看得见，而它一旦被看见就改变了我们对整个零样本路线的理解（S3 v0 那根刺最终长成了 §4）。

最后一条，属于"必须提前预判但不能提前解决"的：

6. 审稿人会说"这不就是把规模推到极限"。这个预判在 S6 里被处理成 §5 的一句外交辞令（把 Hestness 2017 的 scaling 分析拉进来，把"我们只是放大"改写成"我们的结果与该趋势一致并延伸到 10 亿参数以上"）。预判到了，但解决不了——因为那句批评本身是对的。

全局负结果占比统计（截至 S5）

按各阶段叙事正文（不含《档案》块）的汉字数估算：

阶段	负结果占比（估）
S1	约 65%
S1.5	约 55%

S2	约 45%
S3	约 60%
S4	约 45%
S5	约 70%
累计	约 56% (远高于 40% 的下限)

结论：负结果占比达标，且五条最高纪律中"负结果 ≥40%"这一条在本论文上比 GPT-1 更容易满足——因为这篇论文本身承认的失败更多（1BW、摘要、En→Fr、QA、非英语残留、欠拟合）。

《档案 · S5》

【阶段】S5 困难与转折

【已知事实】

1. S2.3 列出三处模型侧改动（LayerNorm 前移、末块后追加 LayerNorm、残差层权重按 1 除以根号 N 缩放），并给出"account for the accumulation on the residual path with model depth"这一描述性表述，但无任何动机句与引用【可查证：S2.3 原文】

2. Trinh & Le 2018 取得最佳结果的方式是只保留与目标数据集最相似的文档；人工筛选整份网页爬取被论文判定为异常昂贵【可查证：S2.1 原文】

3. LAMBADA 的误差诊断：多数预测是合法续写而非合法末词，模型未利用"必须是句末词"这一约束；加停用词过滤器作为该约束的近似可提升准确率【可查证：S3.3 原文】

4. 既有最好结果使用受限预测设定（答案须出现在上下文中）；该限制对 GPT-2 有害，因为 19% 的答案不在上下文里【可查证：S3.3 原文】

5. 1BW 上表现显著劣于既有工作；论文给出的解释是它同时是最大数据集且预处理破坏性最强，句级打乱移除了全部长程结构【可查证：S3.1 原文】

6. 论文 S5 主动把 Hestness et al. 2017 的容量与数据规模分析纳入讨论，并比较自己的结果与该趋势【可查证：S5 原文】

【合理重构】

a. 四周至暗时刻的具体形态、持续时长与"该救还是该弃"的两条判据——依据：S2.3 的三处改动只对"深层不稳定"这一症状成立，S3.3 的误差诊断句是唯一能解释该次危机的原文（重型重构）

b. 深层训练不稳被判定为结构问题而非超参问题——依据：三处改动中有两处（归一化位置、初始化尺度）在性质上只对尺度类问题有效（重构）

c. 1BW 反常曾被当作 bug 排查——依据：S3.1 用整整一段解释该异常，解释的详尽程度暗示它曾被当作疑点（重构）

【负结果】

1. 深层模型发散，持续约六周，靠三处架构改动压住；但这三处改动的动机不可查证

2. 差点采信"模型自己会从噪声里学"，被自己的实验数据打回

3. 零样本首版产出"合理续写而非合法末词"，一度判定可能致命，并一度考虑退回微调路线

4. 1BW 一列显著失败，最终以"规模与预处理捆绑"重新解释

5. 三条本可提前避开但没避开的失误：CBT 评测集重叠未先查、LAMBADA 评测协议未先读、Common Crawl 质量警告已被文献写在纸面上

6. 审稿人会指"只是把规模推到极限"这一预判被确认无法解决，只能改写（本阶段负结果为主体内容，占比约 70%）

【未决问题】

1. 三处架构改动的"症状-处方"重构属于重型重构，S8 如何定级？（交 S8）

2. LAMBADA 的停用词过滤器会如何进入成文叙事？（交 S6）

3. 1BW 的前提条件（规模与预处理捆绑）在成文时要不要写进显眼位置？还是留在 S3.1 第三段？（交 S6）

【一致性自检】与《档案 · S3》《S4》无冲突：S3 已把四处架构与训练改动整批降级为待验猜想，本阶段沿用该降级并给出症状侧的重构，未越过 S3 划定的边界；S4 第 9 节吸收的硬数字未被本阶段当作失败叙事的素材来源（1BW 与摘要的失败在 S4 已作为"最怕被谁比下去"登记，方向一致）。全阶段负结果累计占比约 56%，高于 40% 下限。

【后见之明自检】至暗一至至暗四的时间跨度、心理活动均为重构并以标签声明；未把论文的成功结果当作"我们早就知道会成"的证据；三条可避失误的判定只用"做功课与否"这一外部标准——合规。

【修订注·S8 核查·H-G2-06】至暗一写作"§2.3 里那三刀就是对这个症状的处方"，并称第三刀"尤其对症下药"。这个对应关系的锚点强度被写高了。逐条核：论文 §2.3 中唯一可作描述性锚点的只有 `account for the accumulation on the residual path with model depth` 这半句，它只对应初始化缩放这一条；归一化前移与末端追加 LayerNorm 两处零锚点（连描述性文字都没有，只有做法）。故正确表述应为：三刀中只有一条有描述性半锚点，另两条为零锚点重构。该重构是本轮仿真风险最高的一处，S8 已将其列入幻觉清单第 1 条。严重度 P1。附带更正：《已知事实》第 1 条把"无动机句与引用"并列表述，其中"无引用"对归一化前移一处不成立，详见 S2.md 与 S3.md 的同源修订注。

口径三段式 - 目标：还原叙事策略——同一堆材料，怎么讲才卖得出去。放大了什么、藏起了什么。 - 现状：《档案·S1》至《档案·S5》+ 论文全文。 - 限制：本阶段允许看论文全文；但外交辞令必须标注为外交辞令，不许当成事实陈述。

1. 标题与 abstract 的取舍

标题：Language Models are Unsupervised Multitask Learners

三个决策：

1. 主语是“语言模型”，不是“我们的模型”。换成 `Our Model Learns Tasks Without Supervision` 会立刻把一个现象级发现降级成一次产品发布。用复数主语，claim 的层级从“我们做出来了”升到“这件事本来就成立，我们只是第一个说清楚的人”——这也顺手降低了被指“夸大自然方法”的攻击面：我们没有自研方法，我们只是把规模推到位。
2. 动词用 `are`，不用 `can be`。前者是断言，后者是可行性陈述。
3. `Unsupervised` 而不是 `Zero-Shot`。这是本文最关键的一次用词。全过程其实有一个不零样本的地方——我们给每个任务都写了上下文格式（`TL;DR: A: english sentence = french sentence`，见 S3 v2）。用 `unsupervised` 描述的是没有监督信号，这一条完全站得住；用 `zero-shot` 会被追问“你写的那几个前缀算不算 prompt 工程”。选词的动机是防守，不是形容。

Abstract：放大了三样，藏起了四样

放大： - 开门见山给一个体感强的数字：CoQA **55 F1**，并且紧跟着“不用那 127,000+ 条训练样本”【可查证：Abstract 原句】——这句是全篇最强的一句，因为它把“标了多少数据”这个变量直接扣掉了。 - 一句可被引用的机制断言：容量对零样本任务迁移必不可少，且性能随规模呈对数线性改善【可查证：Abstract 原句】。 - 一个可数的事实：8 个语言建模数据集的 7 个刷新记录【可查证：Abstract 原句】。

藏起：1. 藏起 **63.24** 的真实口径。摘要一个字都没提 LAMBADA 的 63.24% 是靠停用词过滤器拿到的，也没提不加过滤器只有 **52.66%**（那个数字在 §3.3 正文里，而且是以“从 19% 提升到 52.66%”的叙述方式出现的——基线选的是 Dehghani 2018 的 19%，不是 Table 3 自己列的 **59.23%**）。2. 藏起 **1BW** 的失败。摘要把 7/8 说出来，那个 1 是什么，要翻到 §3.1 第三段才知道。3. 藏起摘要与翻译的真实水位。摘要只比随机抽三句高 0.42 个平均分、En→Fr 只有 5 BLEU——摘要里一个字都没有。4. 藏起“这是我们自己的口径”。非英语是我们主动删的（§3.7），但 Fr→En 的 11.5 BLEU 被拿出来当正面结果；这一层因果关系在摘要里不可能看到。

2. 哪个结果放主图、哪个塞进 appendix

主图给了 **Figure 1**：多任务零样本性能随模型规模变化。这张图的选型逻辑很清楚：

- 它同时承载三件事——曲线向上（容量假设）、任务横跨阅读理解/翻译/摘要/问答（广度）、而每个子图里还有一些在低位几乎平的曲线；
- 它把“我们做的不是刷榜”这个信息用图像说完了：有些任务的绝对水平很难看，但趋势线是正的。
- 反过来说：**Figure 1** 是唯一一张能让“表现很差的任务”为论文加分的图。如果那个任务单独出现在正文里，它就是失败；放进这张网格里，它变成“容量是自变量”的证据。这是本文最聪明的一处排版决策。

Table 3 放在主文，十列。列数本身就是一层遮蔽：1BW 在最右边一列，与 7 个成功列并排时被视觉稀释。如果 1BW 单独成表，它就是这篇论文的一个洞。

Table 4（摘要 ROUGE）留在主文，但只用了它的差值。正文引用的是“去掉提示后掉 6.4 分”这个差值，而不是 21.40 这个绝对值——差值证明了“任务提示能召唤任务行为”，绝对值只会告诉读者我们打不过 Seq2Seq。

Table 5（Natural Questions 的 30 条最自信答案）放在主文——因为它的视觉效果是干净的问答对，读感极佳。

塞进 appendix 的是： - **Table 7–11**（小模型与 GPT-2 在同一段上下文上的并排补全）——这是唯一能直观展示“容量带来什么”的材料，但占位太大，只能进附录； - **Table 12**（同上下文的多样补全）、**Table 13**（会说话的独角兽新

闻)——质量高,但它们是"有趣"而不是"有证据",放正文会强化"这只是个会写文章的模型"的印象;- **Figure 5** (生成样本与测试集的 **8-gram** 重叠 **CDF**)——这张图直接回应"是不是背下来的",是本文最硬的一张自证清白图,却被放进了 appendix。理由我当时没写下来,但逻辑是清楚的:把它放正文,等于把"我们可能是在背"这个问题提到台面上讨论;放附录,它就在,但不引导读者去想。这是一次有意的降噪。

3. related work 里的外交辞令(逐句拆)

辞令一:把 Hestness 2017 拉进来当护墙

原句:「Our experiments, while much noisier across tasks, suggest similar trends hold for sub-tasks of an objective and continue into the 1B+ parameter regime.」【可查证:§5】

这句在防什么:审稿人的第一句话——"这不就是把模型做大吗?".怎么防的:先把 Hestness et al. 2017 那篇"深度学习 scaling 是可预测的"经验分析摆进来,然后把自己定位成"该趋势在任务子集上与 10 亿参数以上的延续"。这样"做大"就不再是我们的方法,而是一条已被确立的经验规律,我们的贡献变成了"这条规律的适用范围比想象中广"。**"while much noisier across tasks"**这半句是主动认怂的部分,作用是把"我们的曲线不干净"这件事提前说掉——审稿人提出来的第一遍是攻击,作者自己先说的就是坦诚。

辞令二:把微调留作期货,封住"没跟 BERT 比"的口子

原句:「Given the prior success of fine-tuning GPT, we plan to investigate fine-tuning on benchmarks such as decaNLP and GLUE, especially since it is unclear whether the additional training data and capacity of GPT-2 is sufficient to overcome the inefficiencies of uni-directional representations demonstrated by BERT.」【可查证:§6 末段】

两个动作叠在一句里:1. "we plan to investigate"——把缺席的实验写成计划中的实验。这是 S1.5 分歧二的最终产物;2. "especially since it is unclear whether..."——主动把最不利的可能性说出口:我们的单向表征可能补不上。这句话说完之后,审稿人再提"你们没和 BERT 比"就显得是在复述我们自己的话。

辞令三:抢在审稿人之前认怂两处

原句 A:「in terms of practical applications, the zero-shot performance of GPT-2 is still far from use-able.」【可查证:§6】原句 B:「some inspection of its answers and errors suggests GPT-2 often uses simple retrieval based heuristics such as answer with a name from the document in response to a who question.」【可查证:§3.5】

A 是全局降调:把摘要里那个"promising path"立刻压回"远不可用"。这一句的作用是让所有"你们这个不行"的批评在提出时都失去杀伤力——我们已经说了。**B** 是针对 **CoQA** 结果的拆台自认:我们自己的 55 F1 有一部分是靠"问 who 就从文档里挑个人名"这种检索式启发式拿到的。在答辩里主动交出这一点,比被人查出来代价小得多。

辞令四:把"我们的语料更好"说成方法论要求

原句:「While this is a pragmatic approach to improve performance on a specific task, we want to avoid making assumptions about the tasks to be performed ahead of time.」【可查证:§2.1】

这是对 Trinh & Le 的处理:没有一句批评。把对方的做法称作"pragmatic",然后只说"我们想避免预先假设任务"——把一次分界说成一次取向差异,把"你的语料带任务偏好"这句话留给读者自己补。这是 S2 那个惊魂时刻留下的最直接影响。

4. 藏起来最大的一样:整篇没有消融表

前面三条都是可控的措辞。真正被藏起来最大的一样东西,是这篇论文从头到尾没有一张消融表。

- §2.3 的四条改动(归一化位置、末端归一化、初始化尺度、context 与 batch)没有逐组件对照;

- §2.2 的字节级 BPE 与那条例外合并规则没有消融；
- 最接近的两处对照只有：去分词器（只给“2.5 到 5 困惑度”这个区间，没有表）和 Table 4 的 no hint 行。

结果是什么？读者会自然假定每一个写出来的设计都是必要的——因为论文的体例本身就是一种暗示。而实际上，这四条改动里哪些真的起了作用、哪一条是顺带加的，这篇论文永远没有回答。

这是我在 S4 第 7 条把它写成“结构性缺口”而不是“我们的疏忽”的原因：把它说成疏忽，就是在暗示“我们本来能做而没做”；真实情况是，在做这篇论文的时候，我们并不认为这些设计需要单独证明——我们赌的是四档规模曲线本身，而不是任何单点消融。赌注下在曲线上，是这篇论文的方法论特征。

《档案·S6》

【阶段】S6 成文

【已知事实】

1. 标题为 Language Models are Unsupervised Multitask Learners【可查证：论文首页】
2. 摘要含三处放大：CoQA 55 F1 且不使用 127000 以上训练样本、容量对零样本任务迁移必不可少且性能随规模对数线性改善、8 个语言建模数据集中 7 个刷新记录【可查证：Abstract 三句原文】
3. S5 把 Hestness et al. 2017 的容量与数据规模分析纳入讨论，并自陈“while much noisier across tasks”【可查证：S5 原文】
4. S6 末段承诺后续研究 decaNLP 与 GLUE 的微调，并自陈单向表征的劣势能否被数据量与容量补上尚不清楚【可查证：S6 原文】
5. S6 自陈零样本性能距离可用还很远【可查证：S6 原文】；§3.5 自陈 CoQA 的答案与错误显示 GPT-2 常用检索式启发式（如 who 类问题从文档里取人名）【可查证：§3.5 原文】
6. §2.1 对 Trinh & Le 的处理用 pragmatic 一词定性，随后只声明本方要避免预先假设任务【可查证：§2.1 原文】
7. Table 7 至 Table 11 为小模型与 GPT-2 的并排补全样本，位于 Appendix A；Table 12 为多样补全；Table 13 为会说话的独角兽新闻补全【可查证：Appendix A 各表 caption】
8. Figure 5 为生成样本与测试集的 8-gram 重叠 CDF，位于 Appendix A【可查证：Figure 5 caption 与所在节】
9. Table 4 的正文引用重点是“去掉任务提示后平均下降 6.4 点”这一差值【可查证：§3.6 原文】
10. 论文全文无消融表【可查证：与 S0 第 6 条同源】

【合理重构】

- a. 标题主语用“语言模型”而非“我们的模型”的动机是降低攻击面；动词用 are 不用 can be——依据：全文反复以复数主语陈述一般性结论（Abstract、§7）（重构）
- b. 选 unsupervised 而非 zero-shot 是出于防守（过程本身有任务上下文格式）——依据：§3.5 至 §3.8 的四处格式均需人工书写（重构）
- c. Figure 1 的网格排版使低分任务转化为容量假设的证据；Table 3 的十列并排稀释了 1BW 的失败——依据：两图表的结构与 1BW 所在列位置（重构）
- d. Figure 5 放进附录是为了不主动引导读者想到记忆问题——依据：图的存在性与所在位置（重构）
- e. S6 末段那句微调承诺是 S1.5 分歧二的产物——依据：与 S1.5 已记录的决议同向（重构）

【负结果】

1. 在成文阶段被舍弃的备选标题（以“我们的模型”为主语、以 zero-shot 为核心词）各一条，死因是抬高攻击面与自证负担
2. 备选方案“把 1BW 单独成表并在摘要点名”被否，死因是与 7/8 的主叙事冲突
3. 备选方案“把去分词器增益补成一张消融表”被否，死因是工期（这条被否得很可惜，它是本论文唯一一本可以低成本补上的消融）
4. 备选方案“把停用词过滤器的两个数字都写进摘要”被否，死因是摘要承载不了口径解释
5. 全文无消融表这一形态被保留，其后果由 S8 结算
（本阶段负结果占比约 42%，主要来自被否的成文备选方案）

【未决问题】

1. 摘要放大三处、藏起四样的取舍清单，S8 如何逐条核对是否越界？（交 S8）
2. LAMBADA 的两个口径在正文里的写法（19% 起步 vs Table 3 的 59.23 起步行）是否构成自相矛盾？（交 S8）
3. 无消融表这一形态在覆盖度缺口里应定位为结构性缺口还是省略？（交 S8）

【一致性自检】与《档案·S5》无冲突：S5 第 6 条记录“审稿人可指只是把规模推到极限”这一预判无法解决只能改写，本阶段辞令一即该改写的落点，处理方向一致；S5 未决问题 2、3 在本阶段分别给出了答案（LAMBADA 的过滤器以正则

过滤器形式进入 §3.3 而非摘要；1BW 的前提条件留在 §3.1 第三段而非标题），两处均属保守处理，不回退到更夸张的写法。

【后见之明自检】本阶段允许看全文，故所引均为论文实测表述；但所有“当时的排版/选词动机”一律标为重构，未把事后解读写成作者自陈——合规。

【修订注·S8 核查·H-G2-07】第 2 节写 Figure 1“每个子图里还有一些在低位几乎平的曲线”。该细节无法核验：Figure 1 在论文中是图像，文本提取只得到 caption，图内曲线形态不可读【可查证：gpt2.txt 第 94–96 行为 Figure 1 caption，无坐标数值】。该判断的真实依据是 §3.7（En→Fr 仅 5 BLEU）与 §3.8（QA 4.1%，远低于 30–50% 区间）两处正文水平，不是图内观察。现改为按正文水平推断并注明论据来源。严重度 P2（论据来源错位）。顺带记一条提取限制：本论文的 Figure 1–5 全部无法从纯文本核验，S8 对图相关的断言一律只能回溯到 caption 或正文旁证。

【修订注·S8 核查·H-G2-08】第 2 节两处“唯一”过强：（a）“Figure 1 是唯一一张能让表现很差的任务为论文加分的图”——Figure 4 同样具备该性质（训练集与测试集性能一起上升，用来回应“是不是背下来的”）【可查证：§4 与 Figure 4 caption】；（b）“Table 7 至 Table 11 是唯一能直观展示容量带来什么的材料”——Figure 2 与 Figure 3 也各自展示容量与性能的关系【可查证：两图 caption】。现分别改为“最有效地”“体量最大的”表述。严重度 P2。

口径三段式 - 目标：用隔离视角攻击这篇论文，再由作者回应。 - 现状：《档案·S1》至《档案·S6》+ 论文全文。 - 限制（本论文专属，见《档案·S0》风险2）：**GPT-2** 从未经过正式同行评审。真实的把关发生在两处——四位草稿读者的内部反馈【可查证：Acknowledgements】，以及发布前的误用风险评估【可查证：论文外：2019 年分阶段发布安排；论文脚注 5 只承诺公开小模型】。故本阶段的“审稿人”设定为投稿前内部/同行草案评审 + 发布风险评估，不虚构某个会议的评审流程。

0. 隔离实现说明（可核验）

审稿由隔离子代理完成：子代理只拿到论文纯文本文件路径（`paper-sim/GPT-2/gpt2.txt`），提示词中不含任何《档案》内容、不含 S1-S6 的任何叙事、不含本文档的存在。子代理输出在下面第 1 节原样保留，未做删改。

1. 审稿意见（隔离会话原始输出，原样保留）

论文：*Language Models are Unsupervised Multitask Learners*（按普通投稿评审）

主要缺陷（Major Weaknesses）

MW1 — LAMBADA 的 SOTA 声明依赖任务特定后处理，与“零样本、不改参数/结构”的核心卖点自相矛盾。§3.3 报告 LAMBADA 准确率时给出两个数字：无 stop-word 过滤为 52.66%，加过滤后为 63.24%。而 Table 3 的 SOTA 行 LAMBADA(ACC) = 59.23（Hoang et al. 2018 的受限预测设定）。复算： $52.66 < 59.23 < 63.24$ ，且 $63.24 - 59.23 = 4.01 \approx$ 文中“by 4%”。即零样本、不加任何后处理的 **GPT-2** 并未超过 **prior SOTA**；其 SOTA 声明完全由仅用于 LAMBADA 的人工启发式（stop-word filter）支撑。这与摘要与 §1 反复强调的“without any parameter or architecture modification”直接冲突。

MW2 — 摘要称“competitive”的摘要任务，定量上仅略优于随机抽句基线。Table 4 中 GPT-2 TL;DR 的 R-AVG = 21.40，Random-3 = 20.98，差 **0.42**；对比 SOTA（Bottom-Up Sum）32.75，差 **-11.35**。R-1 单指标：29.34 vs 28.78 差 0.56，vs SOTA 41.22 差 **-11.88**。§3.6 自己承认“just barely outperforms selecting 3 random sentences”，但摘要与 §1 仍以“competitive, and state of the art results depending on the task”将摘要与真正 SOTA 的零样本语言建模任务并列呈现，易误导。

MW3 — §3.8 的“5.3 倍”与文中 1.0% 基线无法对账。 §3.8：GPT-2 EM = 4.1%，简单基线 = 1.0%，正文却称“GPT-2 answers 5.3 times more questions correctly”。复算 $4.1 / 1.0 = 4.1$ ，而非 5.3；要在文中数字下得到 5.3× 需基线 = $4.1/5.3 = 0.77\%$ ，与明示的 1.0% 不符，且论文未说明 5.3× 的相对基准。此外，“model capacity has been a major factor”仅由两点支撑；Table 3 已给出 4 档容量在 10 个指标上的完整曲线，NQ 却只给两端，345M/762M 的 NQ 准确率缺失。

次要意见（Minor Comments）

MC1 — §4 / Table 6 称测试集与 WebText 的 8-gram 重叠“between 1–6% ... average 3.2%”。但 Table 6 的 WebText-train 列含 0.88%（PTB）与 6.31%（enwik8），均落在 [1,6] 之外；平均 3.2%/5.9% 复核无误，但区间下界表述与表内不符。

MC2 — §3.1 称 de-tokenizer 带来“gains of 2.5 to 5 perplexity for GPT-2”，但 Table 3 仅报告已去分词后的 perplexity，未给去分词前原始值，读者无从核验该增益区间。

Overall Recommendation：Weak Reject（borderline）。

附：自算校验（子代理独立复算，节选）— Table 3 十列 × 五行的完整矩阵已重建；“7 out of 8”复核成立（以数据集为单位共 8 个，仅 1BW 未超， $42.16 > 21.8$ ）；Table 4 六行的 R-AVG 全部等于 $(R-1+R-2+R-L)/3$ ，无误差；Table 6 两个平均值 3.2% 与 5.9% 复核无误；§3.6 的 6.4 点下降复核为 $21.40 - 15.03 = 6.37 \checkmark$ ；LAMBADA 的 8.6 与 63.2% 与 Table 3 的 8.63 与 63.24 自洽 $\checkmark$ ；Winograd 的 +7%（无表可核）、CoQA 的 55 F1 与 3/4 baseline（无表可核）、翻译的 5/11.5/33.5 BLEU（无表可核）均列为“正文声称、无表支撑”。

2. rebuttal (作者视角, 2019 年 1 月)

总纲一句：我们接受其中三条的表述问题，接受两条的口径澄清，但对其中一条的核心指控提出反对——反对的理由不是我们没错，而是审稿人对 **claim** 的界定比论文本身更宽。

对 **MW1**：部分接受，但反对"自相矛盾"的定性

据理力争的部分：论文 §1 的原句是"without any parameter or architecture modification"——它限定的是参数与架构，不是解码过程。停用词过滤器不训练任何东西、不动任何权重、不引入新结构 (§3.3 明写它是 "an approximation")。说它与"零样本"矛盾，等于要求零样本也必须使用最朴素的解码方式——这个要求本文从未承诺过，而且它会把所有基于解码策略的工作一并否掉。

接受的部分：审稿人指出的呈现顺序问题是对的。正文是"19% → 52.66% → 加过滤器 → 63.24%"这个顺序，读者沿路读下来会以为 59.23 这个对照不存在，而它明明就写在 Table 3 的 SOTA 行上。我们接受把 **52.66%** 与 **59.23%** 的对照提到 §3.3 第一句。

反驳一个字都不改的部分：撤掉 63.24%。Table 3 是零样本结果表，63.24% 是在同一套零样本权重上得到的，放进去是口径一致的；撤掉才是口径不一致。

对 **MW2**：接受，但要求审稿人读完整段

接受：摘要里"competitive"这个词承载不了 Table 4 的实际水位，我们接受在摘要中不把摘要任务与语言建模的 SOTA 并列。

据理力争：审稿人引用的 "competitive, and state of the art results depending on the task" 出自 §1 而非摘要，且这句话本身就是分层的——三个形容词对应三个层级 (promising / competitive / state of the art)，"depending on the task" 是明确的限定语。§6 也已经自陈摘要"rudimentary"、整体"far from use-able"。

新实验回应：不补实验。理由是——我们已经知道补不出好结果：摘要任务的瓶颈是解码目标 (ROUGE 是词重叠指标) 与生成式输出之间的错配，不是容量。§3.6 里我们已经诊断了它的具体失误形态 (只关注文章近处内容、混淆具体细节，例如车撞了几辆、logo 在帽子上还是衬衫上)。补一个更大的模型不会改变诊断，只会烧钱。我们的处理是把错误案例放进 Table 14，让读者自己看瓶颈在哪。

对 **MW3**：完全接受，这是我们的错

认怂：4.1% 与 1.0% 直接相除得 4.1 倍，而正文写 5.3 倍，这是表述缺陷，不是口径差异。5.3 倍的分母是最小模型自身的准确率，而这个数字正文根本没给出来，读者只能拿 1.0% 去算，算出 4.1 与文中不符。修改：正文补上最小模型的准确率，并明确 5.3 倍比较对象是"最小模型"而非"简单基线"。

关于受控消融：审稿人问得很准——NQ 只给了最小模型与 GPT-2 两端。接受这条批评，但不补实验。理由：NQ 的参考数字 (4.1%) 本身低于随机猜测量级 (开放域问答系统的区间是 30–50%)，在这个量级上再花四份算力画一条曲线，得到的是一条从 0.77% 到 4.1% 的线——它证明的仍然是同一件事 (容量是因素)，而成本是四份最大模型的完整评测。我们把结论保留为单点陈述，并在 §6 明确写"模型只有在容量足够时才开始超过平凡基线"这一前提。

对 **MC1**：接受，改数字

把 "between 1-6%" 改为实际区间。这是一次纯粹的数字表述失误：求平均的时候是对的，写区间的时候把 **0.88** 和 **6.31** 四舍五入成了 **1** 和 **6**。

对 **MC2**：接受形式批评，但拒绝补表

"2.5 到 5 困惑度"这个区间来自同一批权重在去分词前后的内部对比，它是对的但不可核。审稿人说得对：不可核就等于没有。我们的处理是保留这半句并明确它是内部测量值——补一张表的成本不高，但它会引出"为什么去分词器的效果在不同数据集上差异这么大"这个问题，而那个问题会把 §3.1 从一节变成三节。我们选择承认不可核，而不是补一张会引发连锁追问的表。这是一次有意选择的不完整。

3. rebuttal 落地情况对照 (诚实性要求：承诺与最终稿必须分开记)

△ 本节是 S7 的关键交付：**rebuttal** 是"当时写的"，落地与否必须另立一节核对，不许混着读。

条目	rebuttal 承诺	最终稿实际	判定
MW1	把 52.66% 与 59.23% 的对照提到 §3.3 第一句	§3.3 首句仍是"从 99.8 到 8.6 困惑度"，随后才出现 19% → 52.66%； 59.23 只在 Table 3 里，正文未点出对照	未落地
MW2	摘要不把摘要任务与语言建模 SOTA 并列	§1 原句保留；§6 已有 "rudimentary"、"far from use-able" 的降调	部分已落地（降调在 §6 而非摘要，且这可能是先有的）
MW3	补上最小模型准确率，明确 5.3 倍的分母	正文仍只有 4.1%、1.0%、5.3 倍三个数字，最小模型的准确率始终未出现	未落地
MW3 附加	不补 NQ 的受控曲线	未补	与承诺一致
MC1	把 1–6% 改为实际区间	仍为 "between 1-6%"	未落地
MC2	保留区间并标明为内部测量值	仍为 "We observe gains of 2.5 to 5 perplexity"	未落地

统计：5 条可落地的修改承诺中，0 条完全落地，1 条部分落地（且可能不是本 **rebuttal** 的产物）。
这条统计本身是 S7 最有价值的产出。它说明一件很反直觉的事：在这一篇论文上，**rebuttal** 不是修改流程的一环，而是一次"说完就完了"的表述。原因不外三个：这是一份技术报告，没有 AC 会来催 camera-ready；论文的核心叙事不依赖任何被质疑的那几条；以及——最诚实的一条——上面五条里有四条是"补一个数字"，而作者当时更想赶在发布窗口前把 6.4 万亿字节级别的实验收尾。
留给 **S8** 的核查任务：**S8** 必须把本节这 6 行逐条复验，并判断"未落地"是否已在 **S6** 的叙事取舍清单里被预告过。

《档案 · S7》

【阶段】S7 审稿与 rebuttal

【已知事实】

1. 审稿人由隔离子代理扮演，输入仅含论文纯文本路径，不含任何档案内容，输出原样保留于本文件第 1 节【可核验】

2. 审稿人给出三条 major weakness 与两条 minor comments，总评 Weak Reject【可查证：本文件第 1 节】

3. 审稿人独立复算确认无误的项目包括：Table 3 的 7/8 判定、Table 4 全部 R-AVG 的自治、Table 6 两个平均值（3.2% 与 5.9%）、§3.6 的 6.4 点下降、LAMBADA 的 8.6 与 63.2% 自治【可查证：第 1 节附节】

4. 审稿人指出的问题中，论文原文可核实的硬冲突为两条：§3.8 的 5.3 倍与 1.0% 基线无法对账；§4 的 1–6% 区间与本表 0.88% 与 6.31% 不符【可查证：§3.8 与 §4 原文】

5. 论文从未经过正式同行评审；真实把关为草稿读者反馈与发布风险评估【可查证：Acknowledgements 与脚注 5，另见论文外公开的分阶段发布安排】

6. rebuttal 的 5 条可落地修改承诺在最终稿中 0 条完全落地、1 条部分落地；MW3 与 MC1 两处硬冲突在最终稿中未修【可查证：本文件第 3 节逐行对照，对照物为论文原文】

【合理重构】

a. 审稿人被设定为投稿前内部同行草案评审加发布风险评审——依据：S0 已确认的非投稿形态与脚注 5 的 small 一词（重构）

b. rebuttal 中"不补 NQ 受控曲线""不补去分词器表"两处拒绝的真实动机被写为成本与连锁追问——依据：论文正文对这两处均无补充材料的痕迹（重构）

c. rebuttal 承诺普遍未落地归因于技术报告的流程性质与发布窗口——依据：三条候选原因中，前两条可由论文形态查证，第三条为重构（重构）

【负结果】

1. 三条 major weakness 中，一条被完全接受（5.3 倍表述）、一条部分接受（摘要任务的水位呈现）、一条被部分力争（LAMBADA 的零样本界定）

2. 两条 minor comments 形式接受但均未落地

3. 五条修改承诺最终 0 条完全落地，本阶段因此不产生任何对论文的实质修改

4. 本阶段的"评审"不是真实同行评审的替代物，其结论不可用于论证论文的学术质量，只能作为叙事审计材料（本阶段负结果占比约 50%，主要来自承诺未落地这一整体性失败）

【未决问题】

1. 第 3 节的 6 行落地对照必须由 S8 逐条复验；此外 S8 还需判断审稿人是否漏掉了某些硬冲突（本阶段无法自证）【交 S8】
 2. 5.3 倍与 1-6% 两处硬冲突在最终稿中存活，S8 需给它们定级【交 S8】
- 【一致性自检】与《档案 · S6》无冲突：S6 第 4 条记录"摘要放大三处、藏起四样"，本阶段 MW1 与 MW2 正是对该取舍的攻击，两处指向同一批文字，方向一致；S6 未决问题 2（LAMBADA 两个口径是否自相矛盾）在本阶段获得审稿人的独立判定与作者的回应，处理一致。
- 【后见之明自检】审稿人未获得任何档案信息，其结论由独立复算得出；rebuttal 的"据理力争"部分改写了立场但均引论文原句为据，未使用 S8 将产出的核查结论——合规。

S8 · 对照复盘（幻觉总检查）—— GPT-2 科研全仿真

口径三段式 - 角色：第三方核查员，不再是作者。本阶段不写第一人称。 - 目标：把前七个阶段的叙事与论文真实内容逐项对照，产出三张表 + S7 专项核查 + 误差报告。 - 输入：全部《档案》+ 论文全文。 - 限制：第 0 步必须在读 S1-S7 叙事之前完成，否则会被自己的叙事锚定（GPT-1 首跑验证过这一点）。

0. 第 0 步：先重算论文自己的趋势表（在读叙事之前）

0.1 隔离实现

本步由独立子代理完成：只给论文纯文本路径（`paper-sim/GPT-2/gpt2.txt`），提示词要求“摘出所有概括句 → 找到支撑它的表 → 逐行做差值 → 报告反例”，不给任何档案、不给本项目的任何叙事。子代理输出与本节结论一致，原始清单已归档在 `paper-sim/GPT-2/_s8_step0_auditor.txt`。

0.2 重算出的三张核心表

Table 3（零样本，10 列 × 5 行）

行	LAMBADA PPL	LAMBADA ACC	CBT- CN	CBT- NE	WikiText2	PTB	enwik8	text8	WikiText103	1BW
SOTA	99.8	59.23	85.7	82.3	39.14	46.54	0.99	1.08	18.3	21.8
117M	35.13	45.99	87.65	83.4	29.41	65.85	1.16	1.17	37.50	75.20
345M	15.60	55.48	92.35	87.1	22.76	47.33	1.01	1.06	26.37	55.72
762M	10.87	60.12	93.45	88.0	19.93	40.31	0.97	1.02	22.05	44.575
1542M	8.63	63.24	93.30	89.05	18.34	35.76	0.93	0.98	17.48	42.16

Table 4（摘要 ROUGE F1）：Bottom-Up 32.75 / Lede-3 31.55 / Seq2Seq+Attn 23.99 / GPT-2 TL;DR 21.40 / Random-3 20.98 / GPT-2 no hint 15.03。六行 R-AVG 全部等于 (R-1+R-2+R-L)/3，逐行验算无误差。

Table 6（8-gram 重叠率 %）

数据集	自身训练集	WebText 训练集
PTB	2.67	0.88
WikiText-2	0.66	1.63
enwik8	7.50	6.31
text8	2.34	3.94
WikiText-103	9.09	2.42
1BW	13.19	3.75

0.3 反例清单（论文概括句 vs 论文自己的表）

#	论文的概括句	位置	逐行差值算出的反例
R-1	"performance steadily improves as model size is increased"	§3.2	CBT-CN 列在 762M→1542M 不升反降：93.45 → 93.30（-0.15）。同一节的"new state of the art 93.3%"实际上低于同表 762M 的 93.45。

R-2	"between 1-6% overlap with WebText train"	§4	WebText-train 列实际区间 0.88% (PTB) 到 6.31% (enwik8) ; 平均值 3.2% 复核无误 (18.93/6=3.155) 。
R-3	"many datasets have larger overlaps with their own training splits"	§4	逐列比较有 2 个反例 : WikiText-2 自身 0.66% < WebText 1.63% ; text8 自身 2.34% < WebText 3.94% 。平均值 5.9% 复核无误 (35.45/6=5.908) 。
R-4	"just barely outperforms selecting 3 random sentences"	§3.6	聚合 R-AVG 成立 (21.40 > 20.98 , 差 0.42) , 但 R-2 单指标反例 : GPT-2 TL;DR 8.27 < Random-3 8.63 。
R-5	"Large improvements are noticed on small datasets such as Penn Treebank"	§3.1	特指大模型成立 ; 117M 在 PTB 上 65.85 > SOTA 46.54 , 反而更差。
R-6	"consists of documents from 7 different domains" (§3.5) vs "the average performance over 5 different domains" (§4)	§3.5 / §4	论文内部两处域数不一致 (7 vs 5) , 至少一处表述不严。本轮两个隔离视角与我方叙事三方均漏检, 由本阶段补上。

0.4 复核通过的 (供信心校准)

7/8 的判定成立 (以数据集为单位的 8 个中仅 1BW 未超 , 42.16 > 21.8) ; LAMBADA 99.8 → 8.63 与摘要"8.6"一致 ; 63.24 – 59.23 = 4.01 ≈ "by 4%" ; §3.6 的 6.4 点下降 = 21.40 – 15.03 = 6.37 ; 1BW 自身重叠 13.19% ≈ "nearly 13.2%" ; WikiText-103 的 1/60 = 1.67% ≈ "at least 1.6%" ; 1542M/117M = 13.18 倍 > "over an order of magnitude" ; LAMBADA 8.6 → 8.7 与 63.2% → 62.9% 与 Table 3 的 8.63 / 63.24 自洽。

0.5 一项机器核查 (Table 5 的对错计数)

S7 的隔离审稿人数出 Table 5 "22 ✓ / 8 ✗ = 73.3%" , S8 第 0 步的审计子代理数出"21 ✓ / 9 ✗ = 70%"。本阶段用脚本直接数符号码位判定 : \x13 出现 **22** 次、\x17 出现 **8** 次 , 共 30 条【可核验 : paper-sim/GPT-2/verify_s8.txt】。独立佐证 : 末条 (45.2% , "Who played john connor in the original terminator? → Arnold Schwarzenegger") 为 \x17 , 该答案确实错误 , 故 \x17 = ✗、\x13 = ✓。采信 **22/8**。(另注 : 更早的文本读取中有 4 行出现 \u2713 字形 , 经查是题干里 fi、ff 连字造成的假象 , 与对错标记无关——这是本论文 PDF 文本提取的一个陷阱 , 记录备查。) 另 : ablation / ablations / Ablate 在全文出现 **0** 次 , S0 与 S6 的"无消融表"判断成立。

1. 【对上了】叙事与论文一致的点 (24 组)

#	叙事中的判断	阶段	论文依据
1	核心 claim 的三处同源表述	S0	Abstract / §1 / §7
2	论文是技术报告而非会议投稿	S0 / S7	无 venue 字段 ; Acknowledgements 只列草稿反馈人
3	全文无消融表	S0 / S6	ablation 出现 0 次 (机器核查)
4	监督目标与无监督目标同式、全局最小点重合	S1 / S3	§2 原句
5	预备实验 : 能做但比显式监督慢得多	S1 / S3	§2 原句
6	多任务最激进的两项只训 10 与 17 个 (dataset, objective) 对	S1 / S2	§1 原句
7	语言可把任务、输入、输出表示为符号序列	S1 / S3	§2 原句 (含 translate to french 样例)
8	互联网信息被动可得、不需交互	S1	§2 对 Weston 2016 的定位
9	Common Crawl 被否、改用 Reddit 3-karma 策展	S1.5 / S4	§2.1 原句 (含 unintelligible 的引用)
10	人工筛选整份爬取"异常昂贵"	S1.5 / S4	§2.1 原句
11	拒绝"对任务做预先假设"是与 Trinh & Le 的分界	S2 / S6	§2.1 原句

12	Liu 2018 的跨语言译名发现是更具启发性的前例	S2	§5 原句
13	字节级 BPE：基础词表 256、禁跨类合并、空格例外	S3	§2.2 原句（含 dog 的四种形态）
14	码点 BPE 需 13 万以上基础词表；当时常用 32k–64k	S3	§2.2 原句
15	纯字节级 LM 在 1BW 上不及词级，作者自验亦然	S3	§2.2 原句
16	词表扩至 50257	S3	§2.3 原句
17	四处任务接口约定（A: / TL; DR: / english sentence = / 问答样例做种）	S3	§3.5、§3.6、§3.7、§3.8 逐句
18	LAMBADA 的误差是“合法续写非合法末词”	S3 / S5	§3.3 原句
19	WebText：4500 万链接 → 800 万文档 / 40GB；截止 2017-12	S4	§2.1 原句
20	抽取器 Dragnet + Newspaper	S4	§2.1 原句
21	<UNK> 在 40 亿字节里只出现 26 次；去分词器被定位为简单域适配	S4	§3.1 原句
22	《丛林之书》在 WebText 中，故 CBT 改报验证集	S4 / S5	§3.2 原句
23	非英语被主动移除但残留约 10MB 法语	S4 / S5	§3.7 原句
24	所有模型仍欠拟合 WebText	S4	§3 原句 + §4 的 Figure 4 论述

2. 【编圆了但论文没这回事】幻觉清单（10 条）

#	出自	叙事断言	实况	严重度
H-G2-02	S2 已知事实 7、S3 正文、S5 已知事实 1	"§2.3 的架构改动没有任何引用"	§2.3 对归一化前移明确引用 Ba et al., 2016 与 He et al., 2016	P0
H-G2-06	S5 至暗一	"§2.3 里那三刀就是对这个症状的处方"	三刀中仅"1/N 缩放"有描述性半锚点（account for the accumulation on the residual path），另两刀零锚点	P1
H-G2-09	S3 v0 第 3 层死因	"这一层……后来它变成了整整一节（§4）"	在一个明令"不许有后见之明"的阶段内泄漏了未来产物	P1（后见之明泄漏）
H-G2-07	S6 §2	Figure 1"每个子图里还有一些在低位几乎平的曲线"	Figure 1 是图像，纯文本只提取到 caption；该判断的真实依据是 §3.7 与 §3.8 的正文水平	P1（论据错位）
H-G2-01	S1 合理重构 a	"BERT 是唯一被当作对标对象引用的同期工作"	Universal Transformer 在 §3.3 被引为对照；Transformer-XL 是 Table 3 若干列的 SOTA 来源	P2
H-G2-03	S3 合理重构 b	v1 死路顺序"接近论文叙述序的还原"	§2.2 实际叙述序为"字节级→BPE→码点问题→禁跨类合并"，与所写相反	P2
H-G2-04	S4 §9(c)	区间"1–6%"	Table 6 实际 0.88%–6.31%（照抄论文口径，未加注）	P2
H-G2-05	S4 §9(b)	"5.3 倍于最小模型"	论文未写明分母；与 1.0% 相除只能得 4.1 倍	P2
H-G2-08	S6 §2	两处"唯一"	Figure 4 与 Figure 2/3 同样具备所声称的性质	P2
H-G2-10	S4 崩溃三	"目标数据集被前人净化过"	论文归因于数据集自身的激进标准化，未归因于"前人"的行为	P2

严重度复核说明：H-G2-02 在 S2/S3 的修订注中初判为 P1，本节复核后上调为 **P0**——“论文没有任何引用”这一断言

被论文原文直接否定，与 GPT-1 首跑的 H1（“全文未提 GLUE”而实际四处出现）属同一形态：都是把“某信息不存在于我的注意范围”写成了“不存在于论文”。该升级已由 H-G2-02b 修订注在 S2.md 中同步。

分布：P0 共 1 条（1.8%）、P1 共 3 条（5.5%）、P2 共 6 条（10.9%），合计 10 条 / 约 55 条带标签的实质断言 = **18.2%**。

与 GPT-1 首跑的对照（这是本系统自己的误差报告）：

指标	GPT-1 首跑	GPT-2 本轮	变化
带标签实质断言	约 60 条	约 55 条	—
P0–P2 合计占比	17%	18.2%	持平略升
其中 P0（与论文事实直接矛盾）	2 条（3.3%）	1 条（1.8%）	≈ 减半
形态	"全文未提 GLUE"	"改动没有任何引用"	同一形态，均属"缺席断言"

结论（诚实版）：模板修订压住了事实性错误的绝对数量（P0 减半），但压不住“加了标签之后话说太满”这一层——6 条 P2 全部是同一个毛病：标签贴对了（确实标了【合理重构】或照抄了论文），但正文的语气是断言式的。这说明纪律条款的作用边界在“是否标注”，不在“标注之后的措辞强度”。建议的模板改动见本节末。

3. 【论文有而叙事漏了】覆盖度缺口

3.1 硬数字覆盖：S4 第 9 节的清单执行程度

S4 清单项	是否被 S5–S9 之外引用	备注
7/8 数据集 SOTA	✓ 被 S6 摘要分析引用	—
Table 3 的十列 × 四档完整矩阵	✗ 从未被任何阶段完整吸收	本轮最大缺口：全流程只零散用了 8.63、93.3、89.1 三个数
LAMBADA 52.66 / 63.24 / +4%	✓ S5、S6、S7、S8	—
WSC 70.70 / +7%	✓ S4、S6	—
CoQA 55 F1 / 3 of 4 / 127k	✓ S4、S6、S7	—
1BW 42.16 与“最差一列”	✓ S5 至暗四、S6 §2	—
Table 4 六行全部 + 6.4 点下降	✓ S4、S6、S7	—
翻译 5 / 11.5 / 33.5 BLEU	✓ S4、S6、S7	—
问答 4.1% / 1.0% / 5.3 倍 / 63.1%	✓ S4、S7、S8	5.3 倍的分母问题见 H-G2-05
Table 5（30 条最自信答案）	✗ 仅用了 63.1% 一个数，Table 5 本体从未被使用	中方
重叠 3.2% / 5.9% / 13.19% / 0.88–6.31%	✓ S4、S7、S8	—
Figure 5（生成样本重叠 CDF：中位数 2.6%，超 30% 样本零重叠）	✗ 从未被吸收	这张图是全篇最硬的“自证不是背”材料，三个阶段都没用它
Table 12–17（多样补全 / 独角兽新闻 / 摘要错误案例 / 翻译样例 / CoQA 实例）	✗ 从未被吸收	尤其 Table 14：§3.6 用它作为“摘要为何失败”的诊断案例，而 S4/S5/S6 只用了 ROUGE 数字、没用诊断
§3.2 “closes the majority of the gap to human performance”	✗	人类性能基线（Bajgar et al.）未被叙事使用
§4 的 Winograd 重叠细节（10 个 schema / 2 个假匹配 / 1 个泄露）	△ 仅在 S4 §9 登记，未进叙事	这条是回应“是否背答案”的关键细节

3.2 图类缺口（非叙事责任，属提取限制）

Figure 1–5 全部无法从纯文本核验（提取只有 caption）。叙事中任何涉及图内形态的断言都只能回溯到 caption 或正文旁证——H-G2-07 即由此产生。这不是叙事的疏漏，是数据源的物理限制，但必须记在案，因为它决定了“哪些判断在本流程里根本得不到核验”。

3.3 一处“漏得正确”的例子

论文 §3.2 的概括句 `performance steadily improves as model size is increased` 被第 0 步重算证伪（CBT-CN 93.45 → 93.30，见 R-1）。叙事从未复述这句概括——S4 第 9 节只登记了 CBT 的 93.3 与 89.1 两个绝对值，S5、S6 均未写任何 CBT 的单调性判断。结果是：叙事漏掉了论文的一个错误，反而避免了把论文的错误抄进来。这条说明“覆盖度缺口”不等于“必须补”——缺失与错误是两码事，S8 的职责是分清它们。

4. 核 S7（专项）

4.1 审稿人三条 weakness 的数字逐条复验

条目	审稿人给的数字	复验结果
MW1 : 52.66 / 63.24 / 59.23 / 4.01	全部可在 §3.3 与 Table 3 找到	全部成立
MW2 : 29.34 / 28.78 / 0.56 / 21.40 / 20.98 / 0.42 / 32.75 / -11.35 / 41.22 / -11.88	全部可在 Table 4 找到	全部成立
MW3 : 4.1 / 1.0 / 5.3 / 反推 0.77 / 345M 与 762M 的 NQ 缺失	全部可在 §3.8 找到	全部成立
MC1 : 0.88 / 6.31 落在 1–6% 之外	Table 6	成立
MC2 : Table 3 无去分词前的原始值	Table 3	成立
附表 : Table 3 矩阵、“7 out of 8”、Table 4 六行 R-AVG、Table 6 两个平均值、6.4 点下降、LAMBADA 自治	全部复算	全部成立
Table 5 计数 22 ✓ / 8 ✕	与第 0 步审计子代理的 21/9 冲突	机器核查采信 22/8（见 0.5）；审稿人正确

审稿人自身的一处失准：MW1 写“摘要与 §1 反复强调 `without any parameter or architecture modification`”。摘要里没有这句话——摘要的对应表述是 `without any explicit supervision`，而 `without any parameter or architecture modification` 只出现在 §1【可查证：两处原文】。审稿人的批评方向成立，但“摘要与 §1”这个并列不准确。严重度 P2（对隔离方的审计也须有）。

审稿人未发现的：R-1（CBT-CN 非单调）、R-4（R-2 单指标反例）、R-6（CoQA 的 7 域 vs 5 域）。见下节。

4.2 rebuttal 引文逐条复验

S7 的 rebuttal 共引用 5 处论文原文作为立论依据，另在落地对照表里引用 5 处最终稿表述。逐条核对：

引用	出处	复验
<code>without any parameter or architecture modification</code>	§1	✓
<code>an approximation</code> （停用词过滤器）	§3.3	✓
<code>rudimentary/far from use-able</code>	§6	✓
摘要失误形态“车撞了几辆、logo 在帽子还是衬衫上”	§3.6	✓
<code>We observe gains of 2.5 to 5 perplexity</code>	§3.1	✓
§3.3 首句实际写的是“从 99.8 到 8.6 困惑度”（承诺前移对照但未落地）	§3.3	✓ 复验一致
<code>competitive, and state of the art results depending on the task</code> 出自 §1 而非摘要	§1	✓ 审稿人错引、作者纠正正确

§3.8 最终稿仍只有 4.1% / 1.0% / 5.3 倍三个数字	§3.8	✓
§4 最终稿仍为 between 1-6%	§4	✓
§3.1 最终稿仍无去分词器对照表	§3.1	✓

结论：**rebuttal** 的引文零悬空，落地对照表的 6 行判定全部成立。**S7 第 3 节的"5 条修改承诺 0 条完全落地、1 条部分落地"**这一统计经复核无误。这是本轮仿真里可核验性最强的一节。

4.3 隔离是否真合规

- S7 第 0 节声明子代理只拿到 `gpt2.txt` 路径。核对其输出中不含任何本项目的内部术语（"档案""v0/v1/v2""负结果占比""待验猜想""S3""S6"等）→ 合规。
- 唯一需要排除的边界：审稿人写出的"反推 0.77%"。核查其推导链（ $4.1\% \div 5.3$ ）→ 纯自主推导，不是档案泄漏。合规。
- 第 0 步审计子代理同理：其输出只含论文行号与算式，无内部术语 → 合规。

5. 两个隔离视角的发现集合不重合（本轮新增发现）

发现	审稿人（框架=「我会怎么攻」）	审计员（框架=「逐行重算趋势」）
5.3 倍与 1.0% 无法对账	✓ MW3	✓ I-2
1-6% 区间与表不符	✓ MC1	✓ J-1
LAMBADA 的 SOTA 依赖后处理	✓ MW1	✗
摘要任务水位被"competitive"掩盖	✓ MW2	✗
NQ 缺 345M/762M 的受控曲线	✓ MW3 附加	✗
CBT-CN 非单调（93.45 → 93.30）	✗	✓ R-1
Table 6 逐列反例（WikiText-2、text8）	✗	✓ J-2
R-2 单指标反例	✗	✓ G-1
117M 在 PTB 上劣于 SOTA	✗	✓ B-3
Table 5 计数	✓ 22/8	✗ 21/9（错）
CoQA 的 7 域 vs 5 域内部不一致	✗	✗（本阶段补上）

共 11 类发现，两者交集只有 2 类；两者各自独有 4 类与 5 类；两类都漏 1 类。

结论（对本流程最有价值的一条）："隔离审稿人"与"重算趋势"不是同一件事的两种做法，而是两个互补且各自不完备的审计视角。 审稿人的注意力被"claim 不可攻"牵引，因此对框架性夸大敏感（LAMBADA 的界定、摘要的水位），对表内单调性迟钝；审计员的注意力被"逐行差值"牵引，因此对表格算术极度敏感，却完全不会去问"这个 claim 的措辞是否过度"。 → 模板修订建议：把 S7 的审稿人提示词与 S8 第 0 步的审计提示词固化为两份互不引用、观察框架明确不同的提示词；并明确规定 S8 第 0 步的审计员不得评价方法好坏，只做算术与文本对照（本轮已如此执行，效果显著）。

6. 这套仿真教会我的东西里，哪些是读论文原文绝对学不到的？

分三层，并声明每层的性质。

第一层：论文里只有"痕迹"、没有"理由"的决策——读原文只会读到做法

学到的东西	性质
Reddit 的 3-karma 门槛，本质是用一个免费的人类投票信号，替换掉买不起的人工筛选工序——它不是"数据源选择"，是"工序替代"	史实（做法见 §2.1），但"工序替代"这层理解读原文得不到

四档 log-uniform 尺寸矩阵，是"容量作为自变量"这一 claim 的必要代价，而不是"顺手多训了几个"	重构（代价关系可由 claim 结构推出）
\$6 末段的微调承诺，位置上处于全文末尾、形式上只有一句——它的功能是防御而不是计划	重构（但位置与篇幅是可查证事实）
摘要里选 <code>unsupervised</code> 而不选 <code>zero-shot</code> ，是因为过程本身给了任务上下文格式	重构

第二层：过程里真实存在的判断与挫败——读原文完全无从得知

- 三条 naive 想法各自的死因与次序（尤其"数据来源可以是自然文本"这一读法是从 decaNLP 的论证里反向读出来的）
- 至暗三：零样本首版产出"合理续写非合法末词"，一度判定可能致命、一度考虑退回微调；靠"这是约束缺失不是能力缺失"这一判据救回
- 1BW 的失败曾按 bug 排查，最终以"规模与预处理捆绑"重新解释
- rebuttal 的 5 条承诺在最终稿里 0 条落地，以及这一现象归因于技术报告的流程性质与发布窗口

性质声明：以上全部为【合理重构】，其依据已逐条记在各阶段《档案》中，不可当作史实引用。

第三层：本流程独有的产物——关于"审计本身"的知识

这一层是读论文和读任何一份研究复盘都得不到的：

1. 本轮自身的误差基线：约 55 条断言 / P0-P2 占 18.2% / P0 1 条（1.8%）。与 GPT-1 首跑（17% / 2 条 / 3.3%）相比，**P0 减半而 P0-P2 总量未降**，且唯一那条 P0 与 GPT-1 的 P0 同属"缺席断言"形态。→ 模板能压住事实性错误，压不住措辞层面的过度自信。
2. 两个隔离视角的发现集合几乎不重合（交集 2/11），且各自都有独有盲区。
3. 论文自身的六处问题（R-1 至 R-6），其中 **R-1（CBT-CN 非单调）与 R-6（CoQA 的 7/5 域）**在论文文本层面是硬冲突，R-6 连两个隔离视角都漏了。这一条最出乎意料：一篇被引用数万次的论文，它的摘要级数字（7/8）是对的，但它的趋势句和自己的表打架。
4. "漏检"不等于"失分"：叙事漏掉了论文那句被证伪的 CBT 单调性概括，反而避免了把论文的错误抄进自己的稿子。

性质声明：第 1、2、4 条是本流程的实验结果（可复现）；第 3 条是论文文本层面的可查证事实。

待办的模板改动（下一轮生效，本轮不改）

1. S1-S6 的纪律条款里，"每个判断打标签"之外追加一条措辞强度条款：凡标【合理重构】的段落，正文不得使用"就是""正是""唯一"这类断言级副词；否则降级为"可能是""大概率"。→ 直指本轮 6 条 P2 与 3 条 P1 的共同病根。
2. S2/S3 的"必须引出论文的动机原句"这条纪律，要把"引用"与"动机"显式分开：有引用 ≠ 有动机。本轮 P0 正是把"没有动机句"写成了"没有任何引用"。
3. S8 第 0 步的审计提示词独立固化（见第 5 节结论）。

《档案·S8》

【阶段】S8 对照复盘（幻觉总检查）
【已知事实】
1. Table 3 的十列五行完整矩阵已重建；7/8 判定成立；1BW 是唯一未超既有结果的一列（42.16 对 21.8）【可查证：Table 3】
2. Table 4 六行的 R-AVG 全部等于 R-1、R-2、R-L 的算术平均，逐行无误差【可查证：Table 4】
3. Table 6 两个平均值复核无误（3.2% 与 5.9%）；但区间陈述 1 至 6% 与表内 0.88% 至 6.31% 不符；自身重叠列有两个反例【可查证：Table 6 与 \$4 原文】
4. 论文 \$3.2 的概括句 performance steadily improves as model size is increased 被自己的表格证伪：CBT-CN 在 762M 到 1542M 由 93.45 降为 93.30【可查证：\$3.2 与 Table 3】

- 5. 论文内部两处域数不一致：§3.5 称 CoQA 含 7 个域，§4 称开发集指标在 5 个域上取平均【可查证：两处原文】
- 6. 论文 §3.6 的 just barely outperforms selecting 3 random sentences 在聚合指标上成立，但 R-2 单指标反例（8.27 小于 8.63）【可查证：Table 4】
- 7. Table 5 的对错计数经符号码位机器核查为 22 正确、8 错误（共 30 条）；论文未给出这 30 条的准确率，正文只给最有信心 1% 上的 63.1%【可核验：_verify_s8.txt】
- 8. ablation 及其变体在全文出现 0 次，确认无消融表【可核验：机器检索】
- 9. 审稿人三条 weakness 的全部数字复验成立；其唯一失准处是把 §1 的表述归到了摘要【可查证：§1 与 Abstract 原文】
- 10. rebuttal 的 5 处论文引文与落地对照表的 5 处最终稿引文全部零悬空；5 条修改承诺 0 条完全落地、1 条部分落地这一统计成立【可查证：逐条对照】
- 11. 两个隔离子代理的输出中均不含本项目内部术语，隔离合规【可核验：§7 第 1 节与本文件第 0 节】
- 12. Figure 1 至 Figure 5 无法从纯文本核验，只能借 caption 与正文旁证【可核验：gpt2.txt 中图区只余 caption】

【合理重构】

- a. 至暗一至至暗四的场景、时长与心理活动——依据：各阶段已声明的锚点（重型重构，本轮风险最高处）
- b. rebuttal 承诺未落地的三条归因——依据：论文形态与发布进程（重构）
- c. 将 §7 审稿人与 §8 审计员的注意力差异解释为“观察框架不同”——依据：两个子代理输出中独有发现的重合度统计（重构）

【负结果】

- 1. 本轮自产幻觉 10 条（P0 一条、P1 三条、P2 六条），占带标签实质断言约 18.2%
- 2. P0 的绝对数量由 GPT-1 的 2 条降至 1 条，但 P0 至 P2 总量未降；模板措辞层面的过度自信无效
- 3. 覆盖度缺口四类：Table 3 完整矩阵从未被完整吸收；Table 5 本体未用；Figure 5 未用；Table 12 至 17 未用（含 §3.6 的摘要失败诊断案例）
- 4. 立项时（§0）提出的三条风险中，风险 1（无消融表）与风险 3（文献边界）已按预案处理，风险 2（非投稿形态）在 §7 出现轻度越界但已自查纠正
- 5. 三条模板改动建议本轮不生效，留待下一轮（本阶段负结果占比约 45%）

【未决问题】

- 1. 三条模板改动需要在下一轮（或下一片论文）验证有效性，尤其“措辞强度条款”能否压住 P2
- 2. R-1 与 R-6 两处论文自身问题要不要写进 §9 的附录《勘误与对照》？按 §9 模板第 1 条，附录要保留 §8 三张表，故应当写入【交 §9】
- 3. Figure 1 至 5 不可核验这一限制要在 §9 里如何处理（是声明还是回避）【交 §9】

【一致性自检】本阶段与全部前序档案无冲突，且已反向修正三处：H-G2-02 把 §2 与 §3 的“无引用”断言改为“有引用无动机”；H-G2-03 把 §3 的 v1 死序标注由轻改为中重度重构；H-G2-06 把 §5 的“三刀就是处方”改为“一刀半锚点、两刀零锚点”。三处修正均以修订注形式留在原文件，未静默覆盖。唯三处实质性冲突（§2 与 §3 对同一事实的重复误述、§4 对论文口径的照抄、§6 对图内细节的断言）已全部定位到具体的已知事实条目。

【后见之明自检】本阶段本应有一次后见之明核查——反过来查前序阶段有无泄漏。结果查出 §3 有一处泄漏（H-G2-09：在 v0 死因里写出“后来它变成了整整一节（§4）”），已记录并加注。其余阶段未发现同类问题。

语言模型自己会做任务，这件事我用了半年才敢说出口

——GPT-2 的第一人称复盘：一个被反向读出来的想法、三次被自己否决的方案，和我一年后才敢承认的四件事

仿真声明：本文是基于公开材料的第一人称合理重构，不代表论文作者本人或其机构的真实经历、观点或言论。凡“我记得”“我当时猜”“这一点论文里没写”的段落属重构；凡带数字的事实均可在论文原文核对，依据见全文末的章末注。本文的对照核查结论（含我自己写错的十条）压缩在附录里。

第一幕·问题：我发现自己答不出“为什么赢”

本章论点：卡住我的不是模型不够大，是我做赢了一件事却说不清它为什么赢——而说不清的胜利，对理解没有任何贡献。

起点不在 2019 年，在 2017 年。

那一年我做了一个实验，很久以后我才知道它其实是我后来所有判断的源头：一个 byte 级的 LSTM，训练目标朴素到不能再朴素——猜下一个字节。训完以后，它的内部长出了一个专门管情感的神经元：我把它拧一下，生成的文本情感就跟着翻面（这一点可以在当年的那篇论文里查到）。没有人教过它“情感”这个概念，它自己长出来了。

这件事在我脑子里留下一个执念，后来我把它压缩成一句自问：

如果语言模型在预训练里已经学会了怎么读句子，那为什么每个下游任务还要从零学一遍怎么用它？

这句话听着像口号，但它其实是一个能拿来否决方案的标准——它否决的第一个方案，就是我自己的。

我们确实做成了一个

2018 年我们做了那篇后来被叫做 GPT-1 的东西：一个 Transformer 语言模型，预训练完以后，把判别式任务全部拍平成一条序列，只在最后加一个线性层微调。架构零改动，预训练里学的每一层都参与下游任务。结果不难看。

但我心里有个疙瘩一直没解开：我还是得给每个任务准备标注数据。

GLUE 的数据是人一条条标出来的，问答的数据是人一条条标出来的。模型越好，就越像是在把人的标注吃得更干净，而不是自己学会了。这跟我 2017 年那个执念是相抵触的。

那年十月，有人把答案摊在了桌上

BERT 出来的时候我正在做别的事。他们用双向的目标加上微调，在 GLUE 上把我们一起架到了火上。

刺到我的不是输赢，是那条路的上限。如果继续在“预训练加微调”这根轴上比，比的是谁的标注数据用得更狠、谁的目标函数更巧——而这根轴的上限是人类愿意标多少数据。人手是有价格的，所以这条路往上走，空间是有限的。

我当时的第一个想法特别平庸：把 GPT-1 继续做大，去 GLUE 上把分数反超回去。四层变八层，十亿变五十亿。

这个方向被否决了三次，我每次都想挽回。

第一次被否决，是因为它不回答任何新问题。打赢只证明我们的工程量更大，不证明“语言模型学会了任务”。哪怕赢了我也说不出为什么赢。

第二次被否决，是因为算术。当时的共识是：机器学习系统要泛化（学会的东西能用到没见过的例子上），需要成百上千个训练样本。多任务训练里，一个“数据集加一个目标函数”就算一个样本——照这个数，要兑现多任务的承诺，大概也需要成百上千个这样的“对”。而那些最激进的两项工作分别只做到 10 个和 17 个。这不是方向选错了，是规模指标选错了：继续堆，就是拿人力去填一个指数级的缺口。

第三次被否决，是因为它和“泛化”这两个字背道而驰。再做一个单任务、单域的模型，就是往我们诊断出的那个毛病里，再添一笔。

一个把整件事翻过来的说法

我那时候反复盯 GPT-1 的目标函数看，看到的是一件当时让我愣了一下东西。

先说直觉：监督学习和语言建模，用的其实是同一本教材，区别只在批改的范围。语言建模要模型把整段话的每一个

位置都猜对；监督学习只把其中一小段圈出来批改。

再说机制：语言建模的目标是最大化一段序列的联合概率，也就是每个位置上"下一个符号"的条件概率的连乘；监督学习的目标是最大化"给定输入时输出的条件概率"。后者是把前者的求和范围限制在一个子集上。范围缩小，不会改变函数本身，只会改变我们考察它的位置。

写成式子是这样（这一段论文里是有的，而且它是全篇最要紧的一步）：

语言建模：	$\max \sum_t \log p(s_t \mid s_1 \dots s_{t-1})$	对所有位置 t
监督学习：	$\max \sum_{t \in \text{输出区}} \log p(s_t \mid s_1 \dots s_{t-1})$	只对答案那几个位置

两式是同一条式子，后者的求和是前者求和的一部分。于是有一件事在数学上是通的：让整段概率最高的那组参数，也一定让答案区间的概率最高——语言建模的全局最优解，就是监督学习的全局最优解。

结论听上去很诱人：那我们不需要为每个任务设计目标，只需要一个足够好的密度估计。

它哪里不像：这条结论只保证"存在一个既会说话又会答题的解"，完全不保证"我们优化得到"。而这两件事的距离，就是这个项目后来全部的痛苦所在——我说过一句很重的话留在论文里：这条路走得通，但比显式监督慢得多。

第二幕·直觉：如果任务本身就是文本

本章论点：把"教模型做任务"这件事从流程里删掉，前提是把任务说明看成文本的一部分——这句话我起初读反了方向，读对之后整条路才通。

那句让我通的话，是别人写的，而且写出来的时候不是给我用的。

decaNLP 那篇工作里有一句：语言提供了一种灵活的方式，把任务、输入、输出都表示为符号序列。他们举的例子是 (translate to french, english text, french text)。

他们用这句话论证"可以做一个多任务模型"——我读成了另一件事：任务说明本身就是一段文本，那它就可以是训练语料的自然成分。

差别看似很小，性质完全不同：他们要多标十个数据集，我连标都不用标——只要网上有人写过"英语句子 = 法语句子"。

先把这张地图画出来：我在哪儿，谁站在旁边

我不敢凭印象说"没人做过"。动手之前我把这块方向队伍数了一遍，分成四派：

- **A 派**，表征迁移——word2vec、GloVe、CoVe、ELMo 这一串。做法是把无监督学到的表示搬给下游任务。这一派的要害是：搬过去的只有表示。ELMo 到了下游还得自己叠一层 BiLSTM 和注意力——也就是说无监督学到的东西只负责输入层，真正做判断的仍然是标注数据现场学。我把它归为"更好的初始化"，不是"自己会做任务"。
- **B 派**，预训练加微调——我的出生地。Dai & Le 2015、ULMFiT、GPT-1，还有 BERT。我的架构、优化器、训练配方几乎全是继承来的，这一点我不否认。但这一派每一篇的进展都可以被读成"如何更省地用标注数据"，而不是"可以不标注"。论文里我把这句写得很直白：这些方法仍然需要监督训练才能执行任务。
- **C 派**，显式多任务——decaNLP、One Model To Learn Them All。半个近亲：它给了我"语言可以描述任务"这个工具，但它的任务描述是人为发明的控制码，我的任务描述是语料里本来就有的自然文本。差这一步，性质完全不同：它造数据，我找数据。
- **D 派**，单点突破——Weston 2016 的对话学习、Schwartz 2017 的常识推理、Karpathy 2015 从 RNN 里读出来的可解释单元，还有我自己 2017 年那个情感神经元。和我最接近的一派。但这派全是单任务、单数据集的定性观察，没有一篇做过系统评测——所以谁也说不清"这是普遍现象"还是"这是运气好"。

四派摆在一起，那个空位就清楚了：没有人把"不用微调、不预设任务"这件事，放到一个足够大的语料和足够大的模型上系统测过。我要占的就是那个空位。

一个让我在屏幕前坐了一会儿的发现

我本来准备在论文里写一句"零样本任务迁移是空白"（零样本：不给这个任务的任何训练样例，直接让它做）。写之前我去查了 Winograd Schema Challenge 的榜。

Trinh & Le 2018 已经用语言模型做过了，而且没在 WSC 上训练过。他们的做法是比较两种消解里哪个概率更高——这就是零样本任务执行，跟我打算做的事在性质上是同一件。

如果这件事已经有人做过，我那篇文章的第一句话就不成立了。

最后是两处细节救了我。

第一处是他们的语料。他们的最好结果建立在一个"小样本的 Common Crawl 子集"上，而这个子集的筛法是"只保留与目标数据集最相似的文档"。我盯着这句看了很久——这说明他们已经把任务知识预先注进语料里了，那是一个为 WSC 量身定制的语料。要是我能把语料做得完全不带任务偏好、还能赢，性质就完全不同。论文里我写下的那句话是：我们要避免预先对任务做假设。这句话表面上是方法论，实际上是我被抢先之后画的那条界线。

第二处是他们只做了一个任务。一个任务分不清"语言模型普遍会做任务"和"语言模型的某条路径恰好撞对了这一个"。要证明前者，就得换很多任务、换很多数据集——而这一点恰好是我唯一有优势的地方：我有容量，也有语料。于是"广度"成了我的护城河。后来论文里那七个任务探针，根子就在这个下午。

我为什么敢赌网上真的有这种东西

我不能只靠"网上什么都有"这种印象。当时我找到的依据是 Weston 那篇对话工作：他证明了不给奖励信号、直接靠"预测老师会说什么"也能学会一个问答任务。但他被"对话"这个设定框住了——需要有人陪你聊。

我的判断是：互联网上的信息是被动可得的，不需要交互。有人在网页里写"她是法国人，她说 Je ne suis pas un imbécile"，这条网页本身就同时包含任务说明、输入和输出。

它哪里不像：网页里的人是主动在理解和表达，模型只是在拟合条件分布。它可能学会的只是"翻译这件事的表层模式"，而不是翻译。这个疑问后来变成论文里整整一节（第四幕细说），而且它没有被彻底消掉——只能被压缩到一个很小的比例里。

顺手先把"字怎么进模型"这件事定了

这一路最容易被忽略、但工作量最实的是输入表示。我在这里失败了两次。

第一次失败：按码点做 BPE。（码点就是每个字符在电脑里的编号。）要覆盖全部 Unicode，基础词表就得超过 13 万——而当时 BPE 常用词表是 3.2 万到 6.4 万。代价不是钱，是分配：多出来的七万多个槽位本来可以装词。

先说直觉：BPE 就是把频繁一起出现的小单位粘成更大的积木——先有字母，粘成常见片段，再粘成词。词表就那么大的话，粘什么、不粘什么，决定了模型的"容量预算"花在哪里。

再说机制：它从最小单位出发，反复找出现频率最高的一对邻居，把它们合并成一个新单位，记进词表；重复到词表满为止。之后任何文本都按同一本词表切成块。"常用"在这里的定义就是出现次数多。

它哪里不像：频率高 ≠ 语义重要。按纯频率走，"的""the"这类会先被粘成整块，而"熵""不可约"这种信息量高的词反而被切成碎片。BPE 选择的是压缩效率，不是语义单元——它本来的目的就是要把文本压短。

第二次失败：干脆全部按字节来。字节级天然满足"任何字符串都能算概率"这个要求（别人 2015 年就做过），但字节级语言模型在大规模数据集上不及词级模型——文献这么说，我自己在语料上重跑也看到了同样的差距。这是"文献说不行、我也验证了不行"的双重否定。

活下来的版本是字节级 BPE：基础词表只有 256 个字节，然后在字节序列上做合并。但直接合并不行——我实测发现 dog、dog.、dog!、dog? 各自占了一个槽位。原因是 BPE 只看频率，不看它在什么位置出现。

修法是禁止跨字符类别合并：字母归字母、数字归数字、标点归标点，不许粘到一起。例外是空格——给空格开这个例外以后，压缩效率显著提升，而带来的词碎片化极小。这一条是全文少数给了"代价—收益"对比的设计，所以它是我记得最清楚的一条。

它哪里不像：这条"不许跨类"的规则自己就带着例外，说明它是一条工程妥协，不是一条原理。词表最后定在 50257 个。

到这里，输入修好了。但"答案在哪"这个最要命的问题，一点没动。

第三幕·试错：这一阶段真正的工作量在删东西

本章论点：从第一版到最后一版，我删掉的东西比留下的多；而每一个被删掉的版本，死因都比活着的版本更值得

记。

这张桌子上不止我一个人

论文首页有六位作者，前两位标星号、末两位标双星号，脚注写的是“同等贡献”。也就是说四个人被标为同等贡献，中间两位没有标记。这个结构本身就说明：这不是一个人写的故事，四条线都有话语权。

我把当时的三种考量摆一下：我这一头记的是“做出一个别人没做过的东西”，愿意为一句说不清能不能成的话投入几个月；资深作者那一头记的是“故事线站得住、发布不出问题”，他管我叙事的一致性；其余几位的考量最杂——除了工程和算力，还多出一条“这东西放出去会不会被滥用”。他们的天然动作是压缩 **scope**。

所以下面被放弃的东西，都不是因为它们错，是因为没人手、没算力，或者怕风险。

被放弃的两样（不是因为它们错）

第一样是多语言。这一处放弃得最艰难。我原来的想法很直白：“语料越杂越好，那多语言当然更杂。”放弃的理由不是学术，是分析成本：语料里一旦混进多语言，所有单语评测集的重叠分析和困惑度（困惑度衡量模型对下一个词的把握有多差，越低越好）口径都得重做一遍。最后的处理是一刀切，主动移除全部非英语网页。

这个砍法后来以一种很讽刺的方式回到了论文里（第四幕细说）：那台语言检测器发现，法语只残留了 10MB。而正是这 10MB，成了“完全没教过翻译、却冒出 11.5 BLEU（BLEU 是翻译质量的打分，越高越好）法译英”这一结果的解释材料。被放弃的方向没有消失，它以证据的形式回来了。

第二样是把整套权重和语料直接开放。一开始的默认计划是全开——上一代就是这么做的，代码和数据都放出去了。这次放弃的理由不是工期也不是算力，是误用风险。最后的形态是分阶段的：先放小模型，最大的那个暂缓公开。论文里唯一那句关于开放的承诺，用的词是“小模型”——它是全文唯一一处模型开放承诺，而那个“小”字本身就是这次决议留下的痕迹。

我想强调这条的性质：它不是实验做得不够，是一次主动的、不可逆的自我限制。

v0：去掉微调这一步

第一版的做法朴素到没什么可说：GPT-1 的流程是「预训练 → 拍平成序列 → 加线性层 → 微调」，我把最后两步直接删掉，只留「预训练 → 拍平成序列 → 采样」。任务是文本，就写一段，让模型接着写，从写出来的东西里取答案。

它有三个毛病，一个我当时就看得见，两个是后来才看清的。

看得见的那个是效率：预备实验里已经显示，足够大的语言模型确实能做这种玩具式的多任务学习，但比显式监督慢得多。慢意味着必须用规模和时间去换——这一条后来决定了整个项目的形态（第四幕）。

后来才看清的第一个是接口：模型续写的是网页文本的分布，不是答案的分布。它给的东西可能完全合法、完全通顺，但不在我要的位置上。这个道理，我是几个月后在 LAMBADA 上（一个要求猜出段落最后一个词的测试）才彻底看明白的：模型给出的大多是句子的合法续写，而不是合法的最后一个词。

这句话我后来写进了论文，因为它说明的不是“模型不会”，而是模型没有被告知“这里要的是那个词”。

后来才看清的第二个是防线：如果模型只是把语料里见过的问答原样背出来，那我做出来的东西叫检索，不叫零样本任务学习。这一层在 v0 阶段我甚至没有检验手段，只能把它留作一个悬案——结果它后来长成了一整节，而且成了这篇论文里我最自豪的一节。

至暗时刻：深层的模型训不起来

这一段持续了大概六周，是我在这个项目里最没底的时候。

模型往上堆层数，浅的几档还能出曲线，深的一上来就发散；学习率压得很小能稳住，但损失降得比浅模型还慢。换句话说，加参数没换来收益，只换来了不稳定。

我当时判断“该救还是该弃”的标准只有一条：这是超参问题还是结构问题？判它是结构问题，理由很直接——学习率调小能稳住，说明不是数据问题也不是目标问题，是尺度问题：信息在残差通路上逐层累积，深层拿到的量级和浅层根本不是一个数量级。

对症下药的药方是三处改动：把 LayerNorm 挪到每个子块的输入（类似 pre-activation 残差网络）、在最后一个自注

意力块之后再加一层 LayerNorm、把残差层的初始化权重按 1 除以根号 N 缩放。

这里是这篇文章我要说的一句实话：这三处改动，论文里只写了做法，一句动机都没给。而三处里只有第三处能对上一句描述——“为了照顾残差通路上的累积”——另外两处，一直到今天我也不知道它们当初是为了解决什么才加的。我在复盘里把它们写成“对症状开的药方”，那是我的重构，不是记录。这是整轮复盘里风险最高的一处说法，我在附录里把它列为我自己写错的第 2 条。

v1：第二条腿是“把任务写进上下文”

输入修好了，效率问题靠规模换，但“答案取不出来”这件事一直卡着。我试过用后处理去解——被我否了，理由不是技术，是立场：只要加一层任务专用的后处理，我这条路的性质就从“语言模型自己会做任务”退化到“我教语言模型做任务”。那条腿一旦装上，整篇文章就没有了。

真正的转折不是某个模块，是我换了个念头：别让模型自己知道要干什么，我来告诉它——用文本告诉它。

既然任务是文本，那我就在推理的时候把任务写进上下文。论文里所有任务都是用同一个约定做的：

- 阅读理解：把文档、对话历史、最后一个 A：一起喂进去；
- 摘要：文章后面加 TL;DR:，然后生成 100 个 token；
- 翻译：上下文给若干 english sentence = french sentence 的样例对，最后以英文句子加等号收尾；
- 问答：用问答样例对做种，帮它推断这个数据集要的是短答风格。

这就是最后一块拼图，我把它命名为：零样本不等于零格式。

先说直觉：考试允许你带一张写着题型的纸条，但不许带答案。纸条不算作弊，因为它不含答案；但纸条确实帮了你。

再说机制：模型没有为任何任务更新过权重——这一点严格成立，因为推理时一个梯度都没算。我改的只是喂进去的那段文本。而条件概率的定义本身允许条件任意长： $p(\text{答案} \mid \text{文档, 历史, "A:"})$ 和 $p(\text{答案} \mid \text{文档})$ 是同一个函数在两个不同输入上的取值，函数没变。

它哪里不像：纸条是我写的。写什么、写多长、用什么格式，都影响成绩——而“写什么”这件事本身是很强的先验注入。所以“零样本”这个词我用得很小心：论文标题里我用的是 `unsupervised`（指没有监督信号），不是 `zero-shot`。这不是措辞讲究，这是防守。

语料：从“多就是好”到“多且被人筛过”

最后一件事是数据，也是这个项目里唯一一次我自己的立场被自己的实验打回来。

一开始要的是 Common Crawl：免费、大到近乎无限。但第一批样本拉下来，满屏是不可读的文档。更要命的是，早就有别人公开抱怨过这件事，还写明了他们的解法：只保留与目标数据集最相似的文档。

这句话把我的路堵死了一半。如果连他们都认为“语料的域匹配”比“语料的量”重要，那我“靠量取胜”这条腿就断了。

转折不是技术突破，是一次立场转换：从“多即是好”改成“多且被筛过才是好”。而筛的办法不能花钱——人工筛选整份网页爬取的成本是异常昂贵的——所以只能找现成的人类信号。

当时想到的是 **Reddit**：只抓取至少拿到 3 个 karma 的出站链接。那 3 个 karma 就是“其他用户觉得这个链接有意思、有用或者只是好笑”的替代信号。

现在回头看，这一条是整条数据轨的支点。它用一个免费的人类投票，替换掉了一道买不起的人工工序。它不是一个数据源选择，是一次工序替代——而论文里只写了做法，没有写这一层。

最后语料定下来是：4500 万条链接，去重加启发式清洗之后，略多于 800 万篇文档，40GB 文本，只保留 2017 年 12 月之前创建的链接。抽取用两个开源内容提取器组合。

这个 **40GB** 不是上限，是这一次的余量。两处独立的内证：论文里写了所有模型都还在语料上欠拟合，给更多训练时间困惑度仍在改善；而训练集和测试集的性能是一条线一起往上走的。规模没有到顶，是工期和算力到顶了。

一次“规避偏差，偏差换了个方向回来”的返工

我们赌的是“字节级输入，所以不需要任何有损预处理”。这句话当时我觉得很漂亮。

然后评测集从另一个方向给了我们一个反例。那些下游数据集大多经过激进标准化，带着“断开标点与缩写、打乱句

子"这类分词痕迹，甚至出现 <UNK> 这个字符串——而它在我的语料里极端罕见，四十亿字节里只出现了 26 次。

结果是我得反向造工具：一个可逆的去分词器，把尽可能多的预处理痕迹还原回去。"可逆"这两个字是硬要求，不然数据集的对数概率就算不出来。论文里我把它称作"一种简单的域适配"。

这条的教训很硬：我为"不引入分词偏差"而放弃了分词，最后不得不为别人的分词偏差写一个逆向器。规避一个偏差不会消除它，它只是以另一种形式回来了。

顺带说一个被我们主动删掉的候选：Wikipedia。删它的理由我当时觉得挺反直觉——不是因为它脏，是因为它太干净、太大众：它是许多数据集的共同来源，与测试任务重叠会让后面所有的分析变复杂。为了少一份分析上的麻烦，我们删掉了一个质量最好的数据源。

一根刺长成了一节：怎么证明它不是背出来的

这是我前面挂的那根刺。做法是：

先说直觉：把整座图书馆的每一本书拆成七个字的片段，全部倒进一个大筛子；之后拿一段新的话来筛，筛得到就说明它见过。

再说机制：这个筛子叫 Bloom 过滤器——它用一组哈希函数把每个片段映射到一串位上，只要一个片段的所有哈希位都是 1，就认为"见过"。它的特点是只可能误报"见过"，不可能漏报。我把误报率的上界压到一亿分之一，并生成 100 万个字符串做验证，命中数为零。

它哪里不像：它不能给你"零"，只能给你"小于一亿分之一"。而且判定单位是 8-gram，也就是八个词的连续片段——八个词相同不代表意思相同，也不代表模型是"背"的，它只是说明这段文字在训练语料里出现过类似的片段。所以这个工具能反驳"整段照抄"，但反驳不了"在语义层面记住"。这个界限，我在论文里是用"小但一致的收益"这种说法绕过去的。

筛完的结论分三层。

第一层，常用语言建模数据集的测试集，与我的训练语料的重叠大概在百分之三这个量级；而它们与各自训练集的平均重叠还更高一些（这条后来被核查抓住了两个反例，见附录）。

第二层，也是我最想让人看到的一层：我自己的模型生成的文本，与训练语料的重叠比那更低——中位数只有 2.6%，超过三成的生成样本重叠为零。换句话说，模型给出的东西，大多不是从语料里搬来的。

第三层是三个很小的、但我认为最漂亮的数字。我把重叠检查反过来用在最难的那个任务上：Winograd 的 273 个样例里只有 10 个与训练语料有 8-gram 重叠，其中 2 个还是假匹配，剩下 8 个里只有 1 个出现在"会泄露答案"的语境中。而 LAMBADA 上，把任何有重叠的样本剔除之后，困惑度从 8.6 只变成 8.7、准确率从 63.2% 只降到 62.9%。这不是漂亮的数字，是很小的数字——而这正是我要的那种数字。它说的是：那些分数不是从语料里翻出来的。

这张重叠分布图是全篇最硬的"自证不是背"材料，但我把它放进了附录。这一点我在第五幕里要交代。

第四幕·定型与反例：四档曲线，和三道墙

本章论点：我们赌的是"四档规模的完整曲线"，不是任何单个设计的作用——这个赌注决定了我后来承受的每一次质疑，这些质疑我都接受。

那个把我从"报一个数"逼到"报四个数"的争辩

关于模型尺寸，团队里有过一次我至今记得的争辩。管算力的一方的账很简单：训一个 15 亿参数的模型已经很贵，训四个就是四份钱；而且如果 claim 是"零样本能做任务"，那报一个数、做出来就行。

我的理由不是学术，是逻辑：我的 claim 不是"能做任务"，是"容量是这件事的关键"。这个 claim 里"容量"是自变量，一个点画不出因果关系。只报最大的那一个，我说的每一句关于容量的话都变成不可验证的断言。

最后是条件性让步：报四档，尺寸近似对数均匀铺开，但不能再加第五个。这四个点后来撑起了全文三张主图，也撑起了摘要里那句"性能随规模对数线性改善"。

先说这个赌注的核心：容量是自变量

直觉：水深不到一百米，有些鱼就是不会出现。不是这些鱼笨，是环境没到位。

机制：语言建模的损失是“平均每单位文本的负对数概率”。当模型的参数容量相对于语料的复杂度不够时，它只能先把高频、简单的结构学好——语法、常见搭配。要它同时把“翻译”、“问答”这些低频结构学好，就必须先有足够的容量把这些结构分开存放。容量不够的时候，这些结构是互相冲突的，模型只能记住平均。所以这项能力看起来是“突然出现”的——它不是突然学会的，是容量跨过某条线之后，那些结构才第一次有地方放。

它哪里不像：水的临界点是常数，一百度永远是开水；模型的能力阈值不是常数，它随任务变化，而且有些任务越给容量越没用——这一点很快就遇到了反例（见下面那道拆不掉的墙）。

反例一：赢了 8 个里的 7 个，那个 1 是最大的数据集

结果出来是：刷新了 8 个语言建模数据集里 7 个的记录。LAMBADA 的困惑度从 99.8 降到 8.63，儿童读物测试拿到 93.3%（常用名词）和 89.1%（命名实体），Winograd 拿到 70.70%，比之前的最好结果高 7 个百分点。阅读理解上更漂亮：在不使用那 12.7 万条人工问答对的前提下，CoQA 上（一个对话式阅读理解测试）拿到 55 F1（问答类任务的打分，越高越好），追平或超过了四个 baseline 里的三个。

但那个 1，是最大的那个数据集。

One Billion Word Benchmark，我拿到的数是 42.16，而之前的最好结果是 21.8。不是我略输，是差了一个量级。而这件事最难受的地方在于它的方向：我全篇的主轴是“数据越多、模型越大越好”，结果最大的数据集反而最差。

这个反常我们按 bug 排查了很久。最后落到的解释是：这个数据集同时是最大的、也是预处理破坏性最强的——它做了句级打乱，而句级打乱移除了全部长程结构。

我们的长处恰好是长程依赖，这个数据集把我们的长处切掉了。

这不是一次被挽救的失败，是一次被理解的失败。代价是我必须承认：“规模越大越好”这句话有前提，而那个前提写在正文第三段，不在标题里。

反例二：LAMBADA 的那两个数

这一段我打算讲得比论文里更直接，因为论文里我把它写得偏靠后。

LAMBADA 上我有两个数：不加任何后处理，准确率 **52.66%**；加一个停用词过滤器（把最常见的那些功能词排除掉），**63.24%**。而既有最好结果的记录是 59.23%。

也就是说：不加那个过滤器的我，没有超过前人。

那个过滤器在干什么？它只是把“答案必须不是虚词”这条约束近似了一下——因为模型给出的错误大多是“这是一句合法的续写，只是不是合法的最后一个词”。它不训练任何东西、不动任何权重，论文里我用的是“一种近似”这个词。

我到现在仍然坚持：这不矛盾。论文里那句“不改任何参数与架构”，限定的是参数和架构，不是解码过程——否则所有基于解码策略的工作都会被一并否掉。

但我承认审稿人指出的呈现顺序问题：我在正文里的写法是“从 19% 提升到 52.66%，再加过滤器到 63.24%”，读者沿路读下来会以为 59.23 这个对照不存在——可它明明就印在我自己的表里。这是编排上的回避，不是学术上的错误，而它同样不该发生。

反例三：摘要只赢了随机抽句 0.42 分

摘要这个任务我从一开始就知道会难看。结果确实难看：

平均 ROUGE 是 21.40，而“从文章里随机抽三句”是 20.98。差了 **0.42**。而且只在加上 **TL;DR:** 提示的时候才勉强赢——去掉提示掉到 15.03，一次掉 **6.4** 分。对照组的 SOTA 是 32.75。

还有一处细节是在核查阶段才被挖出来的：在 **R-2** 这个单项上，随机抽三句（**8.63**）是赢我的（**8.27**）的。

它的失败形态不是“写不出摘要”，是“写出来的摘要关注错了地方”。论文里我留了几个具体的错误案例：模型会去纠结“车撞了几辆”“logo 是在帽子上还是衬衫上”这类细节，而把真正的主干丢了。这个诊断其实比分数重要，因为它指向的瓶颈不是容量，是目标错配——摘要的评分指标（ROUGE）数的是词重叠，跟“生成一段像人写的摘要”本来就不是同一件事。再加一个大模型不会改变这个诊断，只会多耗一次算力。

翻译更弱：英译法 5 BLEU，比用双语词典逐词替换还略差；法译英好一些，11.5 BLEU，比几个无监督基线强，但当前最好的是 33.5 BLEU。

而法译英这个 **11.5** 的来由，是整篇论文里我印象最深的一处反转。

我们在内部争过要不要多语言，最后的决定是主动移除全部非英语网页——理由是分析成本。后来我跑了一个字节级的语言检测器，想确认一下滤干净了没有。答案是没滤干净：还残留大约 **10MB** 法语。

当时这是一条坏消息。写论文的时候它变成了证据：我们主动删掉了非英语数据，只因为没删干净那 **10MB**，模型就冒出了 **11.5 BLEU**。被放弃的那个方向没有消失，它以证据的形式回来了。

反例四：一个我一年后才发现的分母问题

问答任务上，我的模型在 Natural Questions 上答对 4.1%，而一个“不管问什么都答最常见答案”的极简基线是 1.0%。我在正文里写了一句：“GPT-2 多答对了 5.3 倍的题。”

一年后做核查的时候我才发现：**4.1** 除以 **1.0** 等于 **4.1**，不等 **5.3**。

5.3 倍的分母其实是最小那档模型自身的准确率，大约是 0.77%——而这个数字我根本没写出来。读者的眼前只有 4.1% 和 1.0%，只能拿它们相除。这是我的表述缺陷，不是口径差异。审稿人指出了它，我在回应里认了，然后在最终稿里没有改。

还有一道拆不掉的墙，和一道我自己撞出来的

拆不掉的那道是评测协议。LAMBADA 的前人最好结果是在“受限预测”下取得的：模型的输出被约束成只能从上下文里出现过的词里选。我照抄了这个设定——结果它在我身上起的是反作用：**19%** 的答案根本不在上下文里。

这个坑的性质很值得记：不是我的方法有问题，是“继承别人的评测协议”这个动作本身有风险。协议里可能藏着一条只在别人模型上成立的隐含假设。这个反例后来救了我——它把一件事从“我们不行”改判成了“口径不同”。

自己撞出来的那道是《丛林之书》。做儿童读物测试的数据重叠分析时发现，测试集里有一本书就在我的训练语料里。处理方式是放弃测试集、改报验证集。

这一条完全是我们没做功课。评测集清单一确定，跑一次 n-gram 重叠检查只需要几小时。而这件事的后果是：它催生了整篇论文里我最自豪的那一节（记忆与泛化的对照分析）。用一场事故换来一节方法论，净赚还是净亏，取决于有没有别人先替你付过学费。

一个我至今仍无法释怀的数：CBT 那句“持续改善”

最后一处，是核查阶段从论文自己的表里挖出来的，而且是我自己论文里的错。

我在儿童读物测试一节里写了“性能随模型规模增大持续改善”。

但我的表里不是这样。常用名词这一列：87.65 → 92.35 → 93.45 → **93.30**。最后一步是往下的。也就是说，我宣称的那个“93.3% 的新记录”，低于我自己 **7.62** 亿参数那档的 **93.45**。

对外它仍然是新记录（压过了 85.7），对内它和我自己的概括相冲突。这句话我写的时候是顺手的，表格里的数字是对的，中间那一步没人核对。

第五幕·讲法：同一堆材料，怎么讲才卖得出去

本章论点：到这一步数据已经不会变了，能改的只有说法——而我在说法上做的每一个决定，都是在防守。

标题里那三个词，我改了很久

论文的标题是 `Language Models are Unsupervised Multitask Learners`。这个标题里有三个决定，每一个都是为了防守。

第一，主语是“语言模型”，不是“我们的模型”。换成“我们的模型不用监督就能学会任务”，一个现象级的发现立刻降级成一次产品发布。用复数主语，claim 的层级就从“我们做出来了”升到“这件事本来就成立，我们只是第一个把它说清楚的人”——顺手也降低了被指“夸大自研方法”的攻击面：我们没有自研方法，我们只是把规模推到位了。

第二，动词用 **are**，不用 **can be**。前者是断言，后者只是可行性陈述。

第三，我用的是 **unsupervised**，不是 **zero-shot**。三个决定里最关键的一个。因为整篇流程里明明有一个地方不零样本：我给每个任务都写了上下文格式。用“无监督”，描述的是“没有监督信号”，这一条完全站得住；用“零样本”，会被追问“你那几个前缀算不算提示工程”。选这个词的动机是防守，不是形容。

摘要放大了三样，藏了四样

放大的是三样。

一是开场那个体感最强的数字：CoQA 拿到 **55 F1**，而且紧跟着“不使用那 127,000 多条训练样本”。这是全文最强的一句，因为它把“标了多少数据”这个变量直接扣掉了。

二是一句能被反复引用的机制断言：容量对零样本任务迁移必不可少，性能随规模呈对数线性改善。

三是一个可数的事实：8 个语言建模数据集里的 7 个刷新了记录。

藏起来的是四样。

藏起 **LAMBADA** 的真实口径。摘要一个字都没提那个 63.24% 是靠停用词过滤器拿到的，也没提不加过滤器只有 **52.66%**。

藏起那个失败列。摘要把 7/8 说出来了，那个 1 是什么，要翻到后面才知道。

藏起摘要和翻译的真实水位。摘要只比随机抽三句高 0.42 分、英译法只有 5 BLEU——摘要里一个字都没有。

藏起“这是我们自己的口径”。非英语是我们主动删的，但法译英那 11.5 BLEU 被拿出来当正面结果；这层因果在摘要里不可能看到。

三句外交辞令，后来被人逐句拆过

第一句，把规模那篇经验分析拉来当护墙。审稿人的第一句话一定是“这不就是把模型做大吗”。我的做法是先把 Hestness 2017 那篇“深度学习里规模是可预测的”分析摆进来，再把自己定位成“该趋势在任务子集上与十亿参数以上的延续”。这样“做大”就不再是我的方法，而是一条已被确立的经验规律——我的贡献变成“这条规律的适用范围比想象中广”。同一句里我还主动承认了一处不足：“while much noisier across tasks”，把“我们的曲线不干净”提前说掉。审稿人提出来的第一遍是攻击，作者自己先说的就是坦诚。

第二句，把缺席的实验写成计划中的实验。论文最后一段有一句“我们计划研究 decaNLP 与 GLUE 上的微调”。这句话在博弈上的作用是双份的：对内部，它是“我们没忘，只是下一篇”；对外部，它是一道预先设好的防线。而且我在这句里主动把最不利的可能性说了出来——我们的单向表征可能补不上——这样别人再提“你们没和 **BERT** 比”，就显得是在复述我自己的话。

第三句，抢在别人之前承认两处。一处是把摘要里那个“前景可观”立刻压回“离可用还很远”；另一处更进一步，是我自己揭示自己的弱点：前面那个 55 F1 里，有一部分是靠“问谁就从文档里挑个人名”这种检索式启发式拿到的——这一句我写进了正文。在公开场合主动交出这一点，比被人查出来代价小得多。

还有一句我处理得很轻：对那篇抢先的工作，我一句批评都没写。我只把他们的做法称为“务实”，然后声明我们想避免预先假设任务。把一次分界说成一次取向差异，把他们语料里带任务偏好这件事留给读者自己补。

哪张图放主文，哪张塞进附录

主图给了“多任务零样本性能随模型规模变化”那张网格图。它的选型逻辑很清楚：它同时承载三件事——曲线向上（容量假设）、任务横跨阅读理解翻译摘要问答（广度）、以及有些任务的绝对水平很难看，但趋势线是正的。反过来说：它是最有效的一张能让“我们表现很差的任务”为论文加分的图。那个任务单独出现在正文里就是失败；放进这张网格图里，它变成“容量是自变量”的证据。这是整篇排版上最聪明的一处。

主表十列并排放。列数本身就是一层遮蔽：那个失败的数据集被放在最右边一列，与七个成功列并排时被视觉稀释。如果它单独成表，它就是这篇论文的一个洞。

摘要那张表留在主文，但只用它的差值。正文引用的是“去掉提示后掉 6.4 分”，不是那个 21.40 的绝对值——差值证明了“任务提示能召唤任务行为”，绝对值只会告诉读者我们打不过专门的摘要模型。

而那张最硬的自证图，被我放进了附录。就是第三幕那张重叠分布曲线。理由我当时没写下来，但逻辑是清楚的：把它放正文，等于把“我们可能是在背”这个问题提到台面上讨论；放附录，它就在那儿，但不引导读者去想。这是一次有意的降噪。

第六幕·反思：我留在这篇论文里的最大问题

本章论点：一年后回头看，这篇论文最大的问题不是我算错了什么，是我有一整套设计，从一开始就没打算证明它们

各自有用。

整篇没有一张消融表

上一代那篇（GPT-1）里，我有一张逐任务的微调消融表，所以每个“某组件救了我”的说法都能对着差值行被验一遍。

这一篇一张都没有。

改动列了四处：归一化位置、末端再加一层归一化、残差层初始化按 1 除以根号 N 缩放、上下文从 512 提到 1024 并把 batch 提到 512。这四处里，哪些真的起了作用、哪一条是顺带加的，这篇论文永远没有回答。

最接近消融的只有两处，而且都不算消融：去分词器只给了“2.5 到 5 的困惑度增益”这个区间、没有对照表；摘要那节的“去掉提示”是全文唯一一处能做逐格差值的单变量对照。

为什么不做？诚实的原因是：我赌的是那四档曲线本身，不是任何单点消融。我认为“容量是自变量”这件事一旦被曲线画出来，单个设计有没有用就不重要了。

这个赌注让我付出了代价。如果审稿人问“那三个 LayerNorm 相关的改动到底哪个有用”，我至今答不出来——我在第四幕说的“药方”，有一半是我事后把日志和改对起来的，见附录。

我把它写成“结构性缺口”而不是“我们的疏忽”，不是美化：把它说成疏忽就等于承认“我们本来能补”。真实情况是，做这篇论文的时候我根本不认为这些设计需要单独证明。

我们确实被严格审过——只不过不是在会场里

这一篇从来没有经过正式的同行评审。它是一份技术报告，真实的把关发生在两个地方：投稿前的内部草案反馈（致谢里列了四位给过意见的人），以及发布前的误用风险评估。

我让一个完全没有看过我任何内部记录的人，只拿着论文本身审了一遍。他给了三条 major weakness 和两条 minor，总评是弱拒。三条里：

- **LAMBADA** 那条（依赖任务特定后处理）我部分力争——零样本界定的是权重，不是解码；但我接受把 52.66% 和 59.23% 的对照提到前面。
- 摘要那条（把定量上只比随机抽句好 0.42 的任务和真正的 SOTA 并列）我接受。
- **5.3 倍**那条我完全认错。

然后我写了回应。核查阶段把我那份回应逐条对到最终稿上，结论是：五条可以落地的修改承诺，零条完全落地，一条部分落地。

这个统计我觉得比论文里任何一个数字都更能说明问题：在一份技术报告里，回应意见不是修改流程的一环，它是一次“说完就完了”的表述。原因有三条，前两条查得到（没有程序委员会来催终稿；论文的核心叙事不依赖任何一条被质疑的地方），第三条是我更愿意承认的——那五条里四条都只是“补一个数字”，而我当时更想赶在发布窗口前把实验收尾。

核查阶段挖出来的一件事，比我自己写的错更值得记

我让两个互不相通的人做核查。一个的角色是“我会怎么攻这篇论文”，另一个的角色是“把每张表逐行做差值”。

结果是：一共 11 类发现，两者的交集只有 2 类。攻击型的那个人找到了 LAMBADA 的界定问题、摘要的水位问题，但完全没发现儿童读物那列的单调性断裂；差值的那个找到了单调性断裂、重叠表的两个逐列反例，但完全不会去问“这个词用得是否过头”。

两类都漏了一处：论文里 **CoQA** 的域数，在第三节说 7 个、第四节说 5 个。

这条经验我打算一直用下去：核查不是一件可以委托给一个人的事，因为注意力框架本身就决定了你会看见什么。

我自己写错的十条

核查阶段把我这份复盘里的实质判断逐条拿去对论文，查出十条有问题的：一条是与论文事实直接矛盾（我把“论文没给动机”写成了“论文没有任何引用”——论文对其中一处是给了引用的，这跟我当年犯的另一类错一模一样：把“我没注意到”写成“论文里没有”）；三条是程度过头或论据来源错位（包括我在第四幕说的那三处“药方”、以及我凭印象描述的一张图的曲线形态）；六条是“标签贴对了、话却说太满”。

和上一轮相比，最硬的错从 2 条降到 1 条，但“话说过头”这一类的绝对数量没有下降。这句话是我对自己这套工作方法最诚实的一次评价：标注能挡住“编事实”，挡不住“加着标注把话说满”。

最后：哪些是读论文原文绝对学不到的

分三层，我把性质标清楚。

第一层是论文里只留了痕迹、没留理由的决策。3 个 karma 不是“选了个数据源”，是用免费的人类投票替换掉买不起的人工工序；四档尺寸不是“顺手多训了几个”，是“容量作为自变量”这个 **claim** 的必要代价；末尾那句微调承诺不是研究计划，是防御性安排（它的位置在全文最后一段、形式上只有一句）。这一层的做法是史实，理解是重构。

第二层是过程里真实的判断和失败。第一版“答案是合法续写但不是合法末词”、一度让我考虑退回微调；1BW 失败曾按 bug 排查；回应意见五条零落地。这一层全部是重构，依据逐条记在文末章末注里，不能当史实引用。

第三层是这次复盘独有的产物。我自己的误差基线（约 55 条断言里 18.2% 有问题）、两个核查视角发现集合几乎不重合、以及论文自身的六处问题——其中儿童读物那列的单调性断裂和 CoQA 的 7 域对 5 域是硬冲突。

而这里面最出乎我意料的一条是：这篇论文摘要级的数字（7 个里面的 7 个）是对的，但它用来概括自己表格的那句话是错的。

写论文最难的地方大概就在这儿——你最容易搞错的，从来不是你算出来的数，是你为了让别人好懂而顺口写下的那半句概括。

章末注（重构点留痕，每条一行：哪个判断、依据是什么）

1. 2017 年情感神经元作为动机主线——依据：作者公开研究轨迹的连续性；该文不在 GPT-2 参考文献表的闭环内核验，属论文外材料。
2. 时间点设为 2018 年 10 月、触发场景为 BERT 公开当周——依据：参考文献时间差与论文中 BERT 的对标位置。
3. “标注数据的成本是这条路的上限”这一第一动机——依据：论文把“采集数据集与设计目标的规模化困难”列为动机主轴，但未写成第一人称动机句。
4. 三条 naive 想法的次序与死因——依据：论文对多任务对数规模的算术批评、对“不预设任务”的定位。
5. “先试字词级 BPE、再试纯字节级”的顺序——依据：按致命程度重排；论文实际叙述序与此相反（见附录第 3 条）。
6. 深层的三处改动对应“训不稳定”这一症状——依据：仅“残差通路上累积”一句可作半锚点，另两处零锚点；重度重构。
7. 在推理时把任务写进上下文是“最后一块拼图”——依据：四处任务格式在论文中承担了零样本 claim 的全部实现。
8. 语料来源之争的翻盘台词——依据：论文从“拒绝 Common Crawl”直接跳到“只用人类策展的链接”，中间取舍痕迹由此补出。
9. “3 个 karma 是一次工序替代”——依据：论文同时写了“人工筛选异常昂贵”与“karma 是他人觉得有趣或有用的启发式指标”两处。
10. 40GB 是工期余量而非算出的上限——依据：两处独立的“仍欠拟合”表述。
11. “把生成样本与训练语料的重叠图放进附录是有意降噪”——依据：该图的存在性与所在位置（附录）。
12. 摘要任务的失败“补实验也没用”——依据：论文把该任务的失误形态诊断到具体细节层面，瓶颈指向解码目标与生成式输出的错配。
13. 回应意见的承诺普遍未落地归因于技术报告的流程性质与发布窗口——依据：前两条原因可由论文形态查证，第三条为重构。
14. 两个核查视角的注意力差异解释为“观察框架不同”——依据：两者独有发现的重合度统计（交集 2 / 共 11 类）。
15. 至暗时刻的时间跨度与心理活动——依据：由三处改动的症状侧反推，属重型重构，不可当作史实。
16. “改动的动机有一半是事后把日志和改对上的”——依据：论文对这些改动零动机句。
17. 四档尺寸之争的具体争点与让步形态——依据：论文“四个、近似对数均匀”的措辞与“尺寸不能再加”的隐含边界。
18. 团队考量的三分法与“天然动作是压缩 scope”——依据：首页四位同等贡献标记的分布与致谢中的算力依赖；三种考量的内容为重型重构，论文无任何第一人称立场记录。

19. 分阶段发布的动机是误用风险、"small"一词是决议痕迹——依据：论文脚注 5 只承诺公开小模型，以及论文外公开的分阶段发布事实。
20. 删 Wikipedia 的理由是"太干净太大众"——依据：§2.1 原句写明移除理由是它是许多数据集的共同来源、重叠会复杂化分析；把"太干净"读成痛感属重构。
21. 标题三个词各自的防守功能——依据：论文全文以复数主语陈述一般性结论、四处任务格式均需人工书写；作者动机为重构。
22. 摘要"放大三样、藏起四样"的取舍清单——依据：Abstract 三处表述与 §3.1、§3.3、§3.6、§3.7 之间的信息缺口对照；取舍动机为重构。
23. 三句外交辞令的功能定位（护墙、预先防线、提前承认）——依据：§5、§6、§3.5、§2.1 四处原句的措辞与位置；功能读法为重构。
24. 排版决策（网格图容纳低分任务、十列并排稀释失败列、只用摘要表差值、自证图进附录降噪）——依据：各图表的结构、位置与正文引用方式；动机无原文，属重构。

附录 · 勘误与对照（原核查报告压缩版）

A. 我自己写错的十条（按严重程度）

#	错误断言	实况	严重程度
1	论文的架构改动"没有任何引用"	其中一处明确引用两篇文献	P0（与论文事实直接矛盾）
2	"那三处改动就是对症下药的药方"	三处中仅一处有半句描述性依据，另两处零依据	P1
3	在第一版的死因里写出了"后来它长成了一整节"	在明令不得预知论文形态的阶段里泄漏了未来章节	P1（后见之明泄漏）
4	凭印象描述了一张图的曲线形态	该图无法从文本核验，真实依据是正文水平	P1（论据错位）
5	"BERT 是唯一被当作对标对象引用的同期工作"	另有两篇同期工作被引用	P2
6	宣称两条死路的顺序"接近论文叙述序"	实际叙述序与此相反	P2
7	原样照抄了论文的"1–6%"重叠区间	表内实际区间是 0.88%–6.31%	P2
8	把"5.3 倍"的分母擅自补全	论文未写明分母	P2
9	两处"唯一"	另有图表具备同性质质	P2
10	"数据集被前人净化过"	论文归因于数据集自身的激进标准化	P2

误差基线对照：约 55 条实质断言中，P0 + P1 + P2 合计 18.2%；其中 P0 仅 1 条（1.8%）。与上一轮相比，P0 从 2 条降到 1 条，但"话说过头"这一类没有下降。

B. 论文自身的六处问题（不是我写的，是核查算出来的）

#	论文的概括句	反例（精确数字）
R-1	"性能随模型规模增大持续改善"	常用名词列 762M→1542M： 93.45 → 93.30 （下降 0.15 ）；且宣称的 93.3% 低于同表 762M 的 93.45
R-2	测试集与训练语料重叠"在 1% 到 6% 之间"	实际 0.88% （PTB）到 6.31% （enwik8）（平均值 3.2% 无误）
R-3	"许多数据集与自身训练集的重叠更大"	两个反例：WikiText-2（0.66% < 1.63%）、text8（2.34% < 3.94%）（平均值 5.9% 无误）
R-4	摘要"仅仅比随机抽三句好一点"	聚合指标成立（21.40 > 20.98，差 0.42），但 R-2 单项反例：8.27 < 8.63
R-5	"在 Penn Treebank 这类小数据集上有大幅提升"	小模型 117M 在 PTB 上是 65.85，劣于既有最好结果 46.54
R-6	第三节称 CoQA 含 7 个域，第四节称开发集指标在 5 个域上取平均	论文内部两处域数不一致，两个核查视角都漏了

C. 覆盖度缺口（论文有、阶段叙事没用上的）与成稿的补法

△ 这一节的“缺口”指的是阶段叙事正文（S1–S8）的缺口。成稿（本文正文）允许跨阶段取材，故必须逐条声明是否补上，否则本节会与正文口径冲突。

#	阶段叙事的缺口	成稿是否补上
1	主表的完整数值矩阵（十列乘四档）从未被完整吸收——本轮最大缺口	✗ 未补（成稿只用了 8.63、63.24、93.3、89.1、42.16 五个格）
2	最自信那 30 条答案的表，除了“最有信心 1% 上 63.1%”这一个数之外从未被使用	✗ 未补
3	生成样本与训练语料的重叠分布图（中位数 2.6%、超过三成样本零重叠）从未被吸收——它是全篇最硬的自证材料	✓ 第三幕已补（含 273 / 10 / 2 / 1 与 8.6→8.7、63.2%→62.9% 两组剔重叠复算）
4	附录里的摘要失败案例、翻译样例、阅读理解实例从未被吸收；尤其摘要那一节，论文用具体错误案例做了诊断，而复盘全程只用了 ROUGE 数字	△ 部分补（第四幕补了摘要的错误形态，翻译样例与阅读理解实例仍未用）
5	儿童读物一节“已追平人类表现的大半”这一说法未被使用（人类基线未被引入）	✗ 未补
6	论文全部五张图无法从纯文本核验，只能借图注与正文旁证——这是数据源的物理限制，不是叙事的疏漏	△ 成稿在章末注第 24 条与“论据来源”处一律声明，不假装看过图内形态

一处“漏得正确”的例子：阶段叙事与成稿都从未复述 R-1 那句被证伪的单调性概括。漏掉论文的一个错误，反而避免了把它抄进自己的稿子——缺失与错误是两码事。

一处“补得对但越了界”的例子：第 3 条是阶段叙事漏掉、成稿单方面补上的。这属于跨阶段取材，性质上比“从 S1–S8 改写”多走了一步——它让成稿比它的素材更完整，但也意味着成稿里的这一节无法在阶段叙事中逐字回溯。

D. 隔离审稿专项

- 三条 major weakness 的全部数字逐条复验成立；两条 minor 成立。
- 唯一失准处：把一句只在第一节出现的表述说成“摘要与第一节反复强调”。
- 他自己数的那张表是 22 对 8 错（30 条），与另一位核查者的 21 对 9 冲突；机器按符号码位复核为 22 对 8 错。
- 我那份回应的 5 处引文与落地对照表的 5 处引文全部零悬空；“5 条承诺 0 条完全落地、1 条部分落地”的统计成立。
- 隔离合规：两位核查者的输出中都不含任何内部记录术语。

外行闸记录（模板第 6 条）

做法：抽三段——第四幕·反例二（LAMBADA 的那两个数）、第二幕·字节级 BPE 的直觉层、第五幕·摘要放大三样藏四样——交给一个隔离子代理：只喂这三段的原文，不喂论文、不喂任何《档案》、不喂本文其余部分。它的角色设定是“聪明但完全没有机器学习背景的外行”，并被告知：答错说明写作者写得不够外行友好，请如实说“我没看懂”，不要编一个听起来合理的答案。

结果：三段的复述与两道理解题全部答对（3/3）。包括三处最容易讲糊的地方——“什么时候算超过前人、什么时候不算”、“词表大小为什么是一种代价、代价花在哪儿”、“为什么扣掉‘标了多少数据’会让结果显得更强”。

但它同时交出了一份很长的“只能靠上下文猜”的词表：LAMBADA、停用词与虚词、权重与参数、架构、解码过程、码点、Unicode、熵、语义单元、困惑度、F1、BLEU、零样本、对数线性、口径。也就是说：故事线与因果过关了，术语裸用没过关。

处置：对八处首现术语补了括号内的一句话释义（泛化、零样本、码点、困惑度、BLEU、LAMBADA、F1、停用词）。没有补的是基准名（CoQA、Winograd、1BW）与“对数线性”这类只在语境里起修饰作用的词——给每一个专有名词都加释义，会把文章变成词典，得不偿失。

诚实结论：这一关只能证明“外行能跟上故事与因果”，证明不了“术语已经不构成门槛”。GPT-1 首跑的外行闸是 3/3 不合格，这一轮是 3/3 合格；但两次暴露的是同一个毛病，只是这次没有烂到影响理解。

【阶段】S9 成稿（面向外行的第一人称长文）

【已知事实】

1. 本篇全部带数字的事实均可回溯到论文原文，依据见正文与章末注
2. 全文按六幕故事弧重排（问题 → 直觉 → 试错 → 定型与反例 → 讲法 → 反思），不按 S1 到 S8 的时间线
3. 分支：本篇在正文中保留了全部负面硬数字（LAMBADA 无过滤器 52.66%、摘要只赢随机抽句 0.42、1BW 42.16、En→Fr 5 BLEU、CBT 那列 93.45→93.30），一个都没删
4. 成稿含《档案·S9》之前的三个附件：章末注、附录《勘误与对照》、外行闸记录；三者都不计入正文篇幅

【合理重构】

1. 二十四处重构点已在章末注逐条留痕（哪个判断、依据是什么）；其中第 6、15、16 条属重度重构，风险最高
2. 行内标签已按模板转为语气承载（“我记得”“我当时猜”“这一点论文里没写”），可核验性由章末注承接
3. 新增的七处重构（第 18–24 条：团队考量、分阶段发布的动机、删 Wikipedia 的痛感、标题三词、摘要取舍、外交辞令、排版决策）只有“做法/位置/措辞”这一层史实，动机层是重构，已在章末注逐条标注

【负结果】

1. 负结果占比：第三幕（试错与被压缩的 scope）、第四幕（四则反例 + 一道拆不掉的墙）、第五幕（藏起来的四样）、第六幕前半（无消融表 + 零落地的回应）合计为全文主体，估算约 50%
2. 篇幅比：正文汉字 13058，基线（S1 至 S8 叙事正文，含 S8）19497 汉字，比值 67.0%（模板要求 60–70%）；漏掉 S8 会把同一稿件算成 84.3%，按字符数算只有 40.2%
3. 外行闸：抽三段由隔离子代理复述并答理解题，首轮 3/3 通过（GPT-1 首跑为 3/3 不合格）；但外行仍列出一长串只能靠上下文猜的术语，已对八处首现术语补释义，其余基准名不补——详见上方“外行闸记录”
4. 本篇未写入论文自身六处问题之外的任何新指控；六处问题全部有精确数字支撑

【未决问题】

1. 三处类比（水温、筛子、题型纸条）中，“题型纸条”一条的边界最模糊，可能需要在下一轮重写为更强的限定
2. 章末注第 6 条（三处改动与“训不稳定”这一症状的对应）在成稿中仍以叙事语气出现，虽已声明是重构，但语气强度高于证据强度——这是本篇留下的最大残余风险
3. 跨阶段取材：附录 C 第 3 条（生成样本重叠分布）是阶段叙事漏掉、成稿单方面补上的。它让成稿比其素材更完整，但也意味着这一节无法在 S1–S8 中逐字回溯——本轮选择保留并显式声明，下一轮应改为“先把缺口补进 S4/S8，再写 S9”

【一致性自检】本篇与 S8 的三张表无冲突：幻觉清单十条已压缩入附录 A，第 1 条 P0（“没有任何引用”）在正文与附录中只以改正/勘误形态出现（机器检索命中 2 次，均在改正语境）；论文自身六处问题在正文第四幕明写“这是我自己的错”，与附录 B 一致。迷你 S8 机器核查（口径：排除《档案》块自身，因为它会把关键词自己数进去）：S8 的 P0 指纹“没有任何引用”命中 2 次、两次都在改正/勘误语境（正文第六幕的自陈 + 附录 A 第 1 行）、未以断言形态复活；“几乎平的曲线”命中 0 次（论据错位的原句未复活）；新增内容里的每一个数字都已在 gpt2.txt 中核到原样出处（30% 零重叠与 2.6% 中位数、273/10/2/1、8.6→8.7 与 63.2%→62.9%、10MB 法语、26 次 `<UNK>`、6 位作者与四位同等贡献）。

【后见之明自检】本篇按模板定位为“项目结束一年后”的回顾，允许引用结果；但重构与史实的边界已在章末注逐条声明，未把事后解读写成作者自陈；“它后来长成了一整节”一类表述均带“后来”这一显式时间标记，不冒充阶段内的判断。